

Documentation de la démarche

Hypothèses, essais d'IA, tests, résultats, limites, décisions et procédures

Auteur : Charles Lippens, Data Analyst

Objet : Rendre la démarche reproductible, auditable et facile à reprendre par un tiers

Base de travail : Notebook du projet 6, BottleNeck

Date : Octobre 2026, dépôt du projet (première version en juillet 2026)

Version : 2.8, mise à jour du 1er octobre 2026 (jalón J4 réussi le 30 septembre, relecture des essais C et D en cours, date du dépôt, typographie) ; 2.7, essais C et D du notebook complémentaire (réassort, stabilité du modèle), ChatGPT cité, puis relecture finale (essais C et D à relire, versionnage, recommandation 3), le 25 septembre 2026, et mise à jour du 28 septembre 2026 (performance datée, réexecutions des 25 et 28 septembre, maintenance, figures redessinées, texte allégé) ; 2.6, relecture après l'audit de l'énoncé : portée du contrat de qualité, facteurs de performance, indice de Jaccard, reproductibilité (Python 3.11, installation, durée), puis relecture indépendante (portée des neuf contrôles, réserve sur le stock), le 25 septembre 2026 ; 2.5, six réserves (colonnes d'avis vides), valeurs manquantes et référence à 12,65 euros décrites exactement, sécurité des données dite sans formule absolue, le 25 septembre 2026 ; 2.4, lecture des avis clients corrigée (colonnes vides, avis désactivés sur le site) et trois pistes ajoutées en section 10, le 24 septembre 2026 ; 2.3, annexe A (journal brut des essais d'IA, avec les essais complémentaires du 17 septembre 2026) et règle 8.3 complétée ; 2.2, numérotation de la section 10 rétablie ; 2.1, corrigée après les deux passages d'audit

Sommaire

1. Objet et méthode.....	3
1.1 Les sept critères de comparaison.....	3
1.2 Hypothèses de départ.....	3
2. Journal de traçabilité des essais d'IA.....	3
2.1 Axe 1, qualité des données.....	4
2.2 Axe 2, performance et reproductibilité.....	4
2.3 Axe 3, détection d'anomalies.....	5
2.4 Axe 4, interprétabilité et documentation.....	6
3. Justifications techniques.....	7
4. Résultats consolidés.....	7
5. Ce que le projet change pour le métier.....	8
5.1 Recommandations remises au commanditaire.....	9
6. Reproductibilité.....	9
7. Limites et biais.....	10
8. Procédure de documentation.....	11
8.1 Règles de nommage.....	11
8.2 Règles de versionnage.....	11
8.3 Règles de journalisation des essais.....	11
8.4 Règles de rédaction des livrables.....	12
8.5 Contrôle avant dépôt.....	12
9. Posture de conseil adoptée.....	12
9.1 Ce que le positionnement change concrètement.....	12
9.2 Limites du mandat, énoncées au commanditaire.....	12
9.3 Accompagnement des équipes.....	13
10. Synthèse et prochaines étapes.....	13
Annexe A. Journal brut des essais d'IA.....	14
A.1 Axe 1, qualité des données.....	14
A.2 Axe 2, performance et reproductibilité.....	15
A.3 Axe 3, détection d'anomalies.....	16
A.4 Axe 4, interprétabilité et documentation.....	16
A.5 Besoin 2, les chiffres du réassort.....	17

1. Objet et méthode

Pour chaque amélioration du notebook, je donne le raisonnement demandé par l'énoncé : au moins deux options comparées, des critères explicites, la trace des essais. Le but : une démarche reproductible et présentable.

J'ai utilisé les assistants d'IA pour les variantes de code, la rédaction de documentation, les propositions de tests et la reformulation. Chaque sortie a été exécutée et vérifiée avant d'être intégrée, sauf les essais C et D du 25 septembre : chiffres recalculés par l'assistant dans un script séparé ; ma relecture est en cours. Une suggestion qui n'apporte rien de mesurable est écartée, et cet écart est noté comme une adoption.

Principe directeur. Je ne retiens une amélioration que si elle répond à un besoin repéré au cadrage et si elle bat l'existant sur au moins un des sept critères. Garder l'existant est une décision comme une autre, et je la documente de la même façon.

1.1 Les sept critères de comparaison

Identiques dans tout le dossier, ils sont définis dans le document de veille : qualité et robustesse, biais, coût en temps, reproductibilité, sécurité et conformité, maintenabilité, sobriété et impact.

1.2 Hypothèses de départ

Hypothèse	Énoncé	Statut après essais
H1	La qualité des données peut être contrôlée par un contrat déclaratif plutôt que par des contrôles écrits à la main	Confirmée
H2	À la volumétrie actuelle, changer de moteur de calcul n'apporte pas de gain significatif, mais le gain existe à plus grande échelle	Confirmée dans les deux volets
H3	Une détection d'anomalies multivariée capte des cas que la méthode univariée ignore	Confirmée : 26 signaux de plus, dont le nombre découle du taux de 5 %, et un cas avéré, une référence affichée sous son prix d'achat
H4	Le volume de ventes s'explique par des facteurs identifiables et démontrables	Confirmée avec réserve, voir les limites en section 7

2. Journal de traçabilité des essais d'IA

Pour chaque axe : la demande à l'assistant, les variantes, le résultat mesuré, la décision et son motif. Les essais consignés sont faits avec Claude (Anthropic), en mode Cowork. J'ai aussi utilisé ChatGPT (OpenAI), surtout pour la rédaction, la relecture, la recherche d'idées et le code ; ces échanges n'ont pas été archivés. Le journal brut (outil et modèle, dates, extraits de code et de sorties, retouches à la main) est en annexe A et dans le dossier journal_essais_IA, à côté du notebook.

2.1 Axe 1, qualité des données

Élément	Détail
Demande adressée à l'assistant	Convertir les neuf contrôles écrits à la main, sur l'ERP, le site et la table de liaison, en un schéma de validation typé et réutilisable qui produise un rapport des lignes en infraction. Comparer deux bibliothèques de validation.
Variantes testées	Assertions écrites à la main et Pandera, exécutés ; Great Expectations, comparé sur sa documentation
Résultat mesuré	Le contrat retrouve toutes les anomalies des trois règles de l'ERP (prix, stocks, marges) ; les six autres types d'erreurs, sur le site et la table de liaison, restent comptés par la cellule d'audit. Le schéma déclaratif tient en 14 lignes ; les neuf contrôles manuels du projet 6, sur un périmètre plus large, en demandaient environ 55. Le rapport est produit automatiquement. Neuf lignes de l'ERP sur 825 sont en infraction.
Décision	Pandera retenu. Great Expectations écarté pour un notebook, gardé en réserve pour un pipeline. Contrôles manuels écartés car non réutilisables.
Vérification humaine	Le décompte du schéma a été confronté ligne à ligne à l'audit manuel. Un écart d'affichage a été corrigé, voir la note ci-dessous.

Note de lecture importante. Un contrôle portant sur l'ensemble du tableau, comme la règle de marge négative, remonte un cas par colonne et par ligne fautive. Sept lignes fautives sur six colonnes produisent donc 42 cas dans le rapport brut, ce qui prête à confusion. Le rapport a été réécrit pour afficher le nombre de lignes uniques concernées, soit 9 sur 825. C'est ce chiffre qui figure dans le cahier des charges.

2.2 Axe 2, performance et reproductibilité

Élément	Détail
Demande adressée à l'assistant	Réécrire la jointure et l'agrégation dans deux moteurs alternatifs, puis comparer les trois implémentations en temps médian sur plusieurs exécutions, d'abord à la volumétrie réelle puis sur un jeu synthétique de deux millions de lignes.
Variantes testées	pandas ; Polars ; DuckDB
Résultat mesuré	À 825 lignes, les trois moteurs s'exécutent en moins de 40 millisecondes ; DuckDB est le plus lent, à cause de son temps d'initialisation. À deux millions de lignes, Polars et DuckDB sont 4,1 fois et 2,9 fois plus rapides que pandas le 4 août (exécution livrée) ; 8,1 et 5,7 fois sur mon poste le 25 septembre.
Décision	pandas conservé à la volumétrie actuelle, pour la sobriété et la lisibilité. Polars et DuckDB gardés en réserve, activables quand la volumétrie le justifiera.
Vérification humaine	Le résultat de chaque moteur a été comparé au résultat de référence pour vérifier l'équivalence fonctionnelle avant toute comparaison de temps.

Seule la mesure de cet axe dépend du matériel : le gain change d'une machine à l'autre, la décision ne change pas. Toutes les mesures, du 26 juin au 28 septembre, sont en annexe A.2 et dans le journal (fichier 02).




Figure 1. Temps médian des trois moteurs, au volume réel puis sur deux millions de lignes (exécution livrée du 4 août 2026). Figure redessinée à partir des sorties du notebook (mêmes données).

2.3 Axe 3, détection d'anomalies

Élément	Détail
Demande adressée à l'assistant	Proposer une détection d'anomalies portant sur plusieurs variables à la fois, prix, prix d'achat, stock, ventes et taux de marge, et la comparer à la détection existante par écart type sur le seul prix. Évaluer une troisième méthode fondée sur le voisinage local.
Variantes testées	Écart type sur le prix, méthode existante ; Isolation Forest ; Local Outlier Factor
Résultat mesuré	Isolation Forest signale 36 références, la méthode existante 13, dont 10 communes. La méthode multivariée capte donc 26 références supplémentaires, invisibles à la première.
Décision	Méthode existante conservée pour sa transparence. Isolation Forest ajouté en complément. Local Outlier Factor écarté pour instabilité selon le paramètre de voisinage.
Vérification humaine	Les 26 références supplémentaires ont été inspectées une à une. La plus parlante, la référence 4355, est affichée en ligne à 12,65 euros pour 77,48 euros d'achat, sans vente en octobre : la détection sur le seul prix ne pouvait pas voir cet écart. Chaque vente ferait perdre près de 65 euros.




Figure 2. À gauche, la détection sur le seul prix. À droite, la détection multivariée. Figure redessinée à partir des sorties du notebook (mêmes données).

2.4 Axe 4, interprétabilité et documentation

Élément	Détail
Demande adressée à l'assistant	Modéliser le volume de ventes à partir des variables disponibles, puis expliquer les facteurs de façon interprétable, à la fois globalement et référence par référence. Comparer les importances globales du modèle et une méthode d'attribution par valeurs de Shapley.
Variantes testées	Importances globales d'un modèle d'arbres ; valeurs de Shapley avec l'explicateur dédié aux modèles d'arbres
Résultat mesuré	Le modèle atteint un coefficient de détermination de 0,72 sur le jeu de test, pour une erreur absolue moyenne de 1,54 unité. Le stock disponible est le premier facteur du modèle, devant le prix d'achat et le taux de marge. La note et le nombre d'avis ne pèsent rien, faute de données : les avis sont désactivés sur le site, ces deux colonnes valent zéro pour les 714 produits. En validation croisée à cinq plis (essai D), le pouvoir explicatif va de 0,53 à 0,76 (0,67 en moyenne). Le modèle fait deux fois moins d'erreur qu'une prédiction naïve : 1,54 unité contre 3,46 sur le jeu de test, 1,51 contre 3,26 en moyenne sur les plis.
Décision	Valeurs de Shapley retenues, pour l'explication locale et globale. Importances globales jugées insuffisantes car elles ne disent rien du cas particulier.
Vérification humaine	L'interprétation a été confrontée au bon sens métier, ce qui a fait apparaître un risque de lecture causale abusive, traité en section 7.




Figure 3. Contribution de chaque variable au volume de ventes, référence par référence (valeurs de Shapley ; couleur : valeur de la variable, de faible à élevée). Figure redessinée à partir des sorties du notebook (mêmes données).

3. Justifications techniques

Choix	Décision retenue	Motif
Variables du modèle de ventes	Prix, prix d'achat, taux de marge, stock, note moyenne, nombre d'avis, mise en ligne	Variables présentes dans les extractions et utiles au métier, sans la cible parmi les entrées. Réserve : le stock est relevé le 31 octobre, après les ventes qu'il explique ; usage explicatif, jamais prédictif. En pratique, quatre variables portent l'information : note et nombre d'avis valent zéro (avis désactivés), mise en ligne presque constante (713 produits sur 714)
Traitement des valeurs manquantes	Médiane pour la détection d'anomalies, zéro pour le modèle de ventes	Aucune valeur ne manque dans ces colonnes pour les 714 produits : le remplissage est une précaution pour les prochaines extractions
Stratégie de jointure	Rapprochement en deux temps par la table de liaison	Les deux systèmes utilisent des identifiants différents, aucune jointure directe n'est possible
Algorithme de détection d'anomalies	Isolation Forest	Stable, peu de réglages, adapté aux petits tableaux
Algorithme du modèle de ventes	Modèle d'arbres par renforcement de gradient	Capte les relations non linéaires et se prête à l'explication par valeurs de Shapley
Seuil de détection univariée	Écart supérieur à trois écarts types	Convention statistique usuelle, explicable au métier
Taux d'anomalies attendu	5 %	Ordre de grandeur retenu au cadrage, à réviser avec le métier après une première campagne
Séparation des données	75 % pour l'apprentissage, 25 % pour le test	Limite le surapprentissage et permet une mesure honnête de la performance
Métriques retenues	Coefficient de détermination et erreur absolue moyenne	La première mesure la part de variation expliquée, la seconde parle en unités vendues, compréhensible par le métier

4. Résultats consolidés

Indicateur	Valeur	Origine du calcul
Produits analysables après nettoyage	714	Jointure ERP, liaison et site
Types d'anomalies relevés à l'audit initial	9	Audit des trois fichiers sources
Lignes ERP en infraction au contrat de qualité	9 sur 825	Contrat de qualité déclaratif
Chiffre d'affaires reconstitué	143 680 euros	Prix multiplié par les ventes, par référence
Unités vendues	5 751	Somme des ventes du site
Références générant du chiffre d'affaires	689 sur 714	Ventes strictement positives
Concentration du chiffre d'affaires	435 références sur 689, soit 63 %, font 80 % du chiffre d'affaires : une concentration faible	Cumul décroissant sur les 689 références qui vendent

Indicateur	Valeur	Origine du calcul
Chiffre d'affaires porté par ces 435 références	115 068 euros	Cumul décroissant
Taux de marge moyen	47,4 %, médiane à 48,3 %	Notebook complémentaire, essai C
Anomalies supplémentaires captées par la détection multivariée	26	Comparaison des deux méthodes
Pouvoir explicatif du modèle de ventes	0,72	Jeu de test, 25 % des données
Erreur absolue moyenne du modèle	1,54 unité	Jeu de test
Pouvoir explicatif en validation croisée	0,67 en moyenne, de 0,53 à 0,76 selon le pli	Notebook complémentaire, essai D, cinq plis
Erreur d'une prédiction naïve	3,46 unités, contre 1,54 pour le modèle	Essai D, moyenne du jeu d'apprentissage
Références clés à stock nul	14 sur 435, pour 5 434 euros de ventes en octobre	Essai C
Références à plus d'un an de stock	24, environ 95 000 euros au prix d'achat (35 % de la valeur du stock des 712 produits retenus pour l'essai C)	Essai C, au rythme des ventes d'octobre
Accélération possible en cas de montée en charge	Polars 4,1 fois et DuckDB 2,9 fois plus rapides que pandas le 4 août ; 8,1 et 5,7 fois sur mon poste le 25 septembre	Test sur deux millions de lignes




Figure 4. Concentration du chiffre d'affaires : 63 % des références qui vendent en portent 80 %, une concentration faible. Figure redessinée à partir des sorties du notebook (mêmes données).

5. Ce que le projet change pour le métier

Sujet	Avant, projet 6	Après, projet 13	Bénéfice pour BottleNeck
Qualité	Contrôles écrits à la main, non rejouables	Contrat de qualité déclaratif et rejouable	Les chiffres remis à la direction sont vérifiés avant d'être publiés
Performance	Un seul moteur, choisi par défaut	Décision outillée et documentée	Pas de nouvel outil à installer aujourd'hui ; deux alternatives mesurées si le volume augmente
Anomalies	Détection sur une seule variable	Détection complétée par une méthode multivariée	Les prix sous le prix d'achat et les incohérences croisées sont signalés

Sujet	Avant, projet 6	Après, projet 13	Bénéfice pour BottleNeck
Décision	Analyse descriptive	Explication des facteurs et recommandations	Le réassort se pilote sur la disponibilité en stock
Usage de l'IA	Absent	Assistants tracés et encadrés	Des essais tracés dans un journal, avec leurs décisions

5.1 Recommandations remises au commanditaire

1. **Brancher le contrôle de qualité en amont de chaque import** plutôt que de le lancer à la demande. Le coût est faible, et chaque import est contrôlé automatiquement.
2. **Concentrer l'effort de réassort sur les 435 références qui portent 80 % du chiffre d'affaires.** Les 254 restantes justifient une politique différente, à définir avec les achats.
3. Traiter d'abord les neuf lignes en infraction de l'ERP. Sept ont un prix de vente sous le prix d'achat, peut-être des erreurs de saisie à vérifier avec les achats. Une seule est rapprochée du site : la référence 4355, affichée en ligne à 12,65 euros pour 77,48 euros d'achat, sans vente en octobre. Des deux lignes à stock négatif, une seule reste dans les 714 produits : huit ventes, 356 euros.
4. Piloter le réassort par la disponibilité en stock, premier facteur du modèle de ventes, avec la réserve de la section 7 : ce lien n'est pas causal.
5. **Ne pas changer d'outillage aujourd'hui.** Réévaluer le jour où les ventes seront historisées.

6. Reproductibilité

Élément	Détail
Version de l'interpréteur	Python 3.11 ou supérieur (exécution livrée : 3.11.15 ; mon poste, les 25 et 30 septembre : 3.13.9)
Bibliothèques	pandas, numpy, scikit-learn, pandera, polars, duckdb, shap, matplotlib, seaborn, openpyxl, pyarrow. La dernière étape du notebook imprime les versions des huit bibliothèques principales ; le fichier requirements.txt les fixe.
Graine aléatoire	Fixée à 42 pour la séparation des données, la détection d'anomalies et l'entraînement du modèle
Structure des fichiers	Un notebook séquentiel en huit étapes, un dossier de données à côté du notebook, un dossier de figures, exportées à part (le notebook les affiche sans les enregistrer)
Résolution des chemins	Relative, avec une liste de dossiers candidats. Aucun chemin absolu ni dépendance à un environnement particulier
Procédure d'exécution	Placer les trois fichiers sources dans le dossier de données, installer l'environnement avec <code>pip install -r requirements.txt</code> (versions figées), puis exécuter les cellules dans l'ordre
Durée d'exécution	Une dizaine de secondes pour l'exécution livrée du 4 août 2026, hors installation, dont environ 3 secondes pour le test de montée en charge
Point de vigilance	Le test de montée en charge dépend du matériel. Un écart sur les facteurs d'accélération est normal et ne remet pas en cause la conclusion

Élément	Détail
Ré exécutions de contrôle	Le 25 septembre 2026, sur mon poste (Anaconda, Python 3.13.9, pandas 2.2.3, versions différentes du requirements.txt), trois notebooks ré exécutés sans erreur : mêmes chiffres métier, temps différents. Le 28 septembre, ré exécution par l'assistant dans un environnement neuf, créé avec le requirements.txt : mêmes sorties, temps exceptés. Le 30 septembre, sur mon poste, environnement neuf créé avec le seul requirements.txt : les deux notebooks du dossier de dépôt sans erreur, 14 chiffres clés sur 14, autres sorties identiques hors temps de calcul et version de Python. C'est la preuve du jalon J4 : le critère parle d'un poste vierge, la preuve réelle est cet environnement neuf sur mon poste. Sa validation est demandée en séance 3
Maintenance	Chaque mois : ré exécuter le notebook sur la nouvelle extraction et lire le rapport du contrat. Chaque année : mettre à jour le requirements.txt, ré exécuter sur l'extraction de référence et vérifier les treize résultats. Environ 4 heures par an (cahier des charges, section 8)

7. Limites et biais

Six réserves accompagnent toute lecture des résultats.

Limite	Portée	Ce qui l'atténue
Échantillon réduit	714 produits seulement. Le pouvoir explicatif de 0,72 dépend de la partition des données : de 0,53 à 0,76 en validation croisée, 0,67 en moyenne. Il reste à confirmer sur d'autres mois.	Validation croisée à cinq plis (essai D), chiffre toujours donné avec sa fourchette
Chaque anomalie est un signal à vérifier	La détection multivariée peut produire des faux positifs. Une référence signalée n'est pas nécessairement fautive.	Aucune correction automatique. Toute action passe par une validation du service achats
Corrélation et causalité	L'explication porte sur le modèle, pas sur le monde réel. Affirmer que le stock explique les ventes peut refléter une logique d'offre : on ne vend que ce que l'on a en stock, et le stock est relevé le 31 octobre, après les ventes du mois.	Le résultat est présenté comme une aide à la priorisation, jamais comme une loi causale
Données figées	Extraction ponctuelle, sans historique. Ni saisonnalité ni tendance ne peuvent être captées.	Piste d'évolution identifiée : historiser les ventes pour ouvrir la prévision de demande
Dépendance à l'assistant d'IA	Risque d'accepter une suggestion erronée sans la détecter.	Relecture et exécution systématiques, confrontation au résultat attendu, journal des essais ; ma relecture des essais C et D est en cours
Colonnes d'avis à zéro	Les avis sont désactivés sur le site : la note moyenne et le nombre d'avis valent zéro pour les 714 produits. Le modèle ne peut rien dire des avis.	Constat écrit tel quel, commentaire de l'étape 5 du notebook corrigé, ouverture des avis recommandée (section 10)

8. Procédure de documentation

L'un des objectifs du projet est de formaliser les procédures de documentation pour assurer une gestion fiable. Les règles des sections 8.1, 8.3, 8.4 et 8.5 ont été appliquées à ce projet. Celles de la section 8.2 sont celles que je retiens pour un projet suivant. Ici, les versions ont été tenues par des fichiers datés, un historique en tête de chaque document et une sauvegarde avant chaque remplacement (gestion de projet, section 5).

8.1 Règles de nommage

Objet	Règle	Exemple
Livrable déposé	Nom, prénom, numéro du livrable, nature, mois et année de démarrage du projet	Lippens_Charles_2_documentation_09 2026
Dossier de dépôt	Titre du projet, nom, prénom	Pilotez_un_projet_data_augmente_av ec_I_IA_et_creez_votre_portfolio_de_ professionnel_Lippens_Charles
Figure exportée	Préfixe fig, puis le sujet en minuscules sans accent	fig_performance.png
Version de document	Numéro majeur pour un changement de contenu, mineur pour une correction	Version 2.0 après audit, version 2.1 après correction typographique

8.2 Règles de versionnage

- Un enregistrement de version par tâche terminée, jamais par journée de travail.
- Un message de version qui décrit le résultat obtenu, pas l'action effectuée.
- Une branche par axe d'amélioration, fusionnée après validation du jalon correspondant.
- Une étiquette de version à chaque jalon, ce qui permet de revenir à un état validé.
- Les données sources ne sont jamais versionnées avec le code, seul leur emplacement l'est.

8.3 Règles de journalisation des essais

Tout essai, retenu ou écarté, est consigné avec cinq informations.

Information	Pourquoi elle est indispensable
La demande adressée à l'assistant, résumée	Sans elle, impossible de savoir si le résultat répond à la bonne question
Les variantes comparées	C'est la preuve qu'un choix a eu lieu, et non une adoption par défaut
Le résultat mesuré, chiffré	Distingue une décision fondée d'une préférence
La décision et son motif	Permet à un tiers de contester le raisonnement, pas seulement le résultat
La vérification humaine effectuée	Prouve qu'aucune sortie n'a été acceptée sans contrôle

Depuis le 17 septembre 2026, deux informations s'ajoutent aux cinq précédentes, pour répondre à la lettre de l'étape 4 de l'énoncé. Ce sont le message tel qu'envoyé à l'assistant, copié depuis l'application, et l'identifiant du modèle affiché au moment de l'essai, avec la date. Les essais menés avant cette date sont documentés en annexe A avec le degré de fidélité de chaque élément.

8.4 Règles de rédaction des livrables

- Chaque document commence par sa page d'identification : auteur, objet, périmètre, date, version.
- Chaque document comporte un sommaire actualisable et une pagination.
- Un même objet porte toujours le même nom dans tout le dossier. Un glossaire tranche les synonymes.
- Tout chiffre publié est rattaché à sa source de calcul, ce qui permet de le recalculer.
- Tout terme technique est défini à sa première occurrence, ou renvoyé au glossaire.
- Les limites sont énoncées dans le corps du document, jamais reléguées en annexe.

8.5 Contrôle avant dépôt

Liste de vérification appliquée avant toute remise, dérivée de l'audit de conformité.

Point à vérifier	Comment le vérifier
Le notebook s'exécute de bout en bout sur un poste vierge	Réexécution complète à partir des seuls fichiers sources
Les chiffres publiés correspondent aux sorties du code	Extraction automatique des nombres cités et confrontation aux sorties
Aucun chemin absolu ni référence à un environnement temporaire ne subsiste	Recherche des motifs de chemin dans les cellules de code
Les sommaires sont actualisables et la pagination est présente	Ouverture de chaque document et actualisation des champs
La terminologie est stable d'un document à l'autre	Contrôle croisé des termes clés sur l'ensemble du dossier
Les livrables respectent la convention de nommage	Comparaison des noms de fichiers à la règle de la section 8.1

9. Posture de conseil adoptée

L'énoncé demande une posture de consultant. Elle se voit dans des choix concrets, parfois contraires à ce qu'attend le commanditaire.

9.1 Ce que le positionnement change concrètement

Situation	Réflexe d'exécutant	Posture de conseil retenue
Le commanditaire attend une amélioration sur chaque axe	Trouver quelque chose à améliorer partout, pour montrer du travail	Recommander de ne rien changer sur l'axe performance, en documentant à quelle condition il faudra basculer
Un outil récent est disponible et bien noté	L'adopter parce qu'il est moderne	Le comparer sur sept critères et l'écarter s'il ne bat pas l'existant sur le besoin réel
Le modèle donne un résultat flatteur	Le présenter comme un acquis	Le présenter avec sa réserve d'interprétation et la taille de l'échantillon
Une anomalie est détectée	Corriger la donnée	Signaler, expliquer, et laisser la décision de correction au métier qui en porte la responsabilité
Les utilisateurs ne comprennent pas la restitution	Renvoyer à la documentation technique	Construire un guide en langage métier et une mise en situation de vérification

9.2 Limites du mandat, énoncées au commanditaire

- Le projet livre une preuve de concept. Passer à l'exploitation courante demande un travail d'industrialisation qui n'est pas dans le périmètre.

- Les seuils de détection sont des propositions : ils doivent être arbitrés avec le service achats après une première campagne d'usage.
- L'analyse porte sur une extraction datée. Toute décision structurelle devrait s'appuyer sur plusieurs périodes, ce qui suppose d'historiser les ventes au préalable.

9.3 Accompagnement des équipes

Après la remise, je prends trois engagements.

Engagement	Modalité
Rendre les utilisateurs autonomes sur la lecture des résultats	Quatre séquences de formation courtes, un guide de prise en main en langage métier, un glossaire de douze termes
Permettre à un autre analyste de reprendre le travail	Procédure de documentation écrite, journal des essais, environnement figé
Rester disponible sur la période de prise en main	Un référent identifié pour les questions, et une réévaluation des seuils après la première campagne d'usage

10. Synthèse et prochaines étapes

En une phrase. Le notebook du projet 6 contrôle désormais les règles de l'ERP à chaque extraction, justifie son outillage par la mesure, croise deux détections d'anomalies, explique les ventes et se rejoue à l'identique.

Sept pistes prolongent ce travail, chacune rattachée à un besoin identifié.

1. Brancher le contrôle de qualité dans un traitement planifié, avec un rapport adressé automatiquement au service achats après chaque import.
2. Historiser les ventes, ce qui rendra utile le changement de moteur de calcul et ouvrira la prévision de la demande.
3. Étendre l'explication par valeurs de Shapley à un modèle de recommandation de réassort, une fois l'historique disponible.
4. Automatiser la production d'un rapport mensuel destiné à la direction, à partir des indicateurs déjà calculés.
5. Brancher sur l'extraction mensuelle la couverture de stock et le stock immobilisé, que demandait le projet 6. Le calcul existe depuis le 25 septembre (essai C, fonctionnalité F8 du cahier des charges) ; il faudra tenir compte de la saisonnalité dès qu'un historique existe.
6. Enrichir le catalogue avec la liste officielle des appellations publiée par l'INAO sous Licence Ouverte, rapprochée des noms des produits, pour lire les ventes, les marges et le stock par appellation et par région.
7. Ouvrir les avis sur le site, aujourd'hui désactivés, dans le respect des règles sur les avis en ligne, puis suivre la note moyenne dans l'analyse mensuelle.

Annexe A. Journal brut des essais d'IA

Cette annexe complète la section 2. Pour chaque essai, elle donne les cinq informations qui répondent à l'étape 4 de l'énoncé : l'outil et le modèle, la date, la demande adressée à l'assistant, un extrait de la réponse retenue ou écartée, et ce qui a été modifié ou vérifié à la main. Le dossier journal_essais_IA, livré à côté du notebook, en donne la version longue (un fichier par axe, avec les extraits de code complets).

Outil, dates et degré de fidélité. Les essais ont été menés avec Claude (Anthropic), dans l'application Claude de bureau en mode Cowork, qui travaille dans le dossier du projet et exécute le notebook sur le poste. Trois exécutions sont conservées : 26 juin 2026 (première ébauche, fichiers 062026, Python 3.10.12), 31 juillet 2026 (première version complète, 072026) et 4 août 2026 (exécution livrée, Python 3.11.15, versions dans la dernière cellule). Trois réexecutions de contrôle ont suivi : le 25 septembre sur mon poste, le 28 septembre dans un environnement neuf de l'assistant, le 30 septembre sur mon poste dans un environnement neuf (jalon J4, section 6). Les extraits de code, les sorties chiffrées et les commentaires cités sont littéraux, copiés des notebooks conservés avec leur date d'exécution. Les échanges n'ont pas été archivés mot pour mot. Les demandes sont reconstituées à partir des résumés du notebook (cellules « Prompt (résumé) », devenues « Demande à l'assistant (résumé) » le 25 septembre) et de la section 2. L'identifiant du modèle en service à ces dates n'a pas été consigné. Les deux essais complémentaires du 17 septembre 2026 (Local Outlier Factor, importances globales) sont entièrement littéraux : demande, code, sorties, date et modèle (claude-fable-5-1), dans le notebook Lippens_Charles_1_essais_complementaires_092026.ipynb, livré à côté du notebook amélioré. Le notebook amélioré garde le code exécuté et les sorties du 4 août 2026. Son texte a changé le 24 septembre (étape 5 : avis clients, lien entre stock et ventes), puis les 25 et 28 septembre, pour la clarté. Le 28 septembre, des commentaires ont été ajoutés au code, sans réexécution. Le projet a deux phases. D'abord la préparation, de juin à août 2026 : faisabilité, premiers essais, première version complète. Puis le mentorat, du 14 septembre à la soutenance de la semaine du 12 octobre : les trois versions arbitrées en séance et les essais complémentaires.

A.1 Axe 1, qualité des données

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
1.1 Reproduire l'existant, 26 juin 2026	Reproduire les neuf contrôles écrits à la main dans le projet 6 sous la forme d'un tableau de comptage, pour objectiver le besoin (reconstituée)	Dictionnaire de neuf comptages pandas : prix négatifs, stocks négatifs, prix d'achat supérieur au prix de vente, lignes attachment, SKU manquants ou en doublon, ventes négatives, id_web manquants, formats non standard	3, 2, 7, 714, 2, 1, 2, 91 et 3 occurrences ; diagnostic « jetable », non rejouable, sans rapport	Le comptage des formats non standard est saisi en dur (3), repris de l'audit manuel du projet 6
1.2 Contrat Pandera, 26 juin, corrigé le 31 juillet 2026	Transformer ces neuf contrôles en un schéma typé et réutilisable qui produise un rapport des lignes en infraction sans corriger ; comparer Pandera et Great Expectations (reconstituée, résumé conservé dans le notebook)	DataFrameSchema de six colonnes typées avec contrôles de bornes, unicité et appartenance, plus un contrôle de marge sur l'ensemble du tableau, nommé contrat_qualite_erp, validation en mode lazy	26 juin : rapport brut de 42 cas pour la marge négative ; 4 août : « 9 lignes en infraction sur 825 lignes ERP (1,1 %) », dont 7 marges négatives, 3 prix et 2 stocks	Confrontation ligne à ligne avec l'audit manuel ; rapport réécrit le 31 juillet pour compter les lignes uniques (sept lignes sur six colonnes donnaient 42 cas)

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
1.3 Great Expectations, écarté	Même demande, volet comparaison	Commentaire de la version du 4 août, réécrit le 25 septembre : « très complet (data docs, store) mais lourd ; Pandera est léger, typé, tient en 14 lignes »	Aucune cellule conservée : comparaison sur la documentation officielle et le poids de mise en œuvre	Motif d'écart reporté dans la veille (3.1) : gardé en réserve pour un pipeline avec gouvernance

A.2 Axe 2, performance et reproductibilité

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
2.1 Trois moteurs à la volumétrie réelle, 26 juin 2026	Réécrire la jointure et l'agrégation dans Polars et DuckDB en gardant pandas, vérifier l'égalité des résultats, comparer en temps médian sur plusieurs exécutions (reconstituée)	Trois fonctions pipe_pandas, pipe_polars, pipe_duckdb et une mesure bench sur sept exécutions, temps médian en millisecondes	825 lignes : 26 juin 5,27 / 1,59 / 22,11 ms ; 31 juillet 9,65 / 4,10 / 39,07 ms ; 4 août 9,94 / 2,53 / 32,33 ms ; 25 septembre, mon poste, 4,70 / 2,07 / 26,66 ms (pandas, Polars, DuckDB). Autres mesures dans le journal	Résultats de chaque moteur comparés au résultat pandas avant toute mesure ; lenteur de DuckDB notée comme effet d'initialisation
2.2 Montée en charge, 26 juin, rejoué le 31 juillet et le 4 août 2026	Rejouer la comparaison sur deux millions de ventes et cinquante mille produits générés avec une graine fixe, en facteur par rapport à pandas (reconstituée)	Jeu synthétique numpy default_rng(SEED), NPROD 50 000, NSALES 2 000 000, mêmes trois implémentations, médiane de cinq exécutions	Facteurs Polars et DuckDB : 5,9 et 3,7 (26 juin), 3,5 et 2,9 (31 juillet), 4,1 et 2,9 (4 août, livrée), 8,1 et 5,7 (25 septembre, mon poste). Mesures du 28 septembre dans le journal (fichier 02)	Conclusion réécrite le 31 juillet pour ne publier qu'un ordre de grandeur ; depuis le 28 septembre, le dossier cite des facteurs datés (4 août et 25 septembre)
2.3 Reproductibilité, 31 juillet et 4 août 2026	Faire tourner le notebook de bout en bout sur un poste vierge : graine, chemins relatifs avec message clair, versions affichées (reconstituée)	SEED = 42 partout, recherche du dossier de données parmi quatre emplacements avec assertion explicite, cellule finale listant les versions	Résultats métier identiques aux trois dates, puis le 25 septembre sur mon poste (autres versions), le 28 septembre chez l'assistant et le 30 septembre sur mon poste, chaque fois dans un environnement neuf (versions du requirements.txt). Versions du 4 août : pandas 3.0.2, scikit-learn 1.8.0, pandera 0.32.1, polars 1.43.2, duckdb 1.5.5, shap 0.51.0	requirements.txt et README ajoutés le 17 septembre dans le dossier de dépôt ; installation vérifiée dans un environnement neuf le 28 septembre par l'assistant, puis le 30 septembre sur mon poste

A.3 Axe 3, détection d'anomalies

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
3.1 Méthode existante, 26 juin 2026	Reprendre la détection par écart type sur le prix du projet 6 et compter ses anomalies sur le périmètre rapproché (reconstituée)	Score z sur le prix, seuil de 3 en valeur absolue	13 anomalies (prix moyen 32,33 euros, écart type 27,60)	Limite écrite à la main : méthode univariée, aveugle aux combinaisons suspectes
3.2 Isolation Forest, 26 juin 2026	Proposer une détection sur cinq variables à la fois, peu de réglages, graine fixée, comparer à l'existant et montrer les cas qu'elle seule détecte, sans correction automatique (reconstituée, résumé conservé)	IsolationForest(contaminati on=0.05, n_estimators=200, random_state=SEED) sur prix, prix d'achat, stock, ventes, taux de marge	36 anomalies contre 13, 10 communes, 26 supplémentaires ; cas le plus parlant : une référence affichée à 12,65 euros pour 77,48 euros d'achat, sans vente en octobre	26 références inspectées une à une ; taux d'anomalies noté comme réglage à valider avec le métier ; figure relue
3.3 Local Outlier Factor, juin 2026 puis 17 septembre 2026	Juin : évaluer une méthode de voisinage local (reconstituée). 17 septembre : recommandation A8 de l'audit, littérale : « une note d'essai pour Local Outlier Factor »	Juin : commentaire de la version du 4 août, réécrit le 25 septembre, « sensible au paramètre de voisinage et moins stable ici ». 17 septembre : LocalOutlierFactor sur les mêmes variables standardisées, 5 à 50 voisins, indice de Jaccard entre réglages	17 septembre : 36 anomalies à chaque réglage, mais 11 à 22 communes avec Isolation Forest et un Jaccard de 0,41 entre 20 et 35 voisins. Isolation Forest garde un indice de Jaccard de 0,80 à 0,85 (32 à 33 références communes sur 36) quand seule la graine change	Critère de stabilité choisi à la main ; écart de juin confirmé et rendu rejouable dans le notebook complémentaire

A.4 Axe 4, interprétabilité et documentation

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
4.1 Modéliser le volume de ventes, 26 juin 2026	Modéliser le volume de ventes avec un modèle léger, 75 % pour l'apprentissage, 25 % pour le test, graine fixée, pouvoir explicatif et erreur en unités (reconstituée)	GradientBoostingRegressor (n_estimators=300, max_depth=3, learning_rate=0.05, random_state=SEED) sur sept variables	R ² de 0,724 et erreur absolue moyenne de 1,54 unité sur le jeu de test, identiques à chaque exécution, dont celles des 25, 28 et 30 septembre	Modèle gardé peu profond ; résultat rapporté aux critères du cahier des charges (0,60 et 3 unités)
4.2 Valeurs de Shapley, 26 juin 2026	Expliquer les facteurs globalement et référence par référence avec l'explicateur dédié aux arbres, figure lisible par un non-technicien (reconstituée)	shap.TreeExplainer(gb), shap_values sur le jeu de test, summary_plot	Stock disponible premier facteur, devant le prix d'achat et le taux de marge ; notes et avis à zéro, faute d'avis sur le site (lecture corrigée le 24 septembre 2026)	Risque de lecture causale relevé et traité en section 7 ; recommandation de réassort écrite à la main

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
4.3 Importance s globales, juin 2026 puis 17 septembre 2026	Juin : comparer les importances globales aux valeurs de Shapley (reconstituée). 17 septembre : demande littérale, issue de l'audit des attendus : « une cellule d'importances globales face aux valeurs de Shapley »	17 septembre : feature_importances_, permutation_importance sur le test (20 répétitions) et moyenne des valeurs de Shapley absolues, côte à côte, puis un cas individuel	Même classement pour les trois lectures (stock 0,68 / 0,63 / 0,56 ; prix d'achat ; taux de marge ; prix ; avis et nombre d'avis à zéro). Pour le produit 4220 (ligne 135 de la table, dans le jeu de test), Shapley attribue +5,75 unités au stock et +2,32 au prix d'achat	Importance par permutation ajoutée à la main ; écart de juin confirmé : les importances hiérarchisent, elles n'expliquent pas une référence
4.4 Stabilité et référence naïve, 25 septembre 2026	Extrait littéral, Claude (modèle claudé-opus-5-5), 25 septembre 2026 : « ce serait bien de fix les partiel et manquants pour avoir en complet » ; points visés : stabilité selon la partition, comparaison à une prédiction naïve	KFold(n_splits=5, shuffle=True, random_state=SEED) et cross_validate sur le même modèle ; moyenne du jeu d'apprentissage comme référence naïve	R ² par pli : 0,76 ; 0,68 ; 0,53 ; 0,73 ; 0,64 (moyenne 0,67) ; erreur de 1,54 unité contre 3,46 sur le jeu de test (1,51 contre 3,26 sur les cinq plis) ; stock premier sur les cinq plis	Chiffres recalculés par l'assistant dans un script séparé ; ma relecture est en cours

A.5 Besoin 2, les chiffres du réassort

L'essai C ne compare pas deux outils : il calcule ce que la synthèse du notebook cite sans cellule de calcul, et ce qui manquait pour décider du réassort. Fichier long : 05_Reassort_essai_C.md.

Essai	Demande adressée à l'assistant	Réponse retenue ou écartée (extrait)	Résultat mesuré	Modifié ou vérifié à la main
C, 25 septembre 2026	Même extrait littéral que l'essai 4.4 ; points visés : marge et ruptures sans cellule de calcul, décision de réassort à outiller	Références qui font 80 % du chiffre d'affaires croisées avec le stock ; couverture = stock / ventes d'octobre, hors lignes qui ne respectent pas le contrat	Marge 47,4 % (médiane 48,3 %), 45 ruptures ; 14 références clés à stock nul (5 434 euros) et une à stock négatif ; 24 références à plus d'un an de stock, 95 012 euros	Chiffres recalculés par l'assistant dans un script séparé, concordants avec le test du 24 septembre ; ma relecture est en cours