

Veille métier et technologique

Outils d'IA et méthodes d'analyse pour augmenter le projet BottleNeck

Auteur : Charles Lippens, Data Analyst

Projet : Pilotez un projet data augmenté avec l'IA

Base de travail : Notebook du projet 6, optimisation des données BottleNeck

Date : Septembre 2026, dépôt du projet (première version en juillet 2026)

Version : 2.7, matrice des options sur les sept critères (3.5), cas d'usage et prérequis (3.6), sources vérifiées et cliquables (4), veille métier (4.2), besoin servi par chaque axe (6), puis relecture finale (datation des sources, essais C et D à relire), le 25 septembre 2026, et mise à jour du 28 septembre 2026 (performance datée, traçabilité, figures redessinées, texte allégé) ; 2.6, facteurs de performance et accès aux fichiers décrits exactement, le 25 septembre 2026 ; 2.5, transmission des données décrite exactement, le 25 septembre 2026 ; 2.4, piste sur les sources ouvertes ajoutée en 6.1, le 24 septembre 2026 ; 2.3, dispositif de veille installé et capturé (annexe A), le 17 septembre 2026 ; 2.2, sources nommées avec leur adresse, dispositifs d'automatisation nommés ; 2.1, corrigée après les deux passages d'audit

Sommaire

1. Le besoin de veille.....	3
1.1 Les quatre axes qui en découlent.....	3
2. Méthodologie et système de veille.....	3
2.1 Les sept critères d'évaluation.....	3
2.2 Sources et automatisation.....	4
3. Cartographie des solutions, axe par axe.....	4
3.1 Axe 1, qualité des données.....	5
3.2 Axe 2, performance et reproductibilité.....	5
3.3 Axe 3, détection d'anomalies.....	6
3.4 Axe 4, interprétabilité et documentation assistée.....	7
3.5 La matrice des options sur les sept critères.....	7
3.6 Cas d'usage et prérequis de chaque solution.....	9
4. Sources fiables, datées et hiérarchisées.....	9
4.1 Développement durable et sobriété.....	11
4.2 Veille métier : le marché du vin et la vente en ligne.....	11
5. Sécurité, conformité et usage responsable de l'IA.....	12
6. Synthèse et amélioration continue.....	12
6.1 Pistes d'amélioration continue.....	13
Annexe A. Le dispositif de veille en fonctionnement.....	14

1. Le besoin de veille

Le notebook du projet 6 nettoie et analyse les données de BottleNeck, une boutique de vins. Il rapproche l'ERP et le site de vente en ligne, détecte des anomalies et calcule le chiffre d'affaires. Il fonctionne, mais il reste un travail d'exercice. Les contrôles de qualité sont écrits à la main. Un seul outil de calcul est utilisé, sans que ce choix ait été questionné. La détection d'anomalies ne regarde qu'une variable à la fois. Et rien n'explique ce qui fait vendre une référence plutôt qu'une autre.

J'ai défini le besoin avant de chercher : ces quatre limites deviennent une seule question, qui structure le document.

Question de veille. Quelles technologies, solutions logicielles et méthodes d'analyse récentes permettraient de fiabiliser, d'accélérer et de rendre plus interprétable ce livrable, tout en restant sobres et conformes ?

1.1 Les quatre axes qui en découlent

Axe	Limite constatée sur le notebook du projet 6	Ce que la veille doit trouver
Axe 1, qualité des données	Neuf contrôles écrits à la main, dispersés, non rejouables et sans rapport d'anomalies	Un moyen de déclarer les règles une fois et de les rejouer à chaque extraction
Axe 2, performance et reproductibilité	Un seul moteur de calcul, choisi par défaut, sans visibilité sur la montée en charge	Des alternatives mesurables et le seuil à partir duquel elles deviennent utiles
Axe 3, détection d'anomalies	Un écart type calculé sur le seul prix, qui ignore les anomalies croisées	Une méthode capable de regarder plusieurs variables en même temps
Axe 4, interprétabilité et documentation	L'analyse décrit les ventes mais n'explique aucun facteur	Une méthode d'explication auditable, et un usage encadré des assistants d'IA

Je n'essaie pas un outil parce qu'il est nouveau. Je choisis, je mesure et je justifie, à partir du besoin. Garder l'existant est une conclusion possible.

2. Méthodologie et système de veille

La veille suit un cycle court : repérer les sources, collecter automatiquement, trier selon des critères fixés à l'avance, garder la trace dans un tableau comparatif, décider, puis réévaluer.

2.1 Les sept critères d'évaluation

Les critères sont les mêmes d'un axe à l'autre, pour comparer à armes égales. Ce sont les six critères de l'énoncé et l'indicateur de développement durable. Ils n'ont pas changé depuis la première version.

Critère	Ce qu'il mesure	Comment il est apprécié
Qualité et robustesse	Fiabilité du résultat, comportement sur les cas limites	Test sur le jeu réel, y compris sur les lignes fautives
Biais	Risque de fausser ou de discriminer l'analyse	Analyse des hypothèses de la méthode et de sa sensibilité aux réglages
Coût en temps	Temps d'exécution et temps d'apprentissage	Mesure chronométrée et estimation de la prise en main

Critère	Ce qu'il mesure	Comment il est apprécié
Reproductibilité	Capacité à rejouer à l'identique	Versions figées, graine aléatoire, absence de dépendance à l'environnement
Sécurité et conformité	Protection des données, RGPD, absence de fuite	Nature des données transmises à un service tiers
Maintenabilité	Lisibilité, intégration, dette technique induite	Nombre de lignes, dépendances ajoutées, lisibilité pour un tiers
Sobriété et impact	Empreinte mémoire et calcul, proportion au besoin	Consommation observée et utilité réelle à la volumétrie actuelle

2.2 Sources et automatisation

Quatre dispositifs collectent sans que j'aie à chercher chaque jour. Un lecteur de flux, Feedly, qui regroupe les blogs de Polars et de DuckDB et les notes de version de pandas, pandera, polars, duckdb, scikit-learn et shap. Trois lettres d'information : Data Elixir et Python Weekly chaque semaine, TLDR Data deux fois par semaine. Le suivi des publications de versions sur GitHub pour pandera, polars, duckdb et shap. Deux alertes Google Scholar, sur la validation de données et sur l'interprétabilité des modèles. C'est l'élément d'automatisation demandé par la grille.

Dispositif	Contenu suivi	Fréquence
Lecteur de flux RSS agrégés	Blogs officiels de Polars et de DuckDB, notes de version des six bibliothèques suivies	Consultation quotidienne, dix minutes
Lettres d'information spécialisées	Tendances de l'outillage data et retours d'expérience	Réception une ou deux fois par semaine, tri par thème
Suivi des publications de versions sur GitHub	Nouvelles versions des dépôts des bibliothèques retenues et de leurs concurrentes	Notification à chaque publication
Alertes Google Scholar sur mots-clés méthodologiques	Publications sur la validation de données et l'interprétabilité des modèles	Notification hebdomadaire

Un choix sur l'automatisation. J'automatise surtout la collecte de sources déjà évaluées. Des alertes larges produiraient du volume et un long tri : les deux alertes Google Scholar se limitent donc à deux requêtes précises.

Le dispositif est installé et fonctionne : un dossier « Veille data, projet 13 » dans Feedly, avec huit flux ; le suivi des versions activé sur les quatre dépôts GitHub ; deux alertes Google Scholar hebdomadaires. Les captures du 17 septembre 2026 sont en annexe A.

3. Cartographie des solutions, axe par axe

Chaque axe compare au moins deux options. Le détail des essais est dans la documentation de la démarche ; ici, la synthèse et la décision.

3.1 Axe 1, qualité des données

Solution	Type	Forces	Limites	Décision
Contrôles écrits à la main	Existant	Aucune dépendance ajoutée	Environ 55 lignes pour neuf contrôles, non réutilisables, sans rapport d'anomalies	Écartée
Pandera	Bibliothèque	Schéma typé de 14 lignes, rapport automatique, contrat versionnable	Moins de gouvernance qu'un cadre complet	Retenue
Great Expectations	Cadre complet	Documentation générée, entrepôt de résultats, gouvernance	Installation et configuration lourdes pour un notebook	Gardée en réserve

Justification. Pour un seul notebook, Pandera apporte le plus pour le moins de complexité : un contrat de qualité versionné, rejoué à chaque extraction de l'ERP, avec son propre rapport. Great Expectations se justifierait dans une chaîne industrielle, où la gouvernance et la documentation générée paient son installation : je le garde en réserve pour ce cas.

Les neuf types d'anomalies relevés à l'audit initial




Figure 1. Les neuf types d'anomalies relevés lors de l'audit initial des trois fichiers sources. Figure redessinée à partir des sorties du notebook (mêmes données).


3.2 Axe 2, performance et reproductibilité

Solution	Forces	Limites	Décision
pandas	Standard du marché, écosystème riche, lisible par tout analyste	Traitement sur un seul cœur, consommation mémoire élevée	Retenue à la volumétrie actuelle
Polars	Traitement multicœur, évaluation différée, sobriété mémoire	Interface différente, temps d'apprentissage	Retenue en réserve, si montée en charge
DuckDB	SQL analytique, traitement hors mémoire, lecture directe de fichiers	Temps d'initialisation pénalisant sur les petits volumes	Retenue en réserve, si gros fichiers

Justification. Au volume réel, 825 lignes, les trois moteurs répondent en moins de 40 millisecondes : l'écart ne change rien, et DuckDB est même le plus lent, à cause de son démarrage. À deux millions de lignes, Polars

et DuckDB sont 4,1 fois et 2,9 fois plus rapides que pandas le 4 août (exécution livrée) ; 8,1 et 5,7 fois sur mon poste le 25 septembre. Le gain dépend de la machine ; la décision ne change pas.

Précision méthodologique. Ce facteur dépend du matériel : 5,9 et 3,7 le 26 juin, 3,5 et 2,9 le 31 juillet, 4,1 et 2,9 le 4 août (exécution livrée), 8,1 et 5,7 le 25 septembre sur mon poste. L'ordre de grandeur suffit pour décider : ne pas suréquiper aujourd'hui, basculer quand le volume le justifiera.



Temps médians de l'exécution livrée du 4 août 2026 ; le gain dépend de la machine.

Figure 2. Temps médian des trois moteurs au volume réel, puis sur deux millions de lignes (exécution livrée du 4 août 2026). Figure redessinée à partir des sorties du notebook (mêmes données).

3.3 Axe 3, détection d'anomalies

Solution	Forces	Limites	Décision
Score z sur le prix (écart type)	Simple, explicable au métier en une phrase	Ne regarde qu'une variable, rate les anomalies croisées	Conservée
Isolation Forest	Regarde plusieurs variables ensemble, stable, rapide, peu de réglages	Le taux d'anomalies attendu est un réglage à valider avec le métier	Ajoutée
Local Outlier Factor	Détecte les anomalies relatives au voisinage local	Très sensible au paramètre de voisinage, résultat instable sur ce jeu	Écartée

Justification. Je garde le score z pour sa transparence : un acheteur voit tout de suite pourquoi une référence est signalée. Isolation Forest voit ce qu'il ne voit pas, par exemple un prix normal avec une marge négative. J'écarte Local Outlier Factor : sa liste change avec le réglage du voisinage.




Figure 3. À gauche, la détection sur le seul prix. À droite, la détection multivariée, qui signale 26 références supplémentaires. Figure redessinée à partir des sorties du notebook (mêmes données).

3.4 Axe 4, interprétabilité et documentation assistée

Solution	Forces	Limites	Décision
Importances globales d'un modèle d'arbres	Simple, disponible sans dépendance supplémentaire	Uniquement globales, parfois trompeuses sur des variables corrélées	Jugée insuffisante
SHAP	Explication locale et globale, fondement théorique établi, résultat auditable	Coût de calcul sur de gros volumes	Retenue
Assistants d'IA générative (Claude, ChatGPT)	Génération de variantes, rédaction de documentation, proposition de tests	Sorties à relire et à exécuter, risque de fuite de données	Retenus, sous conditions

Justification. SHAP donne deux lectures : globale (le facteur qui pèse le plus) et locale (pourquoi cette référence). Le métier peut donc discuter chaque résultat. Les assistants d'IA m'aident pour le code et la documentation, à deux conditions : relire et exécuter chaque proposition ; limiter les demandes au code, aux schémas et aux noms de colonnes. Chaque accès de l'assistant aux fichiers est noté au journal (section 5).




Figure 4. Contribution de chaque variable au volume de ventes, référence par référence (valeurs de Shapley ; couleur : valeur de la variable, de faible à élevée). Figure redessinée à partir des sorties du notebook (mêmes données).

3.5 La matrice des options sur les sept critères

Pour chaque axe, les options sont comparées critère par critère, avec la mesure quand elle existe (notebook amélioré, exécution du 4 août 2026, et notebook complémentaire). La dernière ligne rappelle la décision ; le critère qui a tranché figure en section 6 de ce document.

Axe 1, qualité des données

Critère	Contrôles écrits à la main	Pandera	Great Expectations
Qualité et robustesse	Des comptes par type, sans la liste des lignes en faute	Les 9 lignes en faute sur 825, règle par règle	Même couverture possible ; non exécuté ici
Biais	Règles métier explicites	Règles métier explicites	Règles métier explicites
Coût en temps	Aucun apprentissage, relecture longue	Une cellule, prise en main courte	Mise en place longue : contexte, suites d'attentes, points de contrôle
Reproductibilité	Se relance, résultats dispersés	Contrat versionné, rejoué à chaque extraction	Historique des validations
Sécurité et conformité	Exécution locale	Exécution locale	Exécution locale

Critère	Contrôles écrits à la main	Pandera	Great Expectations
Maintenabilité	Environ 55 lignes pour neuf contrôles	14 lignes pour les règles de l'ERP	Configuration lourde, 18 dépendances directes
Sobriété et impact	Aucune dépendance	Une bibliothèque légère	Un cadre complet, surdimensionné pour un notebook
Décision	Écartés	Retenu	En réserve

Axe 2, performance et reproductibilité

Critère	pandas	Polars	DuckDB
Qualité et robustesse	Résultats identiques, vérifiés avant la mesure	Identiques	Identiques
Biais	Sans objet	Sans objet	Sans objet
Coût en temps (mesuré)	9,9 ms au volume réel ; 240 ms à deux millions de ventes	2,5 ms ; 59 ms, soit 4,1 fois plus rapide (8,1 fois sur mon poste le 25 septembre)	32,3 ms ; 82 ms, soit 2,9 fois plus rapide (5,7 fois sur mon poste)
Reproductibilité	Versions figées	Versions à figer : Polars 2.0 change des comportements par défaut	Versions figées ; version 1.4 maintenue à long terme
Sécurité et conformité	Exécution locale	Exécution locale	Exécution locale
Maintenabilité	Connu de tout analyste	Autre syntaxe : expressions, exécution différée	SQL, lisible par un profil BI
Sobriété et impact	Aucune dépendance ajoutée	Utile seulement à gros volume	Démarrage coûteux sur un petit volume
Décision	Gardé	En réserve	En réserve

Axe 3, détection d'anomalies

Critère	Score z sur le prix	Isolation Forest	Local Outlier Factor
Qualité et robustesse	13 alertes, sur le prix seul	36 alertes, dont 26 que le score z ne voit pas	36 alertes, dont 11 à 22 en commun avec Isolation Forest selon le réglage
Biais	Rate les anomalies croisées	Nombre d'alertes fixé d'avance (5 %) : des faux positifs à attendre	Dépend du nombre de voisins et de la mise à l'échelle
Coût en temps	Instantané à 714 produits	Moins d'une seconde	Moins d'une seconde
Reproductibilité	Déterministe	Graine fixée ; indice de 0,80 à 0,85 si elle change	Liste qui change avec le réglage : indice de 0,41 à 1
Sécurité et conformité	Exécution locale	Exécution locale	Exécution locale
Maintenabilité	Une ligne, explicable en une phrase	Deux réglages : taux d'alertes, nombre d'arbres	Standardisation et choix du voisinage
Sobriété et impact	Aucun modèle	200 arbres, léger	Léger
Décision	Gardé	Ajouté	Écarté

Axe 4, interprétabilité et documentation

Critère	Importances du modèle	Valeurs de Shapley (SHAP)	Assistants d'IA (Claude, ChatGPT)
Qualité et robustesse	Même classement que SHAP : stock, prix d'achat, marge, prix	Même classement, plus l'explication référence par référence	Utiles pour les variantes de code et la rédaction ; chaque sortie est relue et exécutée
Biais	Favorise les variables continues	Risque de lecture causale (le stock)	Peuvent se tromper avec assurance : relecture obligatoire
Coût en temps	Immédiat	Rapide à 714 produits, coûteux à gros volume	Gain de temps sur le code et la documentation
Reproductibilité	Déterministe, graine fixée	Déterministe avec l'explicateur d'arbres	Réponses non reproductibles, d'où le journal des essais

Critère	Importances du modèle	Valeurs de Shapley (SHAP)	Assistants d'IA (Claude, ChatGPT)
Sécurité et conformité	Exécution locale	Exécution locale	Service tiers : demandes sur le code et les schémas, accès aux fichiers notés au journal
Maintenabilité	Aucune dépendance	Une dépendance, shap	Un compte et des règles d'usage à tenir
Sobriété et impact	Aucun calcul en plus	Calcul modéré	Appels limités à des questions ciblées
Décision	Insuffisant seul	Retenu	Retenus, sous conditions

3.6 Cas d'usage et prérequis de chaque solution

Ce qu'il faut pour mettre chaque solution en œuvre chez BottleNeck. Les versions ont été vérifiées sur les pages officielles le 25 septembre 2026. Le notebook reste sur ses versions figées du 4 août (requirements.txt) ; sur mon poste, avec d'autres versions, il redonne les mêmes chiffres métier (25 septembre).

Solution	Cas d'usage chez BottleNeck	Prérequis	Version du notebook ; dernière version
Pandera	Contrôler chaque extraction de l'ERP	Python 3.10 ou plus ; pip install 'pandera[pandas]'; savoir écrire un schéma et lire le rapport d'erreurs	0.32.1 ; 0.33.1 du 1er septembre 2026
Great Expectations	Contrôles quotidiens en production, avec historique	Python 3.10 à 3.13, environnement virtuel conseillé ; savoir enchaîner contexte, suite d'attentes et point de contrôle	Non installé ; GX Core 1.23.1 du 18 septembre 2026
pandas	Tous les calculs du notebook	Python 3.11 ou plus, NumPy 1.26 ou plus ; jointures et agrégations	3.0.2 ; 3.0.6 du 17 septembre 2026
Polars	Ventes historisées, gros volume	Python 3.10 ou plus, aucune dépendance obligatoire ; expressions et exécution différée	1.43.2 ; 1.44.2 du 9 septembre 2026, version 2.0 annoncée
DuckDB	Gros fichiers, requêtes SQL	Python 3.10 ou plus, aucune dépendance ; savoir écrire du SQL	1.5.5 ; 1.5.5 du 22 juillet 2026
Isolation Forest et Local Outlier Factor (scikit-learn)	Alertes à faire valider par les achats	Python 3.11 ou plus pour la version 1.9 ; fixer la graine, régler le taux d'alertes avec le métier ; pour Local Outlier Factor, standardiser et choisir le voisinage	1.8.0 ; 1.9.1 du 10 septembre 2026
SHAP	Expliquer les ventes d'une référence	Python 3.11 pour la 0.51, 3.12 pour la 0.52 ; un modèle entraîné et l'explicateur d'arbres	0.51.0 ; 0.52.0 du 28 mai 2026
Assistants d'IA (Claude, ChatGPT)	Variante de code, relecture, rédaction	Un compte ; des règles : demandes sur le code et les schémas, relecture et exécution de chaque proposition, journal des essais	Claude en mode Cowork ; ChatGPT

4. Sources fiables, datées et hiérarchisées

Les seize sources ci-dessous sont nommées, datées et cliquables. Dix ont été consultées en mai et juin 2026, deux sont suivies en continu (lettres et dépôts GitHub) et quatre ont été ajoutées le 25 septembre 2026. Toutes ont été vérifiées une à une ce jour-là : lien valide, version ou date constatée. Chacune porte son niveau de fiabilité : documentation officielle, article scientifique, benchmark public, donnée ouverte ou retour d'expérience. Cette hiérarchie évite de fonder une décision sur un billet de blog isolé.

Source	Niveau	Apport pour le projet	Consultée, puis vérifiée	Adresse
Documentation officielle de Pandera	Officielle	Syntaxe des schémas, contrôles portant sur l'ensemble du tableau, rapport d'erreurs	06/2026 ; 25/09/2026, version 0.33.1	pandera.readthedocs.io
Great Expectations, premier essai et installation	Officielle	Étapes de mise en place, pour juger le coût d'installation face à Pandera	06/2026 ; 25/09/2026, GX Core 1.23.1	docs.greatexpectations.io
Documentation de Polars, guide utilisateur	Officielle	Exécution différée, expressions	06/2026 ; 25/09/2026, version 1.44.2	docs.pola.rs
Database-like ops benchmark, maintenu par DuckDB Labs (repris de H2O.ai)	Benchmark public	Ordres de grandeur sur les jointures et agrégations, à confronter à la mesure locale ; DuckDB Labs édite l'un des outils comparés	06/2026 ; 25/09/2026, résultats du 17/08/2026	duckdblabs.github.io/db-benchmark
Documentation de DuckDB	Officielle	Usage analytique embarqué, lecture directe de fichiers	06/2026 ; 25/09/2026, version 1.5	duckdb.org/docs
scikit-learn 1.8, guide Novelty and Outlier Detection, Isolation Forest	Officielle	Principe de l'isolation, réglage du taux d'anomalies attendu	05/2026 ; 25/09/2026, page de la version du notebook	scikit-learn.org/1.8
Même guide, Local Outlier Factor	Officielle	Sensibilité au voisinage (20 voisins par défaut)	05/2026 ; 25/09/2026	scikit-learn.org/1.8
Documentation de SHAP, version stable	Officielle	Valeurs de Shapley, explicateur dédié aux modèles d'arbres	05/2026 ; 25/09/2026, version 0.52.0	shap.readthedocs.io
Lundberg et Lee, A Unified Approach to Interpreting Model Predictions, NIPS 2017	Article scientifique	Fondement théorique de la méthode retenue	05/2026 ; 25/09/2026	arxiv.org/abs/1705.07874
CNIL, « Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative », 18 juillet 2024	Officielle	Règles d'usage des assistants d'IA, données qu'on peut leur confier	25/09/2026	cnil.fr, IA générative
CNIL, page thématique « Intelligence artificielle »	Officielle	Actualités et recommandations sur l'IA et le RGPD	05/2026 ; 25/09/2026	cnil.fr/fr/intelligence-artificielle
Lettres Data Elixir et Python Weekly (chaque semaine), TLDR Data (deux fois par semaine)	Retour d'expérience	Tendances de l'outillage, signaux faibles	En continu ; 25/09/2026	dataelixir.com , pythonweekly.com , tldr.tech/data
Dépôts GitHub de pandera, polars, duckdb et shap	Officielle	Rythme des versions, ruptures annoncées	En continu ; 25/09/2026	pandera , polars , duckdb , shap
Blogs de Polars et de DuckDB	Officielle	Annonces de versions et de fonctions	25/09/2026, billets des 17 et 22 septembre	pola.rs/posts , duckdb.org/news
Notes de version de pandas, scikit-learn et shap	Officielle	Changements à lire avant une mise à jour	25/09/2026, pandas 3.0.6 du 17/09/2026	pandas , scikit-learn , shap

Source	Niveau	Apport pour le projet	Consultée, puis vérifiée	Adresse
INAO, « Aires et produits AOC/AOP et IGP », sur data.gouv.fr	Donnée ouverte	Liste des appellations, pour enrichir le catalogue (section 6.1)	25/09/2026, mise à jour du 09/10/2025	data.gouv.fr

4.1 Développement durable et sobriété

Le critère de sobriété figure dans les quatre comparaisons ; il a pesé sur la décision de garder pandas. J'en tire trois principes.

- **Proportionner l'outillage au besoin.** Ne pas activer un moteur multicœur pour traiter 825 lignes évite une dépendance supplémentaire, un temps d'apprentissage et une consommation sans contrepartie.
- **Privilégier les modèles légers.** Isolation Forest et un modèle d'arbres de faible profondeur suffisent au besoin d'explication. Un modèle plus lourd n'améliorerait pas la décision métier.
- **Limiter les appels aux modèles de langage.** Les assistants d'IA sont sollicités sur des questions ciblées, pas en boucle sur des variantes marginales.

Éviter le suréquipement réduit l'empreinte de calcul et les coûts, et facilite la reprise du travail par un tiers.

4.2 Veille métier : le marché du vin et la vente en ligne

La veille technique dit comment améliorer le notebook ; la veille métier dit dans quel marché BottleNeck vend, et sous quelles règles. Six sources, vérifiées le 25 septembre 2026, suffisent à situer les chiffres du notebook.

Source	Éditeur et date	Ce qu'elle apporte à BottleNeck	Adresse
« State of the World Wine Sector in 2025 »	OIV, mai 2026	Consommation mondiale de 208 millions d'hectolitres en 2025, en baisse de 2,7 % ; France, 22,0 millions, en baisse de 3,2 %. Un marché qui recule : réassort prudent, stock immobilisé à suivre	oiv.int, rapport 2025
« Note de conjoncture mensuelle sur la filière vitivinicole »	FranceAgriMer, note d'août 2026, publiée le 1er septembre 2026	Prix, consommation et échanges chaque mois : le même rythme que l'analyse mensuelle proposée à BottleNeck	franceagrimer.fr
« Aires et produits AOC/AOP et IGP »	INAO sur data.gouv.fr , mise à jour du 9 octobre 2025, Licence Ouverte	Rattacher chaque référence à son appellation, puis lire chiffre d'affaires, marge et stock par appellation	data.gouv.fr
« Le e-commerce progresse de 6,6 % au premier semestre 2026 »	Fevad, 21 septembre 2026	Repères de la vente en ligne : 52,2 milliards d'euros au deuxième trimestre 2026, en hausse de 8,5 % sur un an, panier moyen de 59,7 euros ; aucun chiffre propre au vin	fevad.com
« En matière d'alcool »	MILDECA, mise à jour du 12 septembre 2023	Vente interdite aux mineurs, preuve de majorité exigée ; publicité en ligne permise hors sites destinés à la jeunesse ou au sport, avec le message sanitaire (loi Évin)	drogues.gouv.fr
« E-commerce : les règles entre professionnels et consommateurs »	DGCCRF, 9 octobre 2023	Information avant la commande, droit de rétractation de 14 jours, livraison sous 30 jours au plus tard : le cadre du site marchand	economie.gouv.fr

Ce que cela change pour le projet. Le marché recule en volume : l'enjeu est moins de vendre plus que de mieux répartir le stock, ce qui conforte le besoin retenu (réassort et stock immobilisé, essai C du notebook complémentaire). La liste de l'INAO est la source ouverte la plus utile pour enrichir le catalogue. Les règles sur l'alcool et la vente en ligne encadrent toute ouverture des avis ou toute action commerciale proposée à la direction.

5. Sécurité, conformité et usage responsable de l'IA

Point	Situation sur ce projet	Règle appliquée
Données personnelles	Le jeu de données porte sur des produits, des prix et des stocks, sans aucune donnée à caractère personnel	Le RGPD ne s'applique pas directement, mais la démarche reste conçue avec la protection des données par défaut
Transmission à un service tiers	Les assistants ont été sollicités sur la structure du code. L'assistant de bureau a lu les sorties du notebook qu'il exécutait ; les fichiers, sans donnée personnelle, ont été confiés à son environnement pour des vérifications en septembre	Demandes limitées aux schémas et aux noms de colonnes ; chaque accès aux fichiers est noté au journal des essais
Traçabilité des suggestions	Les essais faits avec Claude sont consignés, retenus ou écartés ; les demandes de juin à août sont reconstituées et signalées comme telles. ChatGPT a servi surtout pour la rédaction, la relecture, la recherche d'idées et le code ; ces échanges n'ont pas été archivés	Journal des essais dans la documentation de la démarche : demande, variantes, résultat, décision
Validation humaine	Chaque sortie d'assistant est exécutée et vérifiée avant d'être intégrée. Exception : les essais C et D du 25 septembre, chiffres recalculés par l'assistant dans un script séparé ; ma relecture est prévue avant la séance 3	Toute proposition est relue, exécutée et confrontée au résultat attendu
Reproductibilité	Versions des bibliothèques listées, graine fixée ; mêmes chiffres métier sur mon poste le 25 septembre et dans un environnement neuf, installé avec le requirements.txt, le 28 septembre	Le notebook publie son environnement d'exécution en dernière étape

6. Synthèse et amélioration continue

La veille débouche sur une feuille de route où chaque décision est rattachée à un besoin et à un critère.

Axe	Besoin métier servi	Décision	Bénéfice mesuré	Critère déterminant
Qualité	Besoin 1, se fier aux chiffres (Nicolas, la direction et les services)	Adopter un contrat de qualité déclaratif	9 lignes de l'ERP en infraction isolées sur 825 ; contrat de 14 lignes, là où les neuf contrôles manuels en demandaient environ 55	Maintenabilité et reproductibilité
Performance	Besoin 4, refaire l'analyse chaque mois	Conserver l'existant, garder deux alternatives en réserve	Aucun gain au volume actuel. À deux millions de lignes : Polars 4,1 fois et DuckDB 2,9 fois plus rapides le 4 août, 8,1 et 5,7 fois sur mon poste le 25 septembre	Sobriété et coût en temps
Anomalies	Besoin 3, repérer les prix et les stocks suspects (service achats, équipe commerce en ligne)	Conserver le score z et ajouter une détection multivariée	26 anomalies supplémentaires, invisibles au score z	Qualité et biais
Interprétabilité	Besoin 2, savoir où agir, et besoin 5, lire les résultats sans être technicien	Adopter une explication par valeurs de Shapley	Stock premier facteur sur les cinq partitions testées ; pouvoir explicatif de 0,53 à 0,76 selon la partition	Qualité de l'explication, locale et globale ; lecture causale à éviter

6.1 Pistes d'amélioration continue

1. Brancher le contrat de qualité en amont d'un traitement planifié, pour qu'il s'exécute à chaque import et non seulement à la demande.
2. Produire automatiquement un rapport de qualité à chaque extraction de l'ERP, adressé au service achats.
3. Réévaluer les moteurs alternatifs lorsque les ventes seront historisées, ce qui multipliera la volumétrie par le nombre de périodes conservées.
4. Étendre l'explication par valeurs de Shapley à un modèle de prévision de la demande, une fois l'historique disponible.
5. Réexaminer le cadre de gouvernance des données le jour où plusieurs boutiques seront intégrées.
6. Évaluer les sources ouvertes qui enrichiraient le catalogue, en commençant par la liste des appellations publiée par l'INAO sous Licence Ouverte, rapprochée des noms des produits.

Les flux, les lettres d'information et les notifications de versions font vivre cette veille après la fin du projet.

Annexe A. Le dispositif de veille en fonctionnement

Les trois captures ci-dessous ont été prises le 17 septembre 2026 sur les comptes utilisés pour le projet. Elles montrent le dispositif décrit en section 2.2 tel qu'il tourne : l'agrégateur de flux, le suivi des versions et les alertes de publications. Les lettres d'information arrivent par courriel et n'appellent pas de capture.




Figure A1. Feedsy, dossier « Veille data, projet 13 » : les huit flux suivis (blogs de DuckDB et de Polars, notes de version de pandera, polars, scikit-learn, shap, duckdb et pandas). Parmi les derniers articles reçus, l'annonce de scikit-learn 1.9.1, reçue le 11 septembre 2026.




Figure A2. GitHub, page « Watching » du compte : les dépôts unionai-oss/pandera, pola-rs/polars, duckdb/duckdb et shap/shap suivis en mode personnalisé, notification à chaque publication de version.




Figure A3. Google Scholar : les deux alertes hebdomadaires, « dataframe validation schema pandas » et « SHAP model interpretability retail sales », créées le 17 septembre 2026.