

Optimisez la gestion des données d'une boutique avec R ou Python



Lippens Charles
Data Analyst
12/2025

Analyses Exploratoires des Données

Datasets :

erp

825 × 6

Product_id →

liaison

825 × 2

Id_web →

web

1513 × 29

Caractéristiques :

ERP : product_id, onsale_web, price, stock_quantity, stock_status, purchase_price | Web : sku, post_title, product_type, total_sales | Liaison : product_id, id_web

Traitement réalisés & Nettoyages des données :

- Incohérence stock_status (4)
- Prix négatifs (3) → supprimés
- Stocks négatifs (2) → mis à 0
- Marge négative ID 4355

- Codification SKU non standard (3)
- Doublons post + image (714)
- Lignes sans SKU (85)

Features engineering :

Conversion types (int → str) pour jointures | CA = price × total_sales | taux_marge = (prix_HT - purchase_price) / prix_HT × 100

Remarques / Difficultés :

Types incompatibles entre fichiers | Distinction produits vs attachments WordPress | Arbitrage amputation vs correction

Fusion ou consolidations des données

Choix des attributs :

ERP : product_id, price, stock_quantity, purchase_price | Web : sku, post_title, product_type, total_sales | Liaison : product_id, id_web
Clés utilisées :



Merge 1 : df_erp + df_liaison on product_id → Merge 2 : résultat + df_web on id_web = sku → 714 produits

Vigilances particulières :

- Conversion types avant jointure : product_id (int → str), id_web (float → str)
- Filtrage Web : post_type = 'product' uniquement (exclure attachments)

Difficultés / Pièges :

- Jointure échouait (0 résultats) sans conversion str
- SKU : 3 formats différents (int, float, alphanumérique)
- 91 produits ERP sans id_web → **suppression**

Récapitulatif des erreurs identifiées

Récapitulatif des erreurs identifiées

#	Type d'erreur	Fichier	Nb	Impact	Action	Solution appliquée
1	Valeurs NaN dans id_web	Liaison	91	Jointure impossible	Supprimées	<code>dropna(subset=['id_web'])</code>
2	Format id_web non standard	Liaison	3	1 produit sans correspondance web	Documentation	SKU 14680-1 inexistant dans web
3	Incohérence stock_status vs stock_quantity	ERP	4	Statut erroné	Correction	Recalcul automatique
4	Prix négatifs	ERP	3	Aucun car pas de correspondance dans web	Supprimés	vérification métier
5	Marge négative (prix_achat > prix)	ERP	4	Marge erronée	Documentation	Signalement au commercial
6	Stock négatif	ERP	2	Valorisation faussée	Correction	<code>stock_quantity = 0</code>
7	Attachments (post_type=attachment)	Web	714	Bruit dans les données	Filtrage	<code>post_type == 'product'</code>
8	Types incompatibles (id_web vs sku)	Liaison/Web	-	Jointure échouée	Conversion	<code>.astype(str)</code>
9	SKU manquants	Web	85	Jointure impossible	Supprimés	<code>dropna(subset=['sku'])</code>

Note sur l'erreur #2 :

- `bon-cadeau-25-euros` et `13127-1` ont des correspondances dans le fichier web et sont inclus dans l'analyse
- Seul `14680-1` n'a pas de correspondance (SKU inexistant dans web.xlsx)

Analyses univariées du prix

Méthodes statistiques employées :

- Analyse univariée : min, max, moyenne, médiane, écart-type, quartiles (Q1, Q3)
- Z-Score : détection des valeurs éloignées de plus de 3 écarts-types → seuil 115€
- IQR (écart interquartile) : seuils $Q1 - 1.5 \times IQR$ et $Q3 + 1.5 \times IQR$ → seuil 84€

Résultats chiffrés (stats + outliers)

Statistiques descriptives

Moyenne : 32,33€ | Médiane : 23,45€
Écart-type : 27,60€ | Min : 5,20€ | Max : 225€
→ *Distribution asymétrique (moyenne > médiane)*

Outliers détectés

Z-Score (seuil 3) : 13 outliers > 115€
IQR : 31 outliers > 84€ (4,35% du catalogue) – Seuil inférieur pour les outliers -28 €
→ *Produits premium : Champagnes, Grands Crus*

Limites de l'analyse :

- Outliers liés à la stratégie de gamme (produits premium) et non à des erreurs
- Période courte (1 mois) : résultats sensibles aux promotions ponctuelles
- 3 prix négatifs supprimés (erreurs de saisie) avant analyse

Analyses univariées du prix

Graphique Boxplot annoté

Distribution des prix (Plotly)

Q1 (14,06) 25 % des données ont une valeur inférieure à ce point

La médiane

Q3 (42,08) 75 % des données ont une valeur inférieure à ce point



La majorité des prix se situe entre 14€ et 42€

Conclusion sur les outliers (produits premium):


- Champagnes prestigieux (Egly-Ouriet, Agrapart)
- Grands Crus (Clos de Vougeot, Volnay 1er Cru)
- Cognacs et Whiskies haut de gamme

On a les prix outliers dépassant le seuil supérieur 83,7 €

Les prix élevés sont-ils des erreurs ou des produits premium ?

Analyses univariées du prix

Graphique histogramme : *Est-ce que ces produits se vendent ?*



Rappel des statistiques descriptives

32,33€

Prix moyen

23,45€

Prix médian

27,60€


Écart-type

225€

Prix max

Analyses complémentaires : Chiffre d'affaires

Répartition du CA par type de produit



CA Total (1- 31 Octobre)

143 680€

TTC - Site web uniquement

5 751


Ventes totales (unités)

24,98€

Prix moyen par article
vendu

Analyses complémentaires : top 20 produits par CA

Top 20 produits par Chiffre d'Affaires



Règle de Pareto 20/80

En CA

63,1%

des articles font **80%** du CA

En Quantité


63%

des articles font **80%** des ventes

Le catalogue est bien équilibré. Pas de dépendance excessive à quelques produits stars.

Analyses complémentaires : top 20 produits par quantité vendue

Top 20 produits par Quantité vendue



Analyses complémentaires : Stock

Stock Total

16 740

bouteilles en stock

Valorisation (prix achat)

277 328€

coût d'achat du stock


45

Produits en rupture

2,9

Mois de stock moyen

Flop 20 - Produits avec le plus de mois de stock



Certains produits premium ont une rotation très lente. À surveiller pour éviter l'immobilisation de capital.

Analyses complémentaires : Marge et taux de marge

Taux de marge moyen par type de produit



Méthodes statistiques employé:


- Taux de marge minimum (hors anomalies): 22,8%.
- Taux de marge maximum : 47,8%.

Analyse du taux de marge :

- Plage : -635% à +47,8%
- 🚨 Anomalie : ID 4355 (marge -634%) = erreur de saisie

Taux de marge moyen : 37,8% (calculé sur les 713 produits avec marge positive, hors anomalie ID 4355).

Analyses complémentaires : Correlations



Prix ↔ Ventes

Corrélation négative modérée. Les produits moins chers se vendent davantage.

Stock ↔ Ventes

Corrélation positive modérée. On stocke plus les produits qui se vendent bien.

Prix ↔ Stock

Corrélation très faible. Le prix n'influence pas la quantité stockée.

Une politique de prix compétitive est cruciale pour maximiser les ventes.

Conformité RGPD

Analyse des données traitées

Catégorie	Présence
Données produits	Oui (prix, stocks, SKU)
Données personnelles	Non
Données sensibles	Non

Conclusion

Le traitement est **CONFORME au RGPD**. Les données analysées concernent uniquement des produits et des indicateurs commerciaux. **Aucune donnée à caractère personnel n'est présente** dans ce jeu de données.

Recommandations

Documentation

Conserver une trace de ce processus d'analyse pour les futurs audits

Vigilance future

Si des données clients sont ajoutées, revoir la conformité RGPD

Sécurité

Protéger les fichiers exports (données commerciales sensibles)

Actions pour la suite

Contrôles ERP :

- Alertes automatiques sur prix/stocks négatifs
- Vérification des mappings produits (ERP ↔ Web)

Corrections prioritaires :


- Prix/stocks négatifs, marges négatives

Optimisation stocks :

- Focus sur le top 20% contributif
- Déstockage des produits à faible rotation

Préparation Data Viz :

- Modèle de données propre + KPIs clés
- ETL automatisé pour analyses mensuelles
- Dashboard Power BI / Tableau pour suivi temps réel



Point sur les compétences apprises

- *Qu'est-ce qui s'est bien passé pour vous dans ce travail de nettoyage ?*

- Fusion de sources hétérogènes (ERP, Web, liaison)
- Pipeline complet de nettoyage à l'analyse
- Traduction technique → messages business


- *Qu'est-ce que vous avez trouvé le plus difficile ?*

- Arbitrage sur les incohérences (prix/stocks négatifs)
- Choix d'indicateurs pertinents sur une période courte



- *Sur quelles tâches est-ce que vous pensez avoir besoin de plus d'entraînement ?*

- Formalisation des règles de qualité
- Analyses de rotation/valorisation de stock
- Tableaux de bord plus synthétiques



Conclusion: Synthèse et Recommandations

9 TYPES D'ERREURS CORRIGÉES

- 3 prix négatifs → supprimés
- 2 stocks négatifs → mis à 0
- 4 incohérences stock_status
- 714 attachments filtrés
- 91 produits sans id_web → exclus
- ⚠ ID 4355 : marge -634%

KPIS OCTOBRE

143 680€ CA total

5 751 bouteilles vendues

37,8% marge moyenne

16 740 bouteilles en stock

277 328€ valorisation stock

RECOMMANDATIONS ERP

- Unifier product_id = sku
- Validation : prix > 0 et > prix_achat
- Recalcul auto du stock_status
- Alertes si marge < seuil
- → Corriger ID 4355 en priorité

Résultat : 714 produits analysables

Pareto : 63,1% produits = 80% CA

RGPD : ✓ Conforme (données produits)

Prochaine étape : Data Visualisation

Cette base propre servira de fondation au futur dashboard (Power BI / Tableau)

714

produits prêts

Merci de votre attention