


Analyse de l'évolution du profil sociodémographique des étudiants

Data

OpenClassrooms - Parcours Data Analyst (2026)

Charles Lippens | Projet P8



Contexte et mission

Le contexte

OpenClassrooms souhaite comprendre l'évolution du profil de ses étudiants Data sur 4 ans (2022-2025) pour alimenter les réflexions sur l'accessibilité et l'égalité.

La mission

Marie-Neige (Lead Data Analyst) demande :

- Pipeline DBT documenté et reproductible
- Vérification qualité + conformité RGPD
- Intégration de données INSEE
- Présentation pour la direction pédagogique

3 livrables attendus

1. Fichier CSV exporté (données consolidées et nettoyées)
2. Workflow DBT (pipeline commenté, testé, versionné sur GitHub)
3. Ce support de présentation (15 slides)



Les données

4 647

inscriptions

4 ans

2022 → 2025

6

variables

13+

régions

Colonne	Type	Description	Rôle dans l'analyse
USER_ID	STRING	Identifiant pseudonymisé (hash)	Comptage individus distincts
AGE_GROUP	STRING	Tranche d'âge (20-24, 25-29...)	Dimension âge ★
GENDER	STRING	Genre déclaré (M/F/vidé) ★★	Dimension genre ★
REGION	STRING	Région de résidence	Dimension géographique ★
YEAR_PATH_STARTED	INTEGER	Année d'inscription	Dimension temporelle ★

★★ = après nettoyage c'est M/F/Non renseigné

★ = variable clé pour l'analyse sociodémographique | 568 USER_ID en doublon identifiés (637 lignes de réinscriptions)

Conformité RGPD

Pseudonymisation

USER_ID hashé, pas de tentative
de ré-identification

Donnée sensible

GENDER (art. 9 RGPD), justifié
par l'analyse d'égalité des chances

Pas d'imputation

Valeurs vides = « Non renseigné »
Respect du droit de non-réponse

Minimisation

6 colonnes uniquement, tranches
d'âge (pas l'âge exact), régions

Données INSEE : statistiques publiques agrégées, open data → aucun problème RGPD

Nettoyage des données (staging)

AVANT (RAW)

- GENDER contient des vides (~27%)
- Espaces parasites dans les textes
- 568 USER_ID en doublon
- Pas de documentation




APRÈS (STAGING)

- Genre = M / F / Non renseigné
- TRIM appliqué sur toutes les colonnes
- Doublons = réinscriptions (cas métier OK)
- Pipeline documenté et testé

Choix clé : pas d'imputation du genre (RGPD art. 9) → respect du droit de non-réponse

Architecture technique




Stack technologique

Snowflake (entrepôt de données) • **DBT Cloud** (transformations) • **GitHub** (versioning) • **INSEE** (données externes)


Staging : Nettoyer (TRIM, gestion NULL genre, filtre) **Intermediate** : Calculer (GROUP BY, COUNT, %)

Marts : Assembler (JOIN des intermédiaires)

Pipeline DBT




Effectifs par année



Constats

- Baisse de 44% entre 2022 et 2024
- Rebond en 2025 (+12%)
- 4 647 inscriptions totales
- 568 étudiants inscrits sur au moins 2 années (637 lignes de réinscriptions)

Parité Homme / Femme




Constats

- ~31% de femmes parmi les répondants (stable sur 4 ans)
- Chute massive du taux de non-réponse : de 42% (2022) à 7% (2025)
- Part des hommes passe de 41% à 62% (effet mécanique de la baisse des non-réponses)
- Amélioration de la qualité des données de collecte

Note : % femmes calculé sur les répondants uniquement (excluant « Non renseigné ») — conformité RGPD


Distribution par tranche d'âge (2022 -2025)



Constats

- **25-39 ans = 64% des étudiants**
- Profil typique : reconversion professionnelle
- Peu de jeunes 20-24 (4%) et de seniors 55+ (5%)
- Profil stable sur les 4 années

Évolution top 5 tranches d'âge




Constats

**30-34 ans domine mais perd du terrain
(27%→23%)**

- 25-29 ans monte fortement (15%→25%)
- Rajeunissement confirmé : âge moyen 38→35 ans
- 40-44 et 45-49 stables = base fidèle
- Profil reconversion se décale vers les plus jeunes


Répartition géographique (2022 – 2025)



Constats

- **IDF = 46% des étudiants (1 sur 2) vs 17% de la population française**
- Surreprésentation $\times 2,6$
- Top 3 : IDF, ARA, Hauts-de-France = 62%
- 7 régions regroupées dans "Autres" ne représentent que 20%
- Forte concentration géographique
→ levier de développement province
- Régions éloignées sous-représentées
→ enjeu d'accessibilité territoriale

Évolution du % Île-de-France



Constats

Pic à 54% en 2023, retour à ~41%

- Pas de démocratisation géographique durable
- L'IDF reste dominante chaque année
- La baisse 2024 coïncide avec la baisse globale des effectifs
- Enjeu d'accessibilité en province reste entier

Comparaison OC vs Population INSEE

Dimension	Étudiants OC	Population INSEE	Écart
% Femmes	31,1%	52,4%	-21,3 pts
% 25-39 ans	63,7%	23,3%	+40,4 pts
% Île-de-France	45,6%	17,4%	+28,2 pts

Source INSEE publiée le 1^{er} janvier 2026 : Estimations de population en 2023 (séries par région, sexe et âge quinquennal)

Genre

Déficit de parité de 21 points.
Les parcours Data restent majoritairement masculins.

Âge

Profil reconversion : les 25-39 ans sont surreprésentés $\times 2,7$ par rapport à la population.

Géographie

L'IDF concentre 2,6× plus d'étudiants que son poids démographique.

Tests et qualité des données

Test	Type	Ce qu'il vérifie	Résultat
not_null (USER_ID)	YAML	Aucune ligne sans identifiant	✓ PASS
not_null (gender)	YAML	Plus aucun NULL après nettoyage	✓ PASS
accepted_values (gender)	YAML	Uniquement M, F, Non renseigné	✓ PASS
accepted_values (year)	YAML	Années 2022-2025 uniquement	✓ PASS
unique_student_year	Custom	Unicité USER_ID + année	✓ PASS
percentages_sum_100	Custom	Cohérence des pourcentages	✓ PASS
region_pct_sum_100	Custom	Somme % régions = 100% par année	✓ PASS
no_future_years	Custom	Pas d'année hors plage 2022-2025	✓ PASS

Reproductibilité

Le pipeline est exécutable de bout en bout avec « dbt build » sans erreur. Les 8 tests passent automatiquement. Le code est versionné sur GitHub. Un nouveau data analyst peut cloner le repo et obtenir les mêmes résultats.

Synthèse et recommandations

Parité

31% de femmes parmi les répondants
(-21 pts vs population)



Actions ciblées pour attirer plus de femmes dans les parcours Data : partenariats avec des réseaux féminins tech

Profil âge

64% ont entre 25 et 39 ans
Profil type : reconversion pro



Adapter la communication vers les jeunes diplômés et les seniors : créer des parcours "courts" Découverte data

Géographie

46% en IDF ($\times 2,6$ vs population)
Régions éloignées sous-représentées



Renforcer la visibilité et l'accessibilité hors Île-de-France : campagnes régionales ciblées

Limites et perspectives

Limites

- de 42% à 7% de non-réponse au genre (moyenne ~27%)
- Tranches d'âge OC $\neq$ tranches INSEE
- 4 ans = tendances, pas de certitudes statistiques
- DROM regroupés (masque les disparités)
- Pas de données sur les motivations des étudiants

Perspectives

- Rendre le genre obligatoire (avec option NB)
- Comparer avec d'autres parcours OC
- Ajouter le niveau d'études et la CSP
- Étendre l'analyse sur 6-8 ans
- Dashboard Power BI connecté au mart DBT

Merci pour votre attention

Charles Lippens — Projet P8 — OpenClassrooms