

Lippens_Charles_1_notebook_analyse_indicateurs_ventes_052026

May 7, 2026

Analysez les ventes d'une librairie avec Python: analyse des indicateurs de ventes

1 OBJECTIF DE CE NOTEBOOK

Ce notebook analyse les ventes d'une librairie en ligne sur la période 2021-2023.

Objectifs : - Explorer et nettoyer les données transactionnelles (transactions, clients, produits) - Calculer les indicateurs clés de performance (CA, panier moyen, fréquence d'achat) - Analyser les tendances temporelles (CA journalier, moyennes mobiles, KPIs mensuels) - Étudier la répartition du CA par catégorie et identifier les produits clés (Pareto 80/20) - Identifier et profiler les 4 clients BtoB - Mesurer la concentration des ventes (courbe de Lorenz, coefficient de Gini)

Etape 1 - Importation des librairies et chargement des données

1.1 - Importation des librairies

```
[1]: # IMPORTS DE BASE
import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings('ignore')

# VISUALISATION
import matplotlib.pyplot as plt
import seaborn as sns

# STATISTIQUES
from scipy import stats
```

1.2 - Chargements des fichiers

```
[2]: # Chargement des trois fichiers
transactions = pd.read_csv('Transactions.csv', sep=';')
transactions = transactions.dropna(how='all') # Supprimer 361K lignes vides
↳ (padding Excel)
customers = pd.read_csv('customers.csv', sep=';')
products = pd.read_csv('products.csv', sep=';')
```

```
print(" Fichiers chargés avec succès!")
```

Fichiers chargés avec succès!

```
[3]: # Vérification chargement et des dimensions
```

```
print(f"Transactions: {transactions.shape} - {transactions.shape[0]} lignes, \n  
      ↳ {transactions.shape[1]} colonnes")  
print(f"Customers: {customers.shape}")  
print(f"Products: {products.shape}")
```

Transactions: (687534, 4) - 687534 lignes, 4 colonnes

Customers: (8621, 3)

Products: (3286, 3)

Etape 2 - Analyse exploratoire des fichiers

2.1 - Analyse exploratoire détaillée des données: Transactions

```
[4]: # --- Exploration du fichier Transactions ---  
# Objectif : comprendre la structure, les types, les volumes et détecter \n  
      ↳ d'éventuelles anomalies  
# (valeurs extrêmes, doublons, formats incohérents) avant la fusion des tables.  
print("=== TRANSACTIONS ===")  
print(transactions.info())           # Types et valeurs non-nulles par colonne  
print("\nPremières lignes:")  
print(transactions.head(10))         # Aperçu visuel des premières entrées  
print("\nDernières lignes:")  
print(transactions.tail())           # Vérifier la cohérence en fin de fichier  
print("\nTypes de données:")  
print(transactions.dtypes)  
print("\nStatistiques:")  
print(transactions.describe())       # Min/max/mean pour détecter les outliers \n  
      ↳ potentiels
```

=== TRANSACTIONS ===

<class 'pandas.core.frame.DataFrame'>

Index: 687534 entries, 0 to 687533

Data columns (total 4 columns):

#	Column	Non-Null Count	Dtype
0	id_prod	687534 non-null	object
1	date	687534 non-null	object
2	session_id	687534 non-null	object
3	client_id	687534 non-null	object

dtypes: object(4)

memory usage: 26.2+ MB

None

Premières lignes:

	id_prod	date	session_id	client_id
0	0_1259	2021-03-01 00:01:07.843138	s_1	c_329
1	0_1390	2021-03-01 00:02:26.047414	s_2	c_664
2	0_1352	2021-03-01 00:02:38.311413	s_3	c_580
3	0_1458	2021-03-01 00:04:54.559692	s_4	c_7912
4	0_1358	2021-03-01 00:05:18.801198	s_5	c_2033
5	0_1073	2021-03-01 00:05:44.999018	s_6	c_4908
6	0_1304	2021-03-01 00:07:04.371179	s_7	c_1609
7	0_279	2021-03-01 00:07:48.507530	s_6	c_4908
8	1_445	2021-03-01 00:09:11.523122	s_8	c_7991
9	1_556	2021-03-01 00:10:20.265265	s_9	c_6171

Dernières lignes:

	id_prod	date	session_id	client_id
687529	1_508	2023-02-28 23:49:03.148402	s_348444	c_3573
687530	2_37	2023-02-28 23:51:29.318531	s_348445	c_50
687531	1_695	2023-02-28 23:53:18.929676	s_348446	c_488
687532	0_1547	2023-02-28 23:58:00.107815	s_348447	c_4848
687533	0_1398	2023-02-28 23:58:30.792755	s_348435	c_3575

Types de données:

```
id_prod      object
date         object
session_id   object
client_id    object
dtype: object
```

Statistiques:

	id_prod	date	session_id	client_id
count	687534	687534	687534	687534
unique	3265	687419	345505	8600
top	1_369	2021-10-13 17:05:59.572162	s_118668	c_1609
freq	2340	2	14	25586

2.2 - Analyse exploratoire détaillée des données: Customers

```
[5]: # --- Exploration du fichier Customers ---
# Objectif : vérifier la qualité des données clients (âge, sexe),
# détecter les valeurs manquantes et les incohérences avant la fusion.
print("=== CUSTOMERS ===")
print(customers.info())
print("\nPremières lignes:")
print(customers.head())
print("\nStatistiques age (birth year):")
print(customers['birth'].describe()) # Vérifier l'étendue des années de
↳naissance (cohérence)
```

```
=== CUSTOMERS ===
```

```
<class 'pandas.core.frame.DataFrame'>
```

```

RangeIndex: 8621 entries, 0 to 8620
Data columns (total 3 columns):
#   Column      Non-Null Count  Dtype
---  -
0   client_id    8621 non-null   object
1   sex          8621 non-null   object
2   birth        8621 non-null   int64
dtypes: int64(1), object(2)
memory usage: 202.2+ KB
None

```

```

Premières lignes:
  client_id sex  birth
0    c_4410  f   1967
1    c_7839  f   1975
2    c_1699  f   1984
3    c_5961  f   1962
4    c_5320  m   1943

```

```

Statistiques age (birth year):
count      8621.000000
mean       1978.275606
std         16.917958
min        1929.000000
25%        1966.000000
50%        1979.000000
75%        1992.000000
max        2004.000000
Name: birth, dtype: float64

```

2.3 - Analyse exploratoire détaillée des données: Products

```

[6]: print("=== PRODUCTS ===")
      print(products.info())
      print("\nPremières lignes:")
      print(products.head())
      print("\nStatistiques prix:")
      print(products['price'].describe())
      print("\nCatégories disponibles:")
      print(products['categ'].unique())
      # Observer le lien entre id_prod et categ
      print("\nVérification lien id_prod  categ:")
      print("  Préfixe '0_' : categ:", products[products['id_prod'].str.
        ↳startswith('0_')]['categ'].unique())
      print("  Préfixe '1_' : categ:", products[products['id_prod'].str.
        ↳startswith('1_')]['categ'].unique())
      print("  Préfixe '2_' : categ:", products[products['id_prod'].str.
        ↳startswith('2_')]['categ'].unique())

```

```

=== PRODUCTS ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3286 entries, 0 to 3285
Data columns (total 3 columns):
#   Column      Non-Null Count  Dtype
---  -
0   id_prod     3286 non-null   object
1   price       3286 non-null   float64
2   categ       3286 non-null   int64
dtypes: float64(1), int64(1), object(1)
memory usage: 77.1+ KB
None

```

Premières lignes:

```

   id_prod  price  categ
0  0_1421  19.99      0
1  0_1368   5.13      0
2   0_731  17.99      0
3   1_587   4.99      1
4  0_1507   3.99      0

```

Statistiques prix:

```

count    3286.000000
mean         21.863597
std         29.849786
min          0.620000
25%          6.990000
50%         13.075000
75%         22.990000
max         300.000000
Name: price, dtype: float64

```

Catégories disponibles:

```
[0 1 2]
```

Vérification lien id_prod categ:

```

Préfixe '0_' : categ: [0]
Préfixe '1_' : categ: [1]
Préfixe '2_' : categ: [2]

```

2.4 - Vérification de la qualité des données

```

[7]: # VALEURS NULLES
print("=== VALEURS NULLES ===")
print("Transactions:")
print(transactions.isnull().sum())
print("\nCustomers:")
print(customers.isnull().sum())

```

```

print("\nProducts:")
print(products.isnull().sum())

# DOUBLONS
print("\n=== DOUBLONS ===")
print(f"Transactions: {transactions.duplicated().sum()} doublons")
print(f"Customers: {customers.duplicated().sum()} doublons")
print(f"Products: {products.duplicated().sum()} doublons")

```

=== VALEURS NULLES ===

Transactions:

```

id_prod      0
date         0
session_id   0
client_id    0
dtype: int64

```

Customers:

```

client_id    0
sex          0
birth        0
dtype: int64

```

Products:

```

id_prod      0
price        0
categ        0
dtype: int64

```

=== DOUBLONS ===

Transactions: 0 doublons

Customers: 0 doublons

Products: 0 doublons

2.5 - Conversion et Nettoyage des Colonnes

Note : Les variables temporelles ci-dessous sont extraites de la colonne **date** pour permettre les agrégations journalières, hebdomadaires et mensuelles nécessaires à l'analyse des tendances du CA et des KPIs opérationnels.

```

[8]: # Avant de fusionner les données, nous devons nettoyer et convertir les types
      ↪ de colonnes appropriées.
      # Conversion de la colonne date
      transactions['date'] = pd.to_datetime(transactions['date'])

      # Extraction d'informations temporelles
      transactions['annee'] = transactions['date'].dt.year
      transactions['mois'] = transactions['date'].dt.month

```

```

transactions['jour_semaine'] = transactions['date'].dt.day_name()
transactions['jour_semaine_num'] = transactions['date'].dt.dayofweek #_
    ↳ 0=lundi, 6=dimanche
transactions['semaine'] = transactions['date'].dt.isocalendar().week
transactions['annee_mois'] = transactions['date'].dt.to_period('M')

print("Nouvelles colonnes créées:")
print(transactions[['date', 'annee', 'mois', 'jour_semaine', 'annee_mois']]).
    ↳ head()

```

Nouvelles colonnes créées:

	date	annee	mois	jour_semaine	annee_mois
0	2021-03-01 00:01:07.843138	2021	3	Monday	2021-03
1	2021-03-01 00:02:26.047414	2021	3	Monday	2021-03
2	2021-03-01 00:02:38.311413	2021	3	Monday	2021-03
3	2021-03-01 00:04:54.559692	2021	3	Monday	2021-03
4	2021-03-01 00:05:18.801198	2021	3	Monday	2021-03

```

[9]: # Calcul de l'âge (année actuelle = 2023 environ, basé sur les données)
annee_ref = transactions['date'].dt.year.max() # = 2023
customers['age'] = annee_ref - customers['birth']

print("Statistiques âge:")
print(customers['age'].describe())

```

Statistiques âge:

count	8621.000000
mean	44.724394
std	16.917958
min	19.000000
25%	31.000000
50%	44.000000
75%	57.000000
max	94.000000

Name: age, dtype: float64

2.6 - Fusion des DataFrames

```

[10]: # On fusionne les trois tables pour créer un dataset complet avec toutes les_
    ↳ informations.
# Fusion transactions + products (sur id_prod)
data = transactions.merge(products, on='id_prod', how='left')

# Fusion data + customers (sur client_id)
data = data.merge(customers, on='client_id', how='left')

print(f"Dataset fusionné: {data.shape}")
print("\nColonnes disponibles:")

```

```
print(data.columns.tolist())
print("\nPremières lignes:")
print(data.head())
```

Dataset fusionné: (687534, 15)

Colonnes disponibles:

```
['id_prod', 'date', 'session_id', 'client_id', 'annee', 'mois', 'jour_semaine',
'jour_semaine_num', 'semaine', 'annee_mois', 'price', 'categ', 'sex', 'birth',
'age']
```

Premières lignes:

```
id_prod      date session_id client_id  annee  mois  \
0  0_1259 2021-03-01 00:01:07.843138      s_1    c_329   2021    3
1  0_1390 2021-03-01 00:02:26.047414      s_2    c_664   2021    3
2  0_1352 2021-03-01 00:02:38.311413      s_3    c_580   2021    3
3  0_1458 2021-03-01 00:04:54.559692      s_4    c_7912  2021    3
4  0_1358 2021-03-01 00:05:18.801198      s_5    c_2033  2021    3

jour_semaine  jour_semaine_num  semaine  annee_mois  price  categ  sex  birth  \
0      Monday                0        9    2021-03   11.99    0    f   1967
1      Monday                0        9    2021-03   19.37    0    m   1960
2      Monday                0        9    2021-03    4.50    0    m   1988
3      Monday                0        9    2021-03    6.55    0    f   1989
4      Monday                0        9    2021-03   16.49    0    f   1956

age
0    56
1    63
2    35
3    34
4    67
```

2.7 - Création des variables dérivées

Variables dérivées créées pour l'analyse :

Les variables ci-dessous sont créées à partir des données brutes pour faciliter l'analyse :

Variable	Source	Calcul	Utilité
annee, mois, jour_semaine	date	Extraction	Agrégations temporelles, saisonnalité
annee_mois	date	Période mensuelle	KPIs mensuels, moyennes mobiles
age	birth	annee_ref - birth	Profilage démographique des clients

Variable	Source	Calcul	Utilité
montant	price	= price (1 article/transaction)	Calcul du CA, panier moyen
categorie_nom	categ	Mapping 0:Essais, 1:Romans, 2:Jeunesse	Lisibilité graphiques (hypothèse, voir commentaire code)
sexe_nom	sex	f:Femme, m:Homme	Lisibilité analyses par genre

Justification : Ces variables permettent d'analyser les ventes selon plusieurs axes (temporel, catégoriel, démographique) et de calculer les indicateurs clés demandés dans le brief (CA, panier moyen, tendances, profils clients).

```
[11]: # --- Variables dérivées ---
data['montant'] = data['price']

# Création de variables supplémentaires utilisées pour l'analyse business
# Les données ne fournissent pas de nom pour les catégories (categ = 0, 1, 2).
# Hypothèse de nommage basée sur l'analyse des prix et volumes :
#   - categ 0 : "Essais" (prix moyen ~10€, 415K transactions : livres de poche/
#     ↪ essais)
#   - categ 1 : "Romans" (prix moyen ~20€, 235K transactions : romans format_
#     ↪ standard)
#   - categ 2 : "Jeunesse" (prix moyen ~76€, 36K transactions : beaux livres/
#     ↪ coffrets jeunesse)
# Le préfixe des id_prod (0_, 1_, 2_) confirme la cohérence categ produit.
# Montant de la transaction (price x 1 car 1 item par transaction)
categorie_map = {
    0: 'Cat. 0 - Essais',
    1: 'Cat. 1 - Romans',
    2: 'Cat. 2 - Jeunesse'
}
data['categorie_nom'] = data['categ'].map(categorie_map)

# Genre (F/M) : noms complets
data['sexe_nom'] = data['sex'].map({'f': 'Femme', 'm': 'Homme'})

print("Aperçu final du dataset:")
print(data.head(10))
print(f"\nTaille finale: {data.shape}")
```

Aperçu final du dataset:

	id_prod	date	session_id	client_id	annee	mois	\
0	0_1259	2021-03-01 00:01:07.843138	s_1	c_329	2021	3	
1	0_1390	2021-03-01 00:02:26.047414	s_2	c_664	2021	3	
2	0_1352	2021-03-01 00:02:38.311413	s_3	c_580	2021	3	
3	0_1458	2021-03-01 00:04:54.559692	s_4	c_7912	2021	3	

4	0_1358	2021-03-01	00:05:18.801198	s_5	c_2033	2021	3
5	0_1073	2021-03-01	00:05:44.999018	s_6	c_4908	2021	3
6	0_1304	2021-03-01	00:07:04.371179	s_7	c_1609	2021	3
7	0_279	2021-03-01	00:07:48.507530	s_6	c_4908	2021	3
8	1_445	2021-03-01	00:09:11.523122	s_8	c_7991	2021	3
9	1_556	2021-03-01	00:10:20.265265	s_9	c_6171	2021	3

	jour_semaine	jour_semaine_num	semaine	annee_mois	price	categ	sex	birth	\
0	Monday	0	9	2021-03	11.99	0	f	1967	
1	Monday	0	9	2021-03	19.37	0	m	1960	
2	Monday	0	9	2021-03	4.50	0	m	1988	
3	Monday	0	9	2021-03	6.55	0	f	1989	
4	Monday	0	9	2021-03	16.49	0	f	1956	
5	Monday	0	9	2021-03	13.99	0	f	1981	
6	Monday	0	9	2021-03	5.86	0	m	1980	
7	Monday	0	9	2021-03	16.99	0	f	1981	
8	Monday	0	9	2021-03	23.99	1	m	1968	
9	Monday	0	9	2021-03	24.47	1	m	1983	

	age	montant	categorie_nom	sexe_nom
0	56	11.99	Cat. 0 - Essais	Femme
1	63	19.37	Cat. 0 - Essais	Homme
2	35	4.50	Cat. 0 - Essais	Homme
3	34	6.55	Cat. 0 - Essais	Femme
4	67	16.49	Cat. 0 - Essais	Femme
5	42	13.99	Cat. 0 - Essais	Femme
6	43	5.86	Cat. 0 - Essais	Homme
7	42	16.99	Cat. 0 - Essais	Femme
8	55	23.99	Cat. 1 - Romans	Homme
9	40	24.47	Cat. 1 - Romans	Homme

Taille finale: (687534, 18)

2.8 - Vérifications de cohérence post-fusion

```
[12]: # Vérifier qu'aucune ligne n'a été perdue
print(f"Transactions originales: {len(transactions)}")
print(f"Transactions après fusion: {len(data)}")

# Vérifier les valeurs nulles après fusion (signe de problème d'ID)
print("\nValeurs nulles après fusion:")
print(data.isnull().sum())

# Vérifier la couverture des données
print(f"\nClients uniques: {data['client_id'].nunique()}")
print(f"Produits uniques: {data['id_prod'].nunique()}")
print(f"Sessions uniques: {data['session_id'].nunique()}")
```

```
# Vérifier la distribution des catégories
print("\nDistribution catégories:")
print(data['categorie_nom'].value_counts())
```

Transactions originales: 687534
 Transactions après fusion: 687534

Valeurs nulles après fusion:

```
id_prod      0
date          0
session_id    0
client_id     0
annee         0
mois          0
jour_semaine 0
jour_semaine_num 0
semaine       0
annee_mois    0
price         0
categ         0
sex           0
birth         0
age           0
montant       0
categorie_nom 0
sexe_nom      0
dtype: int64
```

Clients uniques: 8600
 Produits uniques: 3265
 Sessions uniques: 345505

Distribution catégories:

```
categorie_nom
Cat. 0 - Essais      415459
Cat. 1 - Romans      235592
Cat. 2 - Jeunesse    36483
Name: count, dtype: int64
```

Etape 3 - Analyse des indicateurs de vente

3.1 - Chiffres clés globaux

```
[13]: # CHIFFRES CLÉS GLOBAUX
# Calculs des KPIs
ca_total = data['montant'].sum()
# Donne une idée du montant typique d'une vente
ca_moyen_transaction = data['montant'].mean()
```

```

nb_transactions = len(data)
nb_clients = data['client_id'].nunique()
nb_produits = data['id_prod'].nunique()
# CA total divisé par le nombre de clients : permet de comprendre l'engagement
↳ et la valeur générée
ca_moyen_par_client = ca_total / nb_clients
# CA total divisé par le nombre de transactions
panier_moyen = ca_total / nb_transactions
# Affichage formaté
print("=" * 50)
print("CHIFFRES CLÉ GLOBAUX")
print("=" * 50)
print(f"Chiffre d'affaires total: {ca_total:.2f} €")
print(f"Chiffre d'affaires moyen par transaction: {ca_moyen_transaction:.2f} €")
print(f"Nombre total de transactions: {nb_transactions}")
print(f"Nombre de clients uniques: {nb_clients}")
print(f"Nombre de produits vendus: {nb_produits}")
print(f"CA moyen par client: {ca_moyen_par_client:.2f} €")
print(f"Panier moyen (par transaction): {panier_moyen:.2f} €")
print(f"Montant min/max par transaction: {data['montant'].min():.2f} € /
↳ {data['montant'].max():.2f} €")

```

```

=====
CHIFFRES CLÉ GLOBAUX
=====

```

```

Chiffre d'affaires total: 12027663.10 €
Chiffre d'affaires moyen par transaction: 17.49 €
Nombre total de transactions: 687534
Nombre de clients uniques: 8600
Nombre de produits vendus: 3265
CA moyen par client: 1398.57 €
Panier moyen (par transaction): 17.49 €
Montant min/max par transaction: 0.62 € / 300.00 €

```

3.2 - Évolution du Chiffre d'Affaires dans le Temps

```

[14]: # CA JOURNALIER
ca_journalier = data.groupby(data['date'].dt.date)['montant'].agg(['sum',
↳ 'count', 'mean'])
ca_journalier.columns = ['CA', 'Transactions', 'Montant_moyen']
ca_journalier = ca_journalier.reset_index()
ca_journalier.rename(columns={'date': 'Date'}, inplace=True)

# CA HEBDOMADAIRE
ca_hebdo = data.groupby(data['date'].dt.to_period('W'))['montant'].agg(['sum',
↳ 'count', 'mean'])
ca_hebdo.columns = ['CA', 'Transactions', 'Montant_moyen']

```

```

# CA MENSUEL
ca_mensuel = data.groupby(data['date'].dt.to_period('M'))['montant'].
    ↪agg(['sum', 'count', 'mean'])
ca_mensuel.columns = ['CA', 'Transactions', 'Montant_moyen']
# Nombre de clients uniques par mois (demandé dans le brief)
clients_par_mois = data.groupby(data['date'].dt.to_period('M'))['client_id'].
    ↪nunique()
produits_par_mois = data.groupby(data['date'].dt.to_period('M'))['id_prod'].
    ↪nunique()
ca_mensuel['Clients_uniques'] = clients_par_mois.values
ca_mensuel['Produits_vendus'] = produits_par_mois.values

print("CA JOURNALIER (premières lignes):")
print(ca_journalier.head(10))
print("\nCA MENSUEL:")
print(ca_mensuel)

```

CA JOURNALIER (premières lignes):

	Date	CA	Transactions	Montant_moyen
0	2021-03-01	16565.22	962	17.219563
1	2021-03-02	15486.45	939	16.492492
2	2021-03-03	15198.69	911	16.683524
3	2021-03-04	15196.07	903	16.828427
4	2021-03-05	17471.37	943	18.527434
5	2021-03-06	15785.28	961	16.425890
6	2021-03-07	14760.20	905	16.309613
7	2021-03-08	15679.53	928	16.896045
8	2021-03-09	15710.51	952	16.502637
9	2021-03-10	15496.87	942	16.451030

CA MENSUEL:

	date	CA	Transactions	Montant_moyen	Clients_uniques \
2021-03	482440.61	28601	16.867963	5676	
2021-04	476109.30	28443	16.739068	5674	
2021-05	492943.47	28285	17.427734	5644	
2021-06	484088.56	26850	18.029369	5659	
2021-07	482835.40	24738	19.517964	5672	
2021-08	482284.79	25650	18.802526	5642	
2021-09	507240.68	33314	15.226052	5693	
2021-10	494733.16	30022	16.479021	6190	
2021-11	516167.73	28311	18.232056	5875	
2021-12	525917.28	32457	16.203509	5867	
2022-01	525338.99	29343	17.903384	5809	
2022-02	535571.50	29594	18.097300	5729	
2022-03	515456.53	29696	17.357776	5835	
2022-04	492998.94	27602	17.860986	5695	

2022-05	517132.60	29975	17.252130	5843
2022-06	496016.12	28504	17.401632	5717
2022-07	510783.12	28670	17.815944	5778
2022-08	506467.27	28544	17.743388	5805
2022-09	494114.53	28306	17.456176	5738
2022-10	507917.77	28964	17.536175	5755
2022-11	496664.94	28563	17.388402	5749
2022-12	510219.50	28619	17.827999	5765
2023-01	517540.55	28938	17.884462	5828
2023-02	456679.76	25545	17.877462	5587

	Produits_vendus
date	
2021-03	2482
2021-04	2492
2021-05	2471
2021-06	2414
2021-07	2369
2021-08	2404
2021-09	2560
2021-10	2506
2021-11	2432
2021-12	2505
2022-01	2470
2022-02	2477
2022-03	2474
2022-04	2462
2022-05	2485
2022-06	2451
2022-07	2470
2022-08	2463
2022-09	2452
2022-10	2489
2022-11	2448
2022-12	2438
2023-01	2488
2023-02	2407

3.2.1 - Moyenne Mobile

```
[15]: # Moyenne mobile (MA): technique de lissage qui réduit les fluctuations court_
      ↳ terme et révèle les tendances sous jacentes. Elle calcule la moyenne
      # sur une fenetre glissante de N jours : identifie les vraies tendances sans_
      ↳ bruit quotidien
      # Calcul moyenne mobiles
      # Créer colonne de date pour CA journalier
      data_daily = data.groupby(data['date'].dt.date)['montant'].sum().reset_index()
      data_daily.columns = ['date', 'ca']
```

```

data_daily['date'] = pd.to_datetime(data_daily['date'])
data_daily = data_daily.sort_values('date')

# Moyennes mobiles
data_daily['MA_7j'] = data_daily['ca'].rolling(window=7, center=True).mean()
data_daily['MA_30j'] = data_daily['ca'].rolling(window=30, center=True).mean()

print("Données avec moyennes mobiles:")
print(data_daily.head(40))

```

Données avec moyennes mobiles:

	date	ca	MA_7j	MA_30j
0	2021-03-01	16565.22	NaN	NaN
1	2021-03-02	15486.45	NaN	NaN
2	2021-03-03	15198.69	NaN	NaN
3	2021-03-04	15196.07	15780.468571	NaN
4	2021-03-05	17471.37	15653.941429	NaN
5	2021-03-06	15785.28	15685.950000	NaN
6	2021-03-07	14760.20	15728.547143	NaN
7	2021-03-08	15679.53	15672.128571	NaN
8	2021-03-09	15710.51	15240.301429	NaN
9	2021-03-10	15496.87	15031.667143	NaN
10	2021-03-11	14801.14	15099.034286	NaN
11	2021-03-12	14448.58	15165.052857	NaN
12	2021-03-13	14324.84	15202.371429	NaN
13	2021-03-14	15231.77	15277.885714	NaN
14	2021-03-15	16141.66	15314.978571	NaN
15	2021-03-16	15971.74	15471.720000	15563.640667
16	2021-03-17	16025.47	15690.170000	15529.179667
17	2021-03-18	15060.79	16008.440000	15530.324000
18	2021-03-19	15545.77	15939.210000	15556.069333
19	2021-03-20	15853.99	15947.325714	15566.344000
20	2021-03-21	17459.66	15815.358571	15521.151000
21	2021-03-22	15657.05	15829.842857	15577.399333
22	2021-03-23	16028.55	15919.915714	15645.393333
23	2021-03-24	15101.70	15831.930000	15639.258667
24	2021-03-25	15162.18	15634.438571	15615.655667
25	2021-03-26	16176.28	15460.151429	15623.675667
26	2021-03-27	15238.09	15286.860000	15637.435000
27	2021-03-28	16077.22	15348.244286	15703.466000
28	2021-03-29	14437.04	15399.472857	15756.534333
29	2021-03-30	14815.51	15370.154286	15768.627333
30	2021-03-31	15531.39	15408.185714	15762.454333
31	2021-04-01	15520.78	15413.665714	15748.487333
32	2021-04-02	15971.05	15847.335714	15706.754333
33	2021-04-03	15504.31	16130.837143	15732.215333
34	2021-04-04	16115.58	16125.708571	15712.105000
35	2021-04-05	17472.73	16051.657143	15700.764000

36	2021-04-06	16800.02	16018.288571	15638.697000
37	2021-04-07	15495.49	15976.804286	15630.263667
38	2021-04-08	15002.42	16021.651429	15663.699667
39	2021-04-09	15737.47	15799.388571	15668.377667

3.2.2 Visualisation de l'évolution CA


```
[16]: fig, axes = plt.subplots(2, 1, figsize=(14, 10))

# Graphique 1: CA journalier + MA
ax1 = axes[0]
ax1.plot(data_daily['date'], data_daily['ca'], alpha=0.5, label='CA Quotidien',
        linewidth=1)
ax1.plot(data_daily['date'], data_daily['MA_7j'], label='Moyenne mobile 7j',
        linewidth=2, color='orange')
ax1.plot(data_daily['date'], data_daily['MA_30j'], label='Moyenne mobile 30j',
        linewidth=2, color='red')
ax1.fill_between(data_daily['date'], data_daily['ca'], alpha=0.2)
ax1.set_title('Évolution du Chiffre d\'Affaires - Avec Moyennes Mobiles',
        fontsize=13, fontweight='bold')
ax1.set_ylabel('CA (€)', fontweight='bold')
ax1.legend(loc='best')
ax1.grid(True, alpha=0.3)

# Graphique 2: CA mensuel (bar chart)
ca_monthly = data.groupby(data['date'].dt.to_period('M'))['montant'].sum()
ax2 = axes[1]
ca_monthly.index = ca_monthly.index.to_timestamp()
ax2.bar(ca_monthly.index, ca_monthly.values, color='steelblue', alpha=0.7,
        width=20)
ax2.set_title('Chiffre d\'Affaires Mensuel', fontsize=13, fontweight='bold')
ax2.set_ylabel('CA (€)', fontweight='bold')
ax2.set_xlabel('Mois', fontweight='bold')
ax2.grid(True, alpha=0.3, axis='y')

plt.tight_layout()
plt.show()

print("\nInterprétation:")
print("- La courbe quotidienne montre la volatilité normale")
print("- MA(7j) lisse les variations semaine par semaine")
print("- MA(30j) montre la vraie tendance long terme")
```

Interprétation:

- La courbe quotidienne montre la volatilité normale
- MA(7j) lisse les variations semaine par semaine
- MA(30j) montre la vraie tendance long terme

3.2.3 Évolution des KPIs Opérationnels

```
[17]: # --- Graphiques temporels des KPIs opérationnels ---
# (à ajouter JUSTE APRÈS le graphique CA + moyennes mobiles)

fig, axes = plt.subplots(3, 1, figsize=(14, 14), sharex=True)
fig.suptitle('Évolution Mensuelle des KPIs Opérationnels',
             fontsize=16, fontweight='bold', y=0.98)

mois_labels = ca_mensuel.index.to_timestamp()

# --- Graphique 1 : Nombre de clients uniques par mois ---
axes[0].plot(mois_labels, ca_mensuel['Clients_uniques'],
             marker='o', linewidth=2, color='#2E86C1', markersize=6)
axes[0].fill_between(mois_labels, ca_mensuel['Clients_uniques'],
                    alpha=0.15, color='#2E86C1')
```

```

mean_clients = ca_mensuel['Clients_uniques'].mean()
axes[0].axhline(mean_clients, color='red', linestyle='--', alpha=0.7,
                label=f'Moyenne : {mean_clients:.0f} clients/mois')
axes[0].set_ylabel('Nb clients uniques', fontweight='bold')
axes[0].set_title('Nombre de Clients Uniques par Mois', fontsize=13,
                 fontweight='bold')
axes[0].legend(loc='best')
axes[0].grid(True, alpha=0.3)
# Annotation min/max
idx_max = ca_mensuel['Clients_uniques'].idxmax()
idx_min = ca_mensuel['Clients_uniques'].idxmin()
axes[0].annotate(f'Max: {ca_mensuel.loc[idx_max, "Clients_uniques"]}',
                 xy=(idx_max.to_timestamp(), ca_mensuel.loc[idx_max, 'Clients_uniques']),
                 fontsize=9, fontweight='bold', color='green',
                 textcoords='offset points', xytext=(10, 10),
                 arrowprops=dict(arrowstyle='->', color='green'))

# --- Graphique 2 : Nombre de transactions par mois ---
axes[1].bar(mois_labels, ca_mensuel['Transactions'],
            color='#E67E22', alpha=0.8, width=20, edgecolor='black',
            linewidth=0.5)
mean_trans = ca_mensuel['Transactions'].mean()
axes[1].axhline(mean_trans, color='red', linestyle='--', alpha=0.7,
                label=f'Moyenne : {mean_trans:.0f} transactions/mois')
axes[1].set_ylabel('Nb transactions', fontweight='bold')
axes[1].set_title('Nombre de Transactions par Mois', fontsize=13,
                 fontweight='bold')
axes[1].legend(loc='best')
axes[1].grid(True, alpha=0.3, axis='y')

# --- Graphique 3 : Nombre de produits distincts vendus par mois ---
axes[2].plot(mois_labels, ca_mensuel['Produits_vendus'],
             marker='s', linewidth=2, color='#27AE60', markersize=6)
axes[2].fill_between(mois_labels, ca_mensuel['Produits_vendus'],
                    alpha=0.15, color='#27AE60')
mean_prod = ca_mensuel['Produits_vendus'].mean()
axes[2].axhline(mean_prod, color='red', linestyle='--', alpha=0.7,
                label=f'Moyenne : {mean_prod:.0f} produits/mois')
axes[2].set_ylabel('Nb produits distincts', fontweight='bold')
axes[2].set_title('Nombre de Produits Distincts Vendus par Mois', fontsize=13,
                 fontweight='bold')
axes[2].set_xlabel('Mois', fontweight='bold')
axes[2].legend(loc='best')
axes[2].grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('kpis_temporels.png', dpi=150, bbox_inches='tight')

```


```

plt.show()

# --- Tableau récapitulatif mensuel ---
print('\nRécapitulatif mensuel :')
recap = ca_mensuel[['CA', 'Transactions', 'Clients_uniques', 'Produits_vendus',
    ↳ 'Montant_moyen']].copy()
recap.columns = ['CA (\u20ac)', 'Transactions', 'Clients', 'Produits', 'Panier_\u20ac']
print(recap.round(2).to_string())
print(f'\nMoyennes mensuelles :')
print(f'  Clients : {mean_clients:.0f} | Transactions : {mean_trans:.0f} | \u20acProduits : {mean_prod:.0f}')

print("\nInterprétation:")
print("- Les KPIs opérationnels sont relativement stables sur la période")
print("- Légère baisse saisonnière visible en fin d'année")
print("- La base clients active reste constante (~5 750 clients/mois)")

```



Récapitulatif mensuel :

	CA (€)	Transactions	Clients	Produits	Panier moyen (€)
date					
2021-03	482440.61	28601	5676	2482	16.87
2021-04	476109.30	28443	5674	2492	16.74
2021-05	492943.47	28285	5644	2471	17.43
2021-06	484088.56	26850	5659	2414	18.03
2021-07	482835.40	24738	5672	2369	19.52
2021-08	482284.79	25650	5642	2404	18.80
2021-09	507240.68	33314	5693	2560	15.23
2021-10	494733.16	30022	6190	2506	16.48
2021-11	516167.73	28311	5875	2432	18.23
2021-12	525917.28	32457	5867	2505	16.20

2022-01	525338.99	29343	5809	2470	17.90
2022-02	535571.50	29594	5729	2477	18.10
2022-03	515456.53	29696	5835	2474	17.36
2022-04	492998.94	27602	5695	2462	17.86
2022-05	517132.60	29975	5843	2485	17.25
2022-06	496016.12	28504	5717	2451	17.40
2022-07	510783.12	28670	5778	2470	17.82
2022-08	506467.27	28544	5805	2463	17.74
2022-09	494114.53	28306	5738	2452	17.46
2022-10	507917.77	28964	5755	2489	17.54
2022-11	496664.94	28563	5749	2448	17.39
2022-12	510219.50	28619	5765	2438	17.83
2023-01	517540.55	28938	5828	2488	17.88
2023-02	456679.76	25545	5587	2407	17.88

Moyennes mensuelles :

Clients : 5759 | Transactions : 28647 | Produits : 2463

Interprétation:

- Les KPIs opérationnels sont relativement stables sur la période
- Légère baisse saisonnière visible en fin d'année
- La base clients active reste constante (~5 750 clients/mois)

3.3 Chiffre d’Affaires par Catégorie

```
[18]: # CA par catégorie
# Rappel mapping : categ 0 = Essais, 1 = Romans, 2 = Jeunesse
ca_categ = data.groupby('categorie_nom')['montant'].agg(['sum', 'count',
↳ 'mean'])

ca_categ.columns = ['CA', 'Nombre_transactions', 'Montant_moyen']
ca_categ['Pourcentage'] = (ca_categ['CA'] / ca_categ['CA'].sum() * 100).round(2)
ca_categ = ca_categ.sort_values('CA', ascending=False)

print(ca_categ)
print("\nInterprétation:")
print(f"- Catégorie dominante:{ca_categ.index[ca_categ['CA'].argmax()]}
↳ ({ca_categ['CA'].max():,.0f} €)")
print("- Les 3 catégories ont des profils de vente distincts (CA, volume,
↳ panier moyen)")
# Visualisation
fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# Bar chart
ax1 = axes[0]
ca_categ['CA'].plot(kind='bar', ax=ax1, color=['#1f77b4', '#ff7f0e', '#2ca02c'])
ax1.set_title('Chiffre d\'Affaires par Catégorie', fontweight='bold',
↳ fontsize=12)
```

```

ax1.set_ylabel('CA (€)', fontweight='bold')
ax1.set_xlabel('Catégorie', fontweight='bold')
ax1.grid(True, alpha=0.3, axis='y')
plt.setp(ax1.xaxis.get_majorticklabels(), rotation=45)

# Pie chart
ax2 = axes[1]
colors = ['#1f77b4', '#ff7f0e', '#2ca02c']
ax2.pie(ca_categ['CA'], labels=ca_categ.index, autopct='%1.1f%%',
        ↪ colors=colors, startangle=90)
ax2.set_title('Distribution du CA par Catégorie', fontweight='bold',
        ↪ fontsize=12)



plt.tight_layout()
plt.show()

```

	CA	Nombre_transactions	Montant_moyen	Pourcentage
categorie_nom				
Cat. 1 - Romans	4827657.11	235592	20.491600	40.14
Cat. 0 - Essais	4419730.97	415459	10.638188	36.75
Cat. 2 - Jeunesse	2780275.02	36483	76.207412	23.12

Interprétation:

- Catégorie dominante: Cat. 1 - Romans (4,827,657 €)
- Les 3 catégories ont des profils de vente distincts (CA, volume, panier moyen)



3.4 Top 10 et Flop 10 des produits

[19]: # Analyse Pareto (règle 80/20) montre que les 20% des des produits génèrent 80%
 ↪ du CA.

```

# Identification de ces produits est crucial pour la stratégie d'inventaire.
# CA par produit
ca_produit = data.groupby('id_prod').agg({
    'montant': ['sum', 'count', 'mean'],
    'price': 'first',
    'categorie_nom': 'first'
}).reset_index()

ca_produit.columns = ['id_prod', 'CA', 'Nb_ventes', 'Montant_moyen', 'Price', 'Categorie']
ca_produit = ca_produit.sort_values('CA', ascending=False)

# TOP 10
top10 = ca_produit.head(10)
print("=" * 80)
print("TOP 10 PRODUITS (par CA)")
print("=" * 80)
print(top10.to_string(index=False))

# FLOP 10
flop10 = ca_produit.tail(10)
print("\n" + "=" * 80)
print("FLOP 10 PRODUITS (par CA)")
print("=" * 80)
print(flop10.to_string(index=False))
print("\nInterprétation:")
print("- Écart considérable entre top et flop produits")
print("- Les top produits sont les piliers du CA, les flop indiquent un possible 'long tail'")

# Visualisation TOP 10
fig, axes = plt.subplots(2, 1, figsize=(12, 10))

ax1 = axes[0]
top10_plot = top10.sort_values('CA')
ax1.barh(top10_plot['id_prod'].astype(str), top10_plot['CA'], color='green', alpha=0.7)
ax1.set_title('Top 10 Produits (par CA)', fontweight='bold', fontsize=12)
ax1.set_xlabel('CA (€)', fontweight='bold')
ax1.grid(True, alpha=0.3, axis='x')

ax2 = axes[1]
flop10_plot = flop10.sort_values('CA')
ax2.barh(flop10_plot['id_prod'].astype(str), flop10_plot['CA'], color='red', alpha=0.7)
ax2.set_title('Flop 10 Produits (par CA)', fontweight='bold', fontsize=12)
ax2.set_xlabel('CA (€)', fontweight='bold')
ax2.grid(True, alpha=0.3, axis='x')

```

```
plt.tight_layout()
plt.show()
```

TOP 10 PRODUITS (par CA)


id_prod	CA	Nb_ventes	Montant_moyen	Price	Categorie
2_159	94893.50	650	145.99	145.99	Cat. 2 - Jeunesse
2_135	69334.95	1005	68.99	68.99	Cat. 2 - Jeunesse
2_112	65407.76	968	67.57	67.57	Cat. 2 - Jeunesse
2_102	60736.78	1027	59.14	59.14	Cat. 2 - Jeunesse
2_209	56971.86	814	69.99	69.99	Cat. 2 - Jeunesse
1_395	56617.47	1953	28.99	28.99	Cat. 1 - Romans
1_369	56136.60	2340	23.99	23.99	Cat. 1 - Romans
2_110	53846.25	865	62.25	62.25	Cat. 2 - Jeunesse
1_383	53834.43	1857	28.99	28.99	Cat. 1 - Romans
1_414	53522.18	2246	23.83	23.83	Cat. 1 - Romans

FLOP 10 PRODUITS (par CA)

id_prod	CA	Nb_ventes	Montant_moyen	Price	Categorie
0_1840	2.56	2	1.28	1.28	Cat. 0 - Essais
0_898	2.54	2	1.27	1.27	Cat. 0 - Essais
0_1498	2.48	1	2.48	2.48	Cat. 0 - Essais
0_1728	2.27	1	2.27	2.27	Cat. 0 - Essais
0_541	1.99	1	1.99	1.99	Cat. 0 - Essais
0_1601	1.99	1	1.99	1.99	Cat. 0 - Essais
0_807	1.99	1	1.99	1.99	Cat. 0 - Essais
0_1653	1.98	2	0.99	0.99	Cat. 0 - Essais
0_1284	1.38	1	1.38	1.38	Cat. 0 - Essais
0_1539	0.99	1	0.99	0.99	Cat. 0 - Essais

Interprétation:

- Écart considérable entre top et flop produits
- Les top produits sont les piliers du CA, les flop indiquent un possible 'long tail'



3.4.1 Analyse Pareto (Courbe 80/20)

```
[20]: # Préparer données pour Pareto
pareto_data = ca_produit.sort_values('CA', ascending=False).
    ↪reset_index(drop=True)
pareto_data['CA_cumul'] = pareto_data['CA'].cumsum()
pareto_data['CA_cumul_pct'] = (pareto_data['CA_cumul'] / pareto_data['CA'].
    ↪sum() * 100)
pareto_data['produit_rank'] = range(1, len(pareto_data) + 1)
pareto_data['produit_pct'] = (pareto_data['produit_rank'] / len(pareto_data) * 100)
    ↪100)

# Créer graphique Pareto
fig, ax1 = plt.subplots(figsize=(12, 6))

# Bar chart (CA par produit)
ax1.bar(pareto_data['produit_rank'], pareto_data['CA'], alpha=0.6,
    ↪color='steelblue', label='CA par produit')
```

```

ax1.set_xlim(0, len(pareto_data))
ax1.set_xlabel('Rang Produit (classé par CA décroissant)', fontweight='bold')
ax1.set_ylabel('CA (€)', fontweight='bold', color='steelblue')
ax1.tick_params(axis='y', labelcolor='steelblue')
ax1.set_title('Diagramme de Pareto - Analyse ABC des Produits',
    ↪fontweight='bold', fontsize=13)


# Courbe cumulative (sur axe secondaire)
ax2 = ax1.twinx()
ax2.plot(pareto_data['produit_rank'], pareto_data['CA_cumul_pct'], color='red',
    ↪marker='o',
        linewidth=2, markersize=3, label='% CA Cumulé')
ax2.axhline(y=80, color='orange', linestyle='--', linewidth=2, label='Seuil_
    ↪80%')
ax2.set_ylabel('% CA Cumulé', fontweight='bold', color='red')
ax2.tick_params(axis='y', labelcolor='red')

# Identifier le point 80%
idx_80 = pareto_data[pareto_data['CA_cumul_pct'] >= 80].iloc[0]
ax2.axvline(x=idx_80['produit_rank'], color='orange', linestyle='--', alpha=0.7)
ax2.text(idx_80['produit_rank'] + 10, 75, f"80% CA\ndevc
    ↪{int(idx_80['produit_rank'])} produits",
        fontsize=10, bbox=dict(boxstyle='round', facecolor='yellow', alpha=0.
    ↪5))

plt.legend(loc='center right')
plt.tight_layout()
plt.show()

print(f"\n80% du CA provient de {int(idx_80['produit_rank'])} produits sur_
    ↪{len(pareto_data)} = {idx_80['produit_pct']:.1f}%")
print("\nInterprétation:")
print("- La règle de Pareto se confirme : une minorité de produits génère_
    ↪l'essentiel du CA")
print("- Stratégie recommandée : protéger le stock et la visibilité des top_
    ↪produits")

```



80% du CA provient de 700 produits sur 3265 = 21.4%

Interprétation:

- La règle de Pareto se confirme : une minorité de produits génère l'essentiel du CA
- Stratégie recommandée : protéger le stock et la visibilité des top produits

3.4.2 Profil détaillé des clients BtoB et répartition de leur CA

3.4.2.1 Identification et tableau récapitulatif des BtoB

```
[21]: # --- Identification des 4 clients BtoB (top CA) ---
ca_par_client = data.groupby('client_id').agg(
    ca_total=('price', 'sum'),
    nb_transactions=('session_id', 'nunique'),
    nb_articles=('id_prod', 'count'),
    nb_categories=('categ', 'nunique'),
    premiere_date=('date', 'min'),
    derniere_date=('date', 'max')
).reset_index()

ca_par_client = ca_par_client.sort_values('ca_total', ascending=False)

# Les 4 premiers sont les BtoB
btob = ca_par_client.head(4).copy()
btob['panier_moyen'] = (btob['ca_total'] / btob['nb_transactions']).round(2)
btob['articles_par_session'] = (btob['nb_articles'] / btob['nb_transactions']).
    round(1)
```

```

print('=' * 70)
print('PROFIL DES 4 CLIENTS BtoB')
print('=' * 70)
print(btob[['client_id', 'ca_total', 'nb_transactions', 'nb_articles',
            'nb_categories', 'panier_moyen', 'articles_par_session']].
      ↪to_string(index=False))

# Poids dans le CA total
ca_total_global = data['price'].sum()
ca_btob = btob['ca_total'].sum()
print(f'\nCA total global : {ca_total_global:,.2f} \u20ac')
print(f'CA des 4 BtoB : {ca_btob:,.2f} \u20ac ({ca_btob/ca_total_global*100:.
      ↪1f}%)')
print(f'CA BtoC restant : {ca_total_global - ca_btob:,.2f} \u20ac ({(1-ca_btob/
      ↪ca_total_global)*100:.1f}%)')

```

```

=====
PROFIL DES 4 CLIENTS BtoB
=====
client_id  ca_total  nb_transactions  nb_articles  nb_categories  panier_moyen
articles_par_session
      c_1609 326039.89           10997           25586              3           29.65
2.3
      c_4958 290227.03           3851           5222              3           75.36
1.4
      c_6714 153918.60           2620           9199              3           58.75
3.5
      c_3454 114110.57           5571           6793              3           20.48
1.2

CA total global : 12,027,663.10 €
CA des 4 BtoB : 884,296.09 € (7.4%)
CA BtoC restant : 11,143,367.01 € (92.6%)

```

3.4.2.2 Quelles catégories achètent les BtoB?

[22]:

```

# --- Répartition du CA BtoB par catégorie ---
# Objectif : analyser si les clients BtoB achètent les mêmes catégories
# que l'ensemble des clients, ou s'ils sont concentrés sur certains segments.
# Cela permet d'identifier les leviers de négociation et le risque de
      ↪dépendance.
btob_ids = btob['client_id'].tolist()
data_btob = data[data['client_id'].isin(btob_ids)] # Filtrer les transactions
      ↪BtoB

ca_btob_categ = data_btob.groupby('categ')['price'].sum().reset_index()
ca_btob_categ.columns = ['Catégorie', 'CA BtoB']

```

```

ca_btob_categ['% du CA BtoB'] = (ca_btob_categ['CA BtoB'] / ca_btob_categ['CA_
↳BtoB'].sum() * 100).round(1)

# Comparaison avec le CA global pour voir les écarts de structure
ca_global_categ = data.groupby('categ')['price'].sum().reset_index()
ca_global_categ.columns = ['Catégorie', 'CA Global']
ca_global_categ['% du CA Global'] = (ca_global_categ['CA Global'] /_
↳ca_global_categ['CA Global'].sum() * 100).round(1)

comparaison = ca_btob_categ.merge(ca_global_categ, on='Catégorie')
comparaison['Catégorie'] = ['Cat. 0', 'Cat. 1', 'Cat. 2']
print('\nComparaison répartition CA par catégorie :')
print(comparaison.to_string(index=False))

```

Comparaison répartition CA par catégorie :

Catégorie	CA BtoB	% du CA BtoB	CA Global	% du CA Global
Cat. 0	300530.28	34.0	4419730.97	36.7
Cat. 1	307555.25	34.8	4827657.11	40.1
Cat. 2	276210.56	31.2	2780275.02	23.1

3.4.2.3 Evolution temporelle des achats BtoB

```

[23]: # --- Évolution mensuelle du CA BtoB vs CA global ---
# Objectif : suivre le poids du CA BtoB dans le temps pour détecter
# une saisonnalité ou une tendance de croissance/décroissance des achats BtoB.
# Utile pour anticiper les variations de trésorerie liées à ces gros clients.

data_btob['mois'] = data_btob['date'].dt.to_period('M')
ca_btob_mois = data_btob.groupby('mois')['price'].sum().reset_index()
ca_btob_mois.columns = ['mois', 'ca_btob']

# CA global par mois pour calculer le ratio BtoB/total
data['mois'] = data['date'].dt.to_period('M')
ca_global_mois = data.groupby('mois')['price'].sum().reset_index()
ca_global_mois.columns = ['mois', 'ca_global']

ca_compare_mois = ca_global_mois.merge(ca_btob_mois, on='mois', how='left').
↳fillna(0)
ca_compare_mois['pct_btob'] = (ca_compare_mois['ca_btob'] /_
↳ca_compare_mois['ca_global'] * 100).round(1)
ca_compare_mois['ca_btoc'] = ca_compare_mois['ca_global'] -_
↳ca_compare_mois['ca_btob']

print('\nPoids du CA BtoB par mois :')
print(ca_compare_mois[['mois', 'ca_global', 'ca_btob', 'pct_btob']].
↳to_string(index=False))

```

Poids du CA BtoB par mois :

mois	ca_global	ca_btob	pct_btob
2021-03	482440.61	36521.90	7.6
2021-04	476109.30	36771.45	7.7
2021-05	492943.47	38056.01	7.7
2021-06	484088.56	36986.39	7.6
2021-07	482835.40	35242.25	7.3
2021-08	482284.79	36282.49	7.5
2021-09	507240.68	36318.88	7.2
2021-10	494733.16	27335.94	5.5
2021-11	516167.73	38075.65	7.4
2021-12	525917.28	38193.88	7.3
2022-01	525338.99	36528.91	7.0
2022-02	535571.50	42644.37	8.0
2022-03	515456.53	38507.69	7.5
2022-04	492998.94	35682.88	7.2
2022-05	517132.60	37932.60	7.3
2022-06	496016.12	38705.34	7.8
2022-07	510783.12	37318.17	7.3
2022-08	506467.27	36835.13	7.3
2022-09	494114.53	34998.80	7.1
2022-10	507917.77	37102.28	7.3
2022-11	496664.94	37277.02	7.5
2022-12	510219.50	39727.69	7.8
2023-01	517540.55	36056.05	7.0
2023-02	456679.76	35194.32	7.7

3.4.2.4 Visualisation: 4 graphiques

```
[24]: fig, axes = plt.subplots(2, 2, figsize=(16, 12))
fig.suptitle('Analyse Détaillée des Clients BtoB', fontsize=16,
            fontweight='bold', y=0.98)

# --- Graphique 1 : CA individuel des 4 BtoB ---
colors_btob = ['#e74c3c', '#e67e22', '#f1c40f', '#2ecc71']
bars = axes[0,0].barh(btob['client_id'].astype(str), btob['ca_total'],
                    color=colors_btob, edgecolor='black')
for bar, val in zip(bars, btob['ca_total']):
    axes[0,0].text(val + 100, bar.get_y() + bar.get_height()/2,
                  f'{val:,.0f}\u20ac', va='center', fontweight='bold')
axes[0,0].set_title('CA individuel des 4 clients BtoB', fontsize=13,
                    fontweight='bold')
axes[0,0].set_xlabel('Chiffre d\'affaires (\u20ac)')
axes[0,0].set_ylabel('ID Client')

# --- Graphique 2 : Pie BtoB vs BtoC ---
ca_btoc = ca_total_global - ca_btob
```

```

axes[0,1].pie([ca_btob, ca_btoc],
              labels=[f'BtoB (4 clients)\n{ca_btob:,.0f}\u20ac',
                      f'BtoC ({len(ca_par_client)-4} clients)\n{ca_btoc:,.
                      ↪0f}\u20ac'],
              autopct='%1.1f%%', colors=['#e74c3c', '#3498db'],
              explode=[0.08, 0], startangle=90,
              textprops={'fontsize': 11})
axes[0,1].set_title('Répartition CA : BtoB vs BtoC', fontsize=13,
                    ↪fontweight='bold')

# --- Graphique 3 : Répartition par catégorie (BtoB vs Global) ---
x = range(len(ca_btob_categ))
w = 0.35
axes[1,0].bar([i - w/2 for i in x], comparaison['% du CA BtoB'],
              w, label='BtoB', color='#e74c3c', edgecolor='black')
axes[1,0].bar([i + w/2 for i in x], comparaison['% du CA Global'],
              w, label='Global', color='#3498db', edgecolor='black')
axes[1,0].set_xticks(list(x))
axes[1,0].set_xticklabels(['Cat. 0 - Romans', 'Cat. 1 - Essais', 'Cat. 2 -
                    ↪Jeunesse'])
axes[1,0].set_ylabel('% du CA')
axes[1,0].set_title('Répartition CA par catégorie\n(BtoB vs Global)',
                    ↪fontsize=13, fontweight='bold')
axes[1,0].legend()


# --- Graphique 4 : Évolution % BtoB dans le CA mensuel ---
mois_str = ca_compare_mois['mois'].astype(str)
axes[1,1].fill_between(range(len(mois_str)), ca_compare_mois['ca_btoc'],
                      label='CA BtoC', alpha=0.7, color='#3498db')
axes[1,1].fill_between(range(len(mois_str)), ca_compare_mois['ca_btoc'],
                      ca_compare_mois['ca_global'],
                      label='CA BtoB', alpha=0.7, color='#e74c3c')
axes[1,1].set_xticks(range(len(mois_str)))
axes[1,1].set_xticklabels(mois_str, rotation=45, ha='right', fontsize=8)
axes[1,1].set_ylabel('CA (\u20ac)')
axes[1,1].set_title('Évolution mensuelle CA : BtoB vs BtoC', fontsize=13,
                    ↪fontweight='bold')
axes[1,1].legend()

plt.tight_layout()
plt.savefig('profil_btob_complet.png', dpi=150, bbox_inches='tight')
plt.show()

print("\nInterprétation:")
print(f"- c_1609 est le plus gros client BtoB ({btob.iloc[0]['ca_total']:,.0f}
                    ↪€)")

```

```
print(f"- Les 4 BtoB représentent {ca_btob/ca_total_global*100:.1f}% du CA_
↳total ({ca_btob:,.0f} €)")
print("- Leur répartition par catégorie suit globalement la tendance globale")
print("- L'évolution mensuelle montre une contribution BtoB stable dans le_
↳temps")
```



Interprétation:

- c_1609 est le plus gros client BtoB (326,040 €)
- Les 4 BtoB représentent 7.4% du CA total (884,296 €)
- Leur répartition par catégorie suit globalement la tendance globale
- L'évolution mensuelle montre une contribution BtoB stable dans le temps

3.5 Courbe de Lorenz et Coefficient de Gini

[25]: *# La courbe de Lorenz et le coefficient de Gini mesurent la concentration des_*
↳ventes parmi les clients.
Un Gini de 0 = distribution parfaitement égale, 1 = concentration extrême.
Calculer CA par client
 ca_client = data.groupby('client_id')['montant'].sum().reset_index()
 ca_client.columns = ['client_id', 'ca']


```

ca_client = ca_client.sort_values('ca').reset_index(drop=True)

# Courbe de Lorenz
ca_client['ca_cumul'] = ca_client['ca'].cumsum()
ca_client['ca_cumul_pct'] = (ca_client['ca_cumul'] / ca_client['ca'].sum() * 100)

ca_client['client_idx'] = range(len(ca_client))
ca_client['client_pct'] = (ca_client['client_idx'] / len(ca_client) * 100)

# Coefficient de Gini
def compute_gini(values):
    sorted_vals = np.sort(values)
    n = len(values)
    index = np.arange(1, n + 1)
    gini = (2 * np.sum(index * sorted_vals)) / (n * np.sum(sorted_vals)) - (n + 1) / n
    return gini

gini = compute_gini(ca_client['ca'].values)

# Visualisation
fig, ax = plt.subplots(figsize=(10, 8))

# Courbe de Lorenz
ax.plot(ca_client['client_pct'], ca_client['ca_cumul_pct'], 'b-', linewidth=2,
        label='Courbe de Lorenz')

# Ligne d'égalité parfaite (45°)
ax.plot([0, 100], [0, 100], 'k--', linewidth=1.5, label='Égalité parfaite',
        alpha=0.7)

# Remplir zone de concentration
ax.fill_between(ca_client['client_pct'], ca_client['ca_cumul_pct'],
               ca_client['client_pct'], alpha=0.3, color='blue')

ax.set_xlabel('% de Clients (du plus faible au plus grand acheteur)',
             fontweight='bold')
ax.set_ylabel('% du CA Cumulé', fontweight='bold')
ax.set_title(f'Courbe de Lorenz - Concentration des Ventes (Gini = {gini:.3f})',
            fontweight='bold', fontsize=13)
ax.grid(True, alpha=0.3)
ax.legend(loc='upper left', fontsize=11)
ax.set_xlim([0, 100])
ax.set_ylim([0, 100])


plt.tight_layout()
plt.show()

```

```

print(f"Coefficient de Gini: {gini:.4f}")
print("\nInterprétation:")
print(f"- Gini = {gini:.4f} : Distribution {'concentrée' if gini > 0.5 else 'relativement égale'}")
print("- Les top clients représentent une part importante du CA")
print("- À adapter: stratégie de fidélisation vs. acquisition")
print(" " * 72)
print(" CONCLUSION SUR CERTAINS CLIENTS. LECTURE DE LA COURBE DE LORENZ".
      ↪center(72))
print(" " * 72)
print()
print("  OBSERVATION ..... La courbe présente un décrochement quasi-vertical")
print("                        sur les derniers pourcents en abscisse.")
print()
print("  IDENTIFICATION ... Ce coude correspond aux 4 clients BtoB :)")
print("                  ~0,05 % des clients captent  7 % du CA total.")
print()
print("  CONCLUSION ..... Ces 4 clients constituent une population atypique")
print("                  aux volumes d'achat hors-norme (×140 vs moyenne).")
print("                  Ils expliquent l'essentiel du Gini (0,442).")
print()
print("  CONSÉQUENCES ..... • Fidélisation critique (exposition concentrée).")
print("                      • Exclusion justifiée du notebook de corrélations")
print("                      (outliers statistiques).")
print("                      • Base BtoC équilibrée : potentiel d'up-sell.")
print(" " * 72)

```



Coefficient de Gini: 0.4419

Interprétation:

- Gini = 0.4419 : Distribution relativement égale
- Les top clients représentent une part importante du CA
- À adapter: stratégie de fidélisation vs. acquisition

CONCLUSION SUR CERTAINS CLIENTS. LECTURE DE LA COURBE DE LORENZ

OBSERVATION ... La courbe présente un décrochement quasi-vertical sur les derniers pourcents en abscisse.

IDENTIFICATION ... Ce coude correspond aux 4 clients BtoB :
~0,05 % des clients captent 7 % du CA total.

CONCLUSION ... Ces 4 clients constituent une population atypique aux volumes d'achat hors-norme ($\times 140$ vs moyenne). Ils expliquent l'essentiel du Gini (0,442).

- CONSEQUENCES ... • Fidélisation critique (exposition concentrée).
- Exclusion justifiée du notebook de corrélations (outliers statistiques).
 - Base BtoC équilibrée : potentiel d'up-sell.

3.5.1 Analyse Pareto Clients

```
[26]: # === 3.5.1 Analyse Pareto Clients (règle 80/20) ===
# Complément de la courbe de Lorenz : identifie le % de clients
# nécessaire pour atteindre 80% du CA.

# CA par client (trié décroissant)
ca_par_client = data.groupby('client_id')['montant'].sum()
ca_par_client = ca_par_client.sort_values(ascending=False).reset_index()
ca_par_client.columns = ['client_id', 'ca']

# Calcul cumulatif
ca_total = ca_par_client['ca'].sum()
ca_par_client['ca_cumul'] = ca_par_client['ca'].cumsum()
ca_par_client['ca_cumul_pct'] = ca_par_client['ca_cumul'] / ca_total * 100
ca_par_client['client_rank'] = range(1, len(ca_par_client) + 1)
ca_par_client['client_pct'] = ca_par_client['client_rank'] / len(ca_par_client)
    ↪ * 100

# Point 80%
seuil_80 = ca_par_client[ca_par_client['ca_cumul_pct'] >= 80].iloc[0]

# Déciles
n = len(ca_par_client)
for pct in [1, 5, 10, 20, 50]:
    nb = int(n * pct / 100)
    ca_pct = ca_par_client.head(nb)['ca'].sum() / ca_total * 100
    print(f'Top {pct}% ({nb} clients) = {ca_pct:.1f}% du CA')

# --- Graphique Pareto Clients ---
fig, ax1 = plt.subplots(figsize=(12, 6))

ax1.fill_between(ca_par_client['client_pct'],
                 ca_par_client['ca_cumul_pct'],
                 alpha=0.3, color='steelblue')
ax1.plot(ca_par_client['client_pct'],
         ca_par_client['ca_cumul_pct'],
         color='steelblue', linewidth=2.5, label='% CA cumulé')

# Ligne 80%
ax1.axhline(y=80, color='#E67E22', linestyle='--', linewidth=2, label='Seuil_
    ↪ 80%')
```

```

ax1.axvline(x=seuil_80['client_pct'], color='#E67E22',
            linestyle='--', alpha=0.7)
# Diagonale (distribution égale)
ax1.plot([0, 100], [0, 100], 'k--', alpha=0.3, label='Égalité parfaite')

# Annotation
ax1.annotate(f'{seuil_80["client_pct"]:.0f}% des clients\n= 80% du CA',
            xy=(seuil_80['client_pct'], 80),
            xytext=(seuil_80['client_pct'] + 10, 65),
            fontsize=12, fontweight='bold', color='#E67E22',
            arrowprops=dict(arrowstyle='->', color='#E67E22', lw=2))


# Marquer les 4 BtoB
btob_pct = 4 / n * 100
btob_ca_pct = ca_par_client.head(4)['ca'].sum() / ca_total * 100
ax1.plot(btob_pct, btob_ca_pct, 'rv', markersize=12,
        label=f'4 BtoB = {btob_ca_pct:.1f}% du CA')

ax1.set_xlabel('% des clients (triés par CA décroissant)', fontweight='bold')
ax1.set_ylabel('% du CA cumulé', fontweight='bold')
ax1.set_title('Analyse Pareto Clients \u2013 Répartition du CA',
            fontsize=14, fontweight='bold')
ax1.legend(loc='lower right')
ax1.grid(True, alpha=0.3)
ax1.set_xlim(0, 100)
ax1.set_ylim(0, 105)
plt.tight_layout()
plt.show()

print("\nInterprétation:")
print(f"- {seuil_80['client_pct']:.0f}% des clients génèrent 80% du CA")
print("- La concentration clients est modérée (cohérent avec le Gini de 0.44)")
print("- Les 4 BtoB sont marqués en rouge : faible % de clients mais impact_
↳significatif")

```

Top 1% (86 clients) = 10.5% du CA
 Top 5% (430 clients) = 21.0% du CA
 Top 10% (860 clients) = 31.6% du CA
 Top 20% (1720 clients) = 48.1% du CA
 Top 50% (4300 clients) = 79.7% du CA



Interprétation:

- 50% des clients génèrent 80% du CA
- La concentration clients est modérée (cohérent avec le Gini de 0.44)
- Les 4 BtoB sont marqués en rouge : faible % de clients mais impact significatif

Etape 4 - Conclusion

2 CONCLUSION

Cette analyse des ventes de la librairie révèle plusieurs enseignements clés :

Performance globale : Le CA total s'élève à environ 12M€ sur la période, avec un panier moyen stable et une base de ~8 600 clients uniques.

Tendances temporelles : Les moyennes mobiles montrent une tendance globalement stable avec des variations saisonnières modérées. Les KPIs opérationnels (clients, transactions, produits) sont relativement constants d'un mois sur l'autre.

Concentration des ventes : L'analyse Pareto confirme que 20% des produits génèrent environ 80% du CA. Le coefficient de Gini indique une concentration modérée des achats parmi les clients.

Clients BtoB : Les 4 clients identifiés (c_1609, c_4958, c_6714, c_3454) représentent ~7.4% du CA total (884 296€) malgré leur faible nombre. Leur profil se caractérise par un volume d'achat et un panier moyen nettement supérieurs à la médiane.

Recommandations : - Fidéliser les clients BtoB avec un suivi commercial dédié - Optimiser le catalogue en se concentrant sur les produits à forte rotation - Mettre en place des actions pour augmenter la fréquence d'achat des clients BtoC