

Lippens_Charles_2_notebook_analyse_corrélations_052026

May 7, 2026

Analysez les ventes d'une librairie avec Python: analyses de corrélations et tests statistiques

1 OBJECTIF DE CE NOTEBOOK

Ce notebook a pour objectif de **réaliser les analyses de corrélations et tests statistiques** demandés par Julie, responsable Marketing de la librairie Lapage.

Contexte : à partir des données de transactions, clients et produits, nous cherchons à identifier les liens entre le profil des clients (genre, âge) et leur comportement d'achat (catégories, montant, fréquence, panier moyen).

Les 5 corrélations analysées : 1. Genre vs Catégorie de livres achetés (Quali $\times$ Quali : Chi2) 2. Âge vs Montant total des achats (Quanti $\times$ Quanti : Spearman) 3. Âge vs Fréquence d'achat (Quanti $\times$ Quanti : Spearman) 4. Âge vs Panier moyen (Quanti $\times$ Quanti : Spearman) 5. Âge vs Catégorie de livres achetés (Quanti $\times$ Quali : Kruskal-Wallis)

Démarche : pour chaque corrélation, nous suivons une méthodologie en 6 étapes : identification des variables, formulation des hypothèses H0/H1, tests préalables (normalité, homoscédasticité), choix du test adapté, comparaison de la p-value au seuil $= 0.05$, et interprétation avec taille d'effet.

Note : les 4 clients BtoB (atypiques) ont été exclus de toutes les analyses.

Etape 1 - Importation des librairies et chargement des données

1.1 - Imports: importation des librairies

```
[1]: # --- Librairies ---
import pandas as pd          # Manipulation et analyse de DataFrames
import numpy as np           # Calculs numériques et tableaux
import matplotlib.pyplot as plt # Création de graphiques
import seaborn as sns        # Visualisations statistiques avancées (heatmaps,
    ↪ violin plots, etc.)

# --- Tests statistiques (scipy) ---
from scipy import stats
from scipy.stats import chi2_contingency # Test Chi2 d'indépendance (quali ×
    ↪ quali)
from scipy.stats import pearsonr, spearmanr # Corrélations linéaire et
    ↪ monotone (quanti × quanti)
```

```

from scipy.stats import shapiro          # Test de normalité Shapiro-Wilk (n < 5000)
from scipy.stats import normaltest        # Test de normalité D'Agostino-Pearson (tout n)
from scipy.stats import levene            # Test d'homogénéité des variances
from scipy.stats import f_oneway, kruskal # ANOVA et Kruskal-Wallis (comparaison de groupes)

import warnings
warnings.filterwarnings('ignore')

```

1.2 - Chargement et nettoyage

Note : Les variables dérivées (age, montant, categorie_nom, sexe_nom) sont créées de manière identique au notebook d'analyse des ventes pour assurer la cohérence entre les deux analyses. Le nommage des catégories (Cat. 0 - Essais, Cat. 1 - Romans, Cat. 2 - Jeunesse) est une hypothèse basée sur le profil statistique des données (voir justification dans le notebook ventes, section 2.7).

```

[2]: # Chargement identique au Notebook 1
transactions = pd.read_csv('Transactions.csv', sep=';')
transactions = transactions.dropna(how='all')
customers = pd.read_csv('customers.csv', sep=';')
products = pd.read_csv('products.csv', sep=';')

# Preparation des dates et age
transactions['date'] = pd.to_datetime(transactions['date'])
annee_ref = transactions['date'].dt.year.max()
customers['age'] = annee_ref - customers['birth']

# Fusion
data = transactions.merge(products, on='id_prod', how='left')
data = data.merge(customers, on='client_id', how='left')

# --- Variables dérivées ---
data['montant'] = data['price']

# Les données brutes ne fournissent que des codes numériques (categ = 0, 1, 2).
# Aucun dictionnaire de données n'associe explicitement un nom à chaque catégorie.
# Nommage basé sur le profil statistique des catégories :
# - categ 0 : "Essais" (prix moyen ~10€, volume très élevé)
# - categ 1 : "Romans" (prix moyen ~20€, volume élevé)
# - categ 2 : "Jeunesse" (prix moyen ~76€, volume faible, typique de beaux livres)
# Les préfixes des id_prod (0_, 1_, 2_) confirment la correspondance.
categorie_map = {0: 'Cat. 0 - Essais', 1: 'Cat. 1 - Romans', 2: 'Cat. 2 - Jeunesse'}

```

```
data['categorie_nom'] = data['categ'].map(categorie_map)
data['sexe_nom'] = data['sex'].map({'f': 'Femme', 'm': 'Homme'})
```

1.3 - Exclusion des quatre clients BtoB

```
[3]: # Identifier les 4 clients BtoB (top CA)
ca_par_client = data.groupby('client_id')['montant'].sum()
btob_ids = ca_par_client.nlargest(4).index.tolist()

print(f"Clients BtoB exclus : {btob_ids}")
print(f"Avant exclusion : {len(data)} transactions, {data['client_id'].
      ↪nunique()} clients")

# Exclusion
data = data[~data['client_id'].isin(btob_ids)]

print(f"Après exclusion : {len(data)} transactions, {data['client_id'].
      ↪nunique()} clients")
print(f"Clients BtoB restants : {data[data['client_id'].isin(btob_ids)].
      ↪shape[0]}") # = 0
```

Clients BtoB exclus : ['c_1609', 'c_4958', 'c_6714', 'c_3454']

Avant exclusion : 687534 transactions, 8600 clients

Après exclusion : 640734 transactions, 8596 clients

Clients BtoB restants : 0

1.4 - Construction du DataFrame d'analyse par client

```
[4]: # Agreger au niveau client
df_clients = data.groupby('client_id').agg(
    age=('age', 'first'),           # Age du client
    sexe=('sex', 'first'),          # Genre
    sexe_nom=('sexe_nom', 'first'), # Genre en clair
    ca_total=('montant', 'sum'),    # CA total
    nb_transactions=('session_id', 'nunique'), # Frequence d'achat (nb
    ↪sessions)
    nb_articles=('id_prod', 'count'), # Nb articles achetes
    nb_categories=('categ', 'nunique'), # Nb categories differentes
).reset_index()

# Panier moyen = CA total / nombre de sessions
df_clients['panier_moyen'] = df_clients['ca_total'] /
    ↪df_clients['nb_transactions']

# Categorie preferee (celle avec le plus d'achats)
categ_pref = data.groupby(['client_id', 'categorie_nom'])['montant'].count()
categ_pref = categ_pref.reset_index().sort_values(['client_id', 'montant'],
    ↪ascending=[True, False])
```

```

categ_pref = categ_pref.drop_duplicates(subset='client_id', keep='first')
df_clients = df_clients.merge(categ_pref[['client_id', 'categorie_nom']],
    ↪ on='client_id', how='left')
df_clients.rename(columns={'categorie_nom': 'categorie_preferee'}, inplace=True)

print(f"DataFrame clients : {df_clients.shape}")
print(df_clients.head())

```

DataFrame clients : (8596, 10)

	client_id	age	sexe	sexe_nom	ca_total	nb_transactions	nb_articles	\
0	c_1	68	m	Homme	629.02	34	43	
1	c_10	67	m	Homme	1353.60	34	58	
2	c_100	31	m	Homme	254.85	5	8	
3	c_1000	57	f	Femme	2291.88	94	126	
4	c_1001	41	m	Homme	1823.85	47	103	

	nb_categories	panier_moyen	categorie_preferee
0	3	18.500588	Cat. 0 - Essais
1	3	39.811765	Cat. 1 - Romans
2	3	50.970000	Cat. 1 - Romans
3	2	24.381702	Cat. 1 - Romans
4	3	38.805319	Cat. 0 - Essais

Etape 2 - Tests préalables généraux

2.1 - Test de normalité - Shapiro-Wilk

```

[5]: # Shapiro-Wilk sur les variables continues
# ATTENTION : Shapiro est fiable pour n < 5000. Pour les gros echantillons,
# utiliser un sous-echantillon ou le test de D'Agostino-Pearson (normaltest)

variables_continues = ['age', 'ca_total', 'nb_transactions', 'panier_moyen']

for var in variables_continues:
    # Sous-echantillon si trop de donnees
    sample = df_clients[var].dropna()
    if len(sample) > 5000:
        sample = sample.sample(5000, random_state=42)

    stat, p_val = shapiro(sample)
    normal = "OUI (normalite acceptable)" if p_val > 0.05 else "NON -> test_
    ↪ non-parametrique"
    print(f"{var:20s} : W={stat:.4f}, p={p_val:.6f} -> Normalite : {normal}")

# Visualisation : histogramme + QQ-plot pour chaque variable
fig, axes = plt.subplots(len(variables_continues), 2, figsize=(14,
    ↪ 4*len(variables_continues)))
for i, var in enumerate(variables_continues):

```

```


data_var = df_clients[var].dropna()
axes[i, 0].hist(data_var, bins=50, edgecolor='black', alpha=0.7,
↳density=True)
# Courbe gaussienne théorique
mu, sigma = data_var.mean(), data_var.std()
x = np.linspace(data_var.min(), data_var.max(), 200)
axes[i, 0].plot(x, stats.norm.pdf(x, mu, sigma), 'r-', linewidth=2,
↳label='Gaussienne')
axes[i, 0].legend()
axes[i, 0].set_title(f'Distribution de {var}')
stats.probplot(df_clients[var], dist="norm", plot=axes[i, 1])
axes[i, 1].set_title(f'QQ-Plot de {var}')
plt.tight_layout()
plt.show()
print("\nInterprétation: Les distributions s'écartent de la normalité (attendu
↳avec n > 8000).")
print("Utilisation de tests non-paramétriques (Spearman, Kruskal-Wallis) pour
↳les corrélations.")

```

```

age                : W=0.9700, p=0.000000 -> Normalite : NON -> test non-
parametrique
ca_total           : W=0.9061, p=0.000000 -> Normalite : NON -> test non-
parametrique
nb_transactions    : W=0.8577, p=0.000000 -> Normalite : NON -> test non-
parametrique
panier_moyen       : W=0.8126, p=0.000000 -> Normalite : NON -> test non-
parametrique

```



Interprétation: Les distributions s'écartent de la normalité (attendu avec $n > 8000$).

Utilisation de tests non-paramétriques (Spearman, Kruskal-Wallis) pour les corrélations.

2.2 - Test de normalité - Test D'Agostino-Pearson

```
[6]: print("\n--- Confirmation avec D'Agostino-Pearson (sur toutes les données) ---")
for var in variables_continues:
    stat_dag, p_dag = normaltest(df_clients[var].dropna())
    normal = "OUI" if p_dag > 0.05 else "NON -> test non-parametrique"
    print(f"{var:20s} : K2={stat_dag:.4f}, p={p_dag:.6f} -> Normalite : ␣
    ↪{normal}")
```

```
--- Confirmation avec D'Agostino-Pearson (sur toutes les données) ---
age : K2=504.2383, p=0.000000 -> Normalite : NON -> test non-
parametrique
ca_total : K2=1455.2480, p=0.000000 -> Normalite : NON -> test non-
parametrique
nb_transactions : K2=1815.6963, p=0.000000 -> Normalite : NON -> test non-
parametrique
panier_moyen : K2=3458.1140, p=0.000000 -> Normalite : NON -> test non-
parametrique
```

2.3 - Test d'homogénéité des variances - Levene (pour corrélation 5 uniquement: Âge vs Catégorie de livres achetés)

```
[7]: # Levene : egalite des variances de l'age entre les 3 categories
groupes_age = [df_clients[df_clients['categorie_preferee']==cat]['age']
               for cat in df_clients['categorie_preferee'].unique()]
stat_lev, p_lev = levene(*groupes_age)
print(f"Levene : F={stat_lev:.4f}, p={p_lev:.6f}")
if p_lev > 0.05:
    print("Variances homogenes : ANOVA possible")
else:
    print("Variances heterogenes : Utilisation de Kruskal-Wallis (ou Welch si ␣
    ↪comparaison de 2 groupes)")
```

```
Levene : F=707.9505, p=0.000000
Variances heterogenes : Utilisation de Kruskal-Wallis (ou Welch si comparaison
de 2 groupes)
```

Etape 3 - Les 5 corrélations de Julie

3.1 - Genre vs Categories de livres achetes

Hypothèses:

H0 : Le genre et la catégorie de livres achetés sont indépendants

H1 : Il existe un lien significatif entre le genre et la catégorie

3.1.1 - Transformation des données

```
[8]: # Tableau de contingence : effectifs observes
tableau_contingence = pd.crosstab(data['sexe_nom'], data['categorie_nom'])
print("Tableau de contingence :")
print(tableau_contingence)
```

```
print(f"\nTotal : {tableau_contingence.sum().sum()} transactions")
```

Tableau de contingence :

categorie_nom	Cat. 0 - Essais	Cat. 1 - Romans	Cat. 2 - Jeunesse
sexe_nom			
Femme	200793	115721	16980
Homme	186488	104884	15868

Total : 640734 transactions

3.1.2 - Test Chi2 d'indépendance

```
[9]: # --- Test Chi2 d'indépendance ---
# Choix du test : le Chi2 est le test approprié pour mesurer l'association
# entre deux variables qualitatives (ici sexe et catégorie de livres).
# Il compare les fréquences observées aux fréquences théoriques attendues
# sous l'hypothèse d'indépendance (H0).
chi2, p_value, dof, expected = chi2_contingency(tableau_contingence)

print(" " * 60)
print("Test du Chi² d'indépendance. Sexe × Catégorie")
print(" " * 60)
print(f"  Chi²          = {chi2:.4f}")
print(f"  p-value         = {p_value:.6f}")
print(f"  Degrés de liberté = {dof}    "
      f"[(n_lignes-1)×(n_colonnes-1) = ({tableau_contingence.
↪shape[0]}-1)×({tableau_contingence.shape[1]}-1)]")
print(" " * 60)

if p_value < 0.05:
    print(f"  Conclusion : on rejette H0 (p = {p_value:.6f} < 0,05)")
    print(f"  Il existe un lien significatif entre le sexe et la catégorie.")
else:
    print(f"  Conclusion : on ne rejette pas H0 (p = {p_value:.6f} > 0,05)")
    print(f"  Pas de lien significatif.")
print(" " * 60)
```

Test du Chi² d'indépendance. Sexe × Catégorie

Chi² = 22.6686
p-value = 0.000012
Degrés de liberté = 2 [(n_lignes-1)×(n_colonnes-1) = (2-1)×(3-1)]

Conclusion : on rejette H0 (p = 0.000012 < 0,05)
Il existe un lien significatif entre le sexe et la catégorie.


3.1.3 - Graphique bivarié Chi2

```
[10]: # Graphique bivarie : barplot empile ou groupe
fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# Barplot groupe
cross_pct = pd.crosstab(data['sexe_nom'], data['categorie_nom'],
    ↪normalize='index') * 100
cross_pct.plot(kind='bar', ax=axes[0], colormap='Set2', edgecolor='black')
axes[0].set_title('Repartition des categories par genre (%)', fontweight='bold')
axes[0].set_ylabel('Pourcentage (%)')
axes[0].set_xlabel('Genre')
axes[0].legend(title='Categorie')
plt.setp(axes[0].xaxis.get_majorticklabels(), rotation=0)

# Heatmap des residus standardises
residus = (tableau_contingence.values - expected) / np.sqrt(expected)
sns.heatmap(pd.DataFrame(residus, index=tableau_contingence.index,
    columns=tableau_contingence.columns),
    annot=True, fmt='.2f', cmap='RdBu_r', center=0, ax=axes[1])
axes[1].set_title('Residus standardises du Chi2', fontweight='bold')

plt.tight_layout()
plt.show()
print("\nInterprétation: Les barres sont quasi-identiques entre H et F : pas de
    ↪différence visible.")
print("Les résidus standardisés sont très faibles : le lien genre-catégorie est
    ↪négligeable.")
```



Interprétation: Les barres sont quasi-identiques entre H et F : pas de différence visible.

Les résidus standardisés sont très faibles : le lien genre-catégorie est

négligeable.

3.1.4 - V de Cramér

```
[11]: # Taille d'effet : V de Cramer
n = tableau_contingence.sum().sum()
k = min(tableau_contingence.shape) - 1
v_cramer = np.sqrt(chi2 / (n * k))
print(f"V de Cramer = {v_cramer:.4f}")

# Interprétation de la taille d'effet
if v_cramer < 0.1: force = "négligeable"
elif v_cramer < 0.3: force = "faible"
elif v_cramer < 0.5: force = "modérée"
else: force = "forte"
print(f"Taille d'effet : {force}")
print("Le lien est statistiquement significatif mais pratiquement négligeable.")
```

V de Cramer = 0.0059

Taille d'effet : négligeable

Le lien est statistiquement significatif mais pratiquement négligeable.

3.2 - Age vs Montant total des achats

Hypothèses:

H0 : Il n'existe pas de corrélation entre l'âge et le montant total des achats

H1 : Il existe une corrélation significative entre l'âge et le CA total

3.2.1 - Calcul et comparaison des coefficients Pearson et Spearman

```
[12]: # Pearson
r_pearson, p_pearson = pearsonr(df_clients['age'], df_clients['ca_total'])
print(f"Pearson : r = {r_pearson:.4f}, p-value = {p_pearson:.6f}")

# Spearman
r_spearman, p_spearman = spearmanr(df_clients['age'], df_clients['ca_total'])
print(f"Spearman : rho = {r_spearman:.4f}, p-value = {p_spearman:.6f}")

# Interpretation
print(f"\nInterpretation :")
r = r_spearman # Privilégier Spearman si normalité non vérifiée
if abs(r) < 0.1: print("Correlation négligeable")
elif abs(r) < 0.3: print("Correlation faible")
elif abs(r) < 0.5: print("Correlation modérée")
elif abs(r) < 0.7: print("Correlation forte")
else: print("Correlation très forte")

# Conclusion : Shapiro a rejeté la normalité pour les deux variables
# -> On privilégie le coefficient de Spearman (non-paramétrique)
```

```
print(f"\nConclusion : Normalité rejetée (cf. Shapiro Etape 2)")
print(f"On retient Spearman : rho = {r_spearman:.4f}, p = {p_spearman:.6f}")
```


Pearson : r = -0.1876, p-value = 0.000000
 Spearman : rho = -0.1845, p-value = 0.000000

Interpretation :
 Correlation faible

Conclusion : Normalité rejetée (cf. Shapiro Etape 2)
 On retient Spearman : rho = -0.1845, p = 0.000000

3.2.2 - Graphique bivarié

```
[13]: fig, ax = plt.subplots(figsize=(10, 7))
ax.scatter(df_clients['age'], df_clients['ca_total'], alpha=0.3, s=10,
           color='steelblue')
# Ligne de tendance
z = np.polyfit(df_clients['age'], df_clients['ca_total'], 1)
poly = np.poly1d(z)
x_line = np.linspace(df_clients['age'].min(), df_clients['age'].max(), 100)
ax.plot(x_line, poly(x_line), color='red', linewidth=2, label=f'Tendance
           (r={r_pearson:.3f})')
ax.set_title('Age vs CA Total des Achats', fontsize=14, fontweight='bold')
ax.set_xlabel('Age')
ax.set_ylabel('CA Total (euros)')
ax.legend()
ax.annotate(f'Pearson r={r_pearson:.4f} (p={p_pearson:.4f})\nSpearman
           rho={r_spearman:.4f} (p={p_spearman:.4f})',
           xy=(0.02, 0.95), xycoords='axes fraction', fontsize=10,
           bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.8), va='top')
plt.show()
print("\nInterprétation: Le nuage est très dispersé avec une légère pente
           négative.")
print("Corrélation faible confirmée visuellement.")
```



Interprétation: Le nuage est très dispersé avec une légère pente négative. Corrélation faible confirmée visuellement.

3.3 - Age vs Frequence d'achat

Hypothèses:

H0 : Il n'existe pas de corrélation entre l'âge et la fréquence d'achat

H1 : Il existe une corrélation significative entre l'âge et la fréquence

3.3.1 - Calcul et comparaison des coefficients Pearson et Spearman

```
[14]: r_p, p_p = pearsonr(df_clients['age'], df_clients['nb_transactions'])
r_s3, p_s3 = spearmanr(df_clients['age'], df_clients['nb_transactions'])
print(f"Pearson : r = {r_p:.4f}, p = {p_p:.6f}")
print(f"Spearman : rho = {r_s3:.4f}, p = {p_s3:.6f}")

print(f"\nInterprétation :")
r = r_s3 # Spearman privilégié
if abs(r) < 0.1: print("Corrélation négligeable")
elif abs(r) < 0.3: print("Corrélation faible")
elif abs(r) < 0.5: print("Corrélation modérée")
```

```

elif abs(r) < 0.7: print("Corrélation forte")
else: print("Corrélation très forte")

# Conclusion : Shapiro a rejeté la normalité pour les deux variables
# -> On privilégie le coefficient de Spearman (non-paramétrique)
print(f"\nConclusion : Normalité rejetée (cf. Shapiro Etape 2)")
print(f"On retient Spearman : rho = {r_s3:.4f}, p = {p_s3:.6f}")

```

Pearson : r = 0.1645, p = 0.000000
Spearman : rho = 0.2120, p = 0.000000

Interprétation :
Corrélation faible


Conclusion : Normalité rejetée (cf. Shapiro Etape 2)
On retient Spearman : rho = 0.2120, p = 0.000000

3.3.2 - Graphiques bivariés

```

[15]: # Graphique bivarié : Âge vs Fréquence d'achat (scatter + ligne de tendance)
fig, ax = plt.subplots(figsize=(10, 7))
ax.scatter(df_clients['age'], df_clients['nb_transactions'], alpha=0.3, s=10,
           color='#2ca02c')
z = np.polyfit(df_clients['age'], df_clients['nb_transactions'], 1)
poly = np.poly1d(z)
x_line = np.linspace(df_clients['age'].min(), df_clients['age'].max(), 100)
ax.plot(x_line, poly(x_line), color='red', linewidth=2, label=f'Tendance
           (r={r_p:.3f})')
ax.set_title('Age vs Frequence d\'achat (nb sessions)', fontsize=14,
           fontweight='bold')
ax.set_xlabel('Age')
ax.set_ylabel('Nombre de sessions')
ax.legend()
ax.annotate(f'Pearson r={r_p:.4f}\nSpearman rho={r_s3:.4f}',
           xy=(0.02, 0.95), xycoords='axes fraction', fontsize=10,
           bbox=dict(boxstyle='round', facecolor='lightgreen', alpha=0.8),
           va='top')
plt.show()
print("\nInterprétation: Légère tendance positive visible malgré une forte
           dispersion.")


```



Interprétation: Légère tendance positive visible malgré une forte dispersion.

```
[16]: # Créer les tranches d'âge
df_clients['tranche_age'] = pd.cut(df_clients['age'],
    bins=[19, 29, 39, 49, 59, 69, 100],
    labels=['20-29', '30-39', '40-49', '50-59', '60-69', '+ de 70'])

# Graphique bivarié : Âge vs Fréquence d'achat (scatter + ligne de tendance)
# Boxplot
fig, ax = plt.subplots(figsize=(10, 6))
sns.boxplot(x='tranche_age', y='nb_transactions', data=df_clients,
    palette='Set2', ax=ax)
ax.set_title('Distribution de la fréquence d\'achat par tranche d\'âge',
    fontweight='bold')
ax.set_xlabel('Tranche d\'âge')
ax.set_ylabel('Nombre de sessions')
plt.show()
print("\nInterprétation: Les tranches d'âge 50+ montrent une fréquence médiane_
    ↳ légèrement plus élevée.")
```



Interprétation: Les tranches d'âge 50+ montrent une fréquence médiane légèrement plus élevée.

3.4 - Age vs Taille du panier moyen

Hypothèses:

H0 : Il n'existe pas de corrélation entre l'âge et le panier moyen

H1 : Il existe une corrélation significative entre l'âge et le panier moyen

3.4.1 - Calcul et comparaison des coefficients Pearson et Spearman

```
[17]: r_p, p_p = pearsonr(df_clients['age'], df_clients['panier_moyen'])
r_s4, p_s4 = spearmanr(df_clients['age'], df_clients['panier_moyen'])
print(f"Pearson : r = {r_p:.4f}, p = {p_p:.6f}")
print(f"Spearman : rho = {r_s4:.4f}, p = {p_s4:.6f}")

print(f"\nInterprétation :")
r = r_s4 # Spearman privilégié
if abs(r) < 0.1: print("Corrélation négligeable")
elif abs(r) < 0.3: print("Corrélation faible")
elif abs(r) < 0.5: print("Corrélation modérée")
elif abs(r) < 0.7: print("Corrélation forte")
else: print("Corrélation très forte")
```

```
# Conclusion : Shapiro a rejeté la normalité pour les deux variables
# -> On privilégie le coefficient de Spearman (non-paramétrique)
print(f"\nConclusion : Normalité rejetée (cf. Shapiro Etape 2)")
print(f"On retient Spearman : rho = {r_s4:.4f}, p = {p_s4:.6f}")
```

```
Pearson : r = -0.6165, p = 0.000000
Spearman : rho = -0.7006, p = 0.000000
```

Interprétation :
Corrélation très forte

```
Conclusion : Normalité rejetée (cf. Shapiro Etape 2)
On retient Spearman : rho = -0.7006, p = 0.000000
```


1.0.1 Résultat : la corrélation Âge vs Panier moyen

C'est la corrélation la plus forte de l'étude ($\rho = -0.70$, forte). Les clients jeunes (< 35 ans) ont un panier moyen nettement plus élevé.

Recommandation métier : Julie pourrait cibler les jeunes clients avec des offres de fidélisation ou de cross-selling, car ils dépensent davantage par session d'achat.

3.4.2 - Graphique bivarié

```
[18]: # Graphique bivarié : Âge vs Panier moyen (scatter + ligne de tendance)
fig, ax = plt.subplots(figsize=(10, 7))
ax.scatter(df_clients['age'], df_clients['panier_moyen'], alpha=0.3, s=10,
           color='#ff7f0e')
z = np.polyfit(df_clients['age'], df_clients['panier_moyen'], 1)
poly = np.poly1d(z)
x_line = np.linspace(df_clients['age'].min(), df_clients['age'].max(), 100)
ax.plot(x_line, poly(x_line), color='red', linewidth=2, label=f'Tendance
      (r={r_p:.3f})')
ax.set_title('Age vs Panier Moyen', fontsize=14, fontweight='bold')
ax.set_xlabel('Age')
ax.set_ylabel('Panier moyen (euros)')
ax.legend()
ax.annotate(f'Pearson r={r_p:.4f}\nSpearman rho={r_s4:.4f}',
            xy=(0.02, 0.95), xycoords='axes fraction', fontsize=10,
            bbox=dict(boxstyle='round', facecolor='lightyellow', alpha=0.8),
            va='top')
plt.show()
print("\nInterprétation: Tendance négative nette. les jeunes ont un panier
      moyen plus élevé.")
print("C'est la corrélation la plus forte de l'analyse (rho -0.70).")
```



Interprétation: Tendance négative nette. les jeunes ont un panier moyen plus élevé.

C'est la corrélation la plus forte de l'analyse (rho -0.70).

3.5 - Age vs Categorie de livres achetes

Hypothèses:

H0 : L'âge moyen est identique entre les catégories de livres

H1 : L'âge moyen diffère significativement selon la catégorie

3.5.1 - Tests préalables (normalité, homogénéité de la variance), ANOVA et alternative

```
[19]: # Définir les groupes : age des clients selon leur categorie preferee
groupes = {}
for cat in df_clients['categorie_preferee'].unique():
    groupes[cat] = df_clients[df_clients['categorie_preferee']==cat]['age'].
    ↪values

# --- Test prealable 1 : Normalite (Shapiro-Wilk par groupe) ---
print("=== NORMALITE (Shapiro-Wilk) ===")
normalite_ok = True
```

```

for cat, ages in groupes.items():
    sample = ages if len(ages) <= 5000 else np.random.choice(ages, 5000,
↪replace=False)
    stat, pval = shapiro(sample)
    ok = "OK" if pval > 0.05 else "REJETE"
    if pval <= 0.05: normalite_ok = False
    print(f" {cat:10s} : W={stat:.4f}, p={pval:.6f} -> {ok}")

# --- Test prealable 2 : Homogénéité des variances (Levene) ---
print("\n=== HOMOSCEDASTICITE (Levene) ===")
stat_l, p_l = levene(*groupes.values())
homo_ok = p_l > 0.05
print(f" Levene : F={stat_l:.4f}, p={p_l:.6f} -> {'OK' if homo_ok else
↪'REJETE'}")

# --- Decision ---
print("\n=== DECISION ===")
stat_k = None; p_k = None
stat_a = None; p_a = None
if normalite_ok and homo_ok:
    print("Conditions remplies -> ANOVA")
    stat_a, p_a = f_oneway(*groupes.values())
    print(f"ANOVA : F={stat_a:.4f}, p-value={p_a:.6f}")
    test_utilise = "ANOVA"
    p_final = p_a
else:
    print("Conditions NON remplies -> Kruskal-Wallis (non-parametrique)")
    stat_k, p_k = kruskal(*groupes.values())
    print(f"Kruskal-Wallis : H={stat_k:.4f}, p-value={p_k:.6f}")
    test_utilise = "Kruskal-Wallis"
    p_final = p_k

# --- Conclusion ---
if p_final < 0.05:
    print(f"\nConclusion ({test_utilise}) : p={p_final:.6f} < 0.05")
    print("On rejette H0 : l'age moyen differe significativement entre les
↪categories.")
else:
    print(f"\nConclusion ({test_utilise}) : p={p_final:.6f} > 0.05")
    print("On ne rejette pas H0 : pas de difference significative d'age entre
↪les categories.")

```

```

=== NORMALITE (Shapiro-Wilk) ===
Cat. 0 - Essais : W=0.9552, p=0.000000 -> REJETE
Cat. 1 - Romans : W=0.9101, p=0.000000 -> REJETE
Cat. 2 - Jeunesse : W=0.8766, p=0.000000 -> REJETE

```

=== HOMOSCEDASTICITE (Levene) ===

Levene : F=707.9505, p=0.000000 -> REJETE

=== DECISION ===

Conditions NON remplies -> Kruskal-Wallis (non-parametrique)

Kruskal-Wallis : H=2003.6681, p-value=0.000000

Conclusion (Kruskal-Wallis) : $p=0.000000 < 0.05$

On rejette H_0 : l'age moyen differe significativement entre les categories.


3.5.2 - Graphique bivarié

```
[20]: fig, axes = plt.subplots(1, 2, figsize=(14, 7))

# Boxplot
sns.boxplot(x='categorie_preferee', y='age', data=df_clients, ax=axes[0],
            palette='Set2', order=['Cat. 0 - Essais', 'Cat. 1 - Romans', 'Cat. 2 - Jeunesse'])
axes[0].set_title(f'Distribution de l\'age par categorie\n({test_utilise}, p={p_final:.4f})',
                 fontweight='bold')
axes[0].set_xlabel('Categorie preferee')
axes[0].set_ylabel('Age')

# Violinplot (plus informatif que le boxplot)
sns.violinplot(x='categorie_preferee', y='age', data=df_clients, ax=axes[1],
              palette='Set2', order=['Cat. 0 - Essais', 'Cat. 1 - Romans', 'Cat. 2 - Jeunesse'], inner='quartile')
axes[1].set_title('Distribution de l\'age par categorie (violin)',
                 fontweight='bold')
axes[1].set_xlabel('Categorie preferee')
axes[1].set_ylabel('Age')

plt.tight_layout()
plt.show()
print("\nInterprétation:")
print("- Les distributions d'âge diffèrent nettement entre catégories")
print("- Les acheteurs de Cat. 2 - Jeunesse sont en moyenne plus jeunes")
print("- Le violin plot confirme des formes de distribution distinctes par catégorie")
```



Interprétation:

- Les distributions d'âge diffèrent nettement entre catégories
- Les acheteurs de Cat. 2 - Jeunesse sont en moyenne plus jeunes
- Le violin plot confirme des formes de distribution distinctes par catégorie

3.5.3 - Taille d'effet: η^2

```
[21]: all_ages = np.concatenate(list(groupees.values()))
grand_mean = all_ages.mean()
ss_between = sum(len(g) * (g.mean() - grand_mean)**2 for g in groupees.values())
ss_total = sum((all_ages - grand_mean)**2)
eta2 = ss_between / ss_total
print(f"Eta carre = {eta2:.4f}")

# Interprétation de la taille d'effet
if eta2 < 0.01: force = "négligeable"
elif eta2 < 0.06: force = "faible"
elif eta2 < 0.14: force = "modérée"
else: force = "forte"
print(f"Taille d'effet : {force}")
print(f"{eta2*100:.1f}% de la variance de l'âge est expliquée par la catégorie.
↪")
```

Eta carre = 0.2186

Taille d'effet : forte

21.9% de la variance de l'âge est expliquée par la catégorie.

Etape 4 - Synthèse des résultats

4.1 - Tableau récapitulatif

```
[22]: # Tableau récapitulatif des 5 corrélations
recap = pd.DataFrame({
    'Corrélation': ['Genre vs Catégorie', 'Âge vs CA total',
                  'Âge vs Fréquence', 'Âge vs Panier moyen',
                  'Âge vs Catégorie'],
    'Type': ['Quali x Quali', 'Quanti x Quanti', 'Quanti x Quanti',
            'Quanti x Quanti', 'Quanti x Quali'],
    'Test': ['Chi2', 'Spearman', 'Spearman', 'Spearman', 'Kruskal-Wallis'],
    'Statistique': [chi2, r_spearman, r_s3, r_s4, stat_k],
    'p-value': [p_value, p_spearman, p_s3, p_s4, p_k],
    'Taille effet': ['V=0.006', 'rho=-0.18', 'rho=0.21',
                   'rho=-0.70', 'Eta²=0.24'],
    'Significatif': ['Oui', 'Oui', 'Oui', 'Oui', 'Oui'],
    'Force': ['Négligeable', 'Faible', 'Faible', 'Forte', 'Fort']
})
print(recap.to_string(index=False))
```

Corrélation	Type	Test	Statistique	p-value
Taille effet Significatif	Force			
Genre vs Catégorie	Quali x Quali	Chi2	22.668567	1.195593e-05
V=0.006	Oui Négligeable			
Âge vs CA total	Quanti x Quanti	Spearman	-0.184538	1.021291e-66
rho=-0.18	Oui Faible			
Âge vs Fréquence	Quanti x Quanti	Spearman	0.211964	6.629168e-88
rho=0.21	Oui Faible			
Âge vs Panier moyen	Quanti x Quanti	Spearman	-0.700551	0.000000e+00
rho=-0.70	Oui Forte			
Âge vs Catégorie	Quanti x Quali	Kruskal-Wallis	2003.668101	0.000000e+00
Eta²=0.24	Oui Fort			

4.2 - Conclusions métiers (recommandations pour Julie)

1.0.2 Synthèse pour Julie

Les 5 corrélations demandées ont toutes été testées. Voici les enseignements principaux :

- 1. Genre vs Catégorie** : le lien est statistiquement significatif mais négligeable ($V = 0.006$). Hommes et femmes achètent quasiment les mêmes catégories. Pas besoin de différencier l'offre par genre.
- 2. Âge vs CA total** : corrélation faible et négative ($\rho = -0.18$). Les clients plus âgés dépensent légèrement moins au total, mais l'effet est trop faible pour être actionnable.
- 3. Âge vs Fréquence d'achat** : corrélation faible et positive ($\rho = 0.21$). Les clients plus âgés achètent un peu plus souvent, mais là encore l'effet est modeste.
- 4. Âge vs Panier moyen** : corrélation forte et négative ($\rho = -0.70$). C'est le résultat clé : les jeunes clients dépensent nettement plus par session. Julie pourrait cibler les jeunes avec des offres de fidélisation pour capitaliser sur leur panier élevé.
- 5. Âge vs Catégorie** : différence significative et forte ($\text{Eta}^2 = 0.24$). L'âge influence fortement

la catégorie préférée. Cela permet de personnaliser les recommandations par tranche d'âge.

Note : ces analyses excluent les 4 clients BtoB qui auraient biaisé les résultats. Les recommandations sont des suggestions. la décision finale revient à l'équipe marketing.