

L A P A G E · C O M I T É D E D I R E C T I O N

Analysez les ventes d'une librairie avec Python

Deux ans de librairie en ligne:

Ce que les données nous racontent, et ce que j'en retiens pour la suite

Période · Mars 2021 : Février 2023 (24 mois)

Volume · 12,0 M€ de CA · 8 600 clients

Présenté par

Charles Lippens

Data Analyst - équipe Marketing

Lapage, c'est d'abord une histoire de livres

Plusieurs librairies physiques, une communauté de clients fidèles. Il y a deux ans, l'ouverture du site en ligne a été un pari, et le pari a tenu.

Aujourd'hui, Sylvain veut faire le point

« Faire le point global sur les indicateurs et chiffres clés, pour décider de la marche à suivre : créer des offres, adapter des prix, cibler une clientèle. »

Deux parties, une même finalité : comprendre pour décider

- **Côté produit : les indicateurs de vente**
- **Côté client : comportement en ligne, à comparer avec les librairies physiques (avec Julie)**

Les trois questions qui structurent la présentation

1

Où en est l'activité ?

Trajectoire, signaux forts et faibles

2

Qui sont nos clients en ligne ?

Profils, concentration, spécificités

3

Quoi faire concrètement ?

Offres, prix, cibles, priorités

12,0 M€

Chiffre d'affaires total

cumulé sur 24 mois

687 534

Transactions

environ 28 600 par mois

8 600

Clients uniques

dont 4 comptes professionnels

3 265

Produits distincts vendus

sur 3 catégories

17,49 €

Panier moyen par transaction


stable sur la période

1 399 €

CA moyen par client

mais distribution très inégale

Deux ordres de grandeur à retenir pour la suite : environ 500 K€ de CA par mois, environ 5 700 clients actifs par mois.



Lecture du graphique

MA 7 jours

Lisse les pics hebdomadaires, révèle le rythme de la semaine.

MA 30 jours

Montre la tendance de fond.


Ce que disent les courbes

CA moyen autour de 16 500 €/jour. La courbe bouge peu : l'activité est très régulière

À retenir

Un seul creux visible, en octobre 2021. Et on le retrouve, plus léger, un an plus tard : c'est saisonnier, pas structurel.

Une stabilité rare, et c'est elle qui pose question



501 K€

Moyenne mensuelle

+/- 4 %

Amplitude autour de la moyenne

457 : 536 K€

Min : Max sur 24 mois

79 K€

Écart maximum mensuel

Ce que ça veut dire de bien

Trésorerie prévisible, visibilité sur les coûts et les stocks.

Ce que ça veut dire de moins bien

Aucune croissance organique : nous sommes sur un plateau depuis 2 ans.



en moyenne / mois



en moyenne / mois



vendus / mois

6 / 22

Pourquoi cette hypothèse ?

Le jeu de données ne fournit pas de nom pour les catégories : on y lit uniquement `categ = 0, 1 ou 2`. Pour rendre l'analyse lisible tout au long de la présentation, on propose un nommage métier, basé sur le croisement prix moyen x volume.

Deux signaux le justifient :

- le niveau de prix moyen par catégorie,
- le volume de transactions associé.

Le préfixe des identifiants produits (`0_`, `1_`, `2_`) confirme la cohérence entre la catégorie et le produit.

À garder en tête

Hypothèse de nommage, pas une donnée source. Toute la présentation utilise ces libellés. À confirmer avec l'équipe catalogue pour valider la correspondance.

0

Catégorie 0 : Essais

Prix moyen

Volume

~10 €

415 K transactions

Prix moyen bas + plus gros volume : on est sur des livres de poche et des essais, format le plus courant du catalogue.

1

Catégorie 1 : Romans

Prix moyen

Volume

~20 €

235 K transactions

Prix moyen intermédiaire et volume élevé : typique d'un roman grand format, cœur traditionnel d'une librairie.

2

Catégorie 2 : Jeunesse

Prix moyen

Volume



~76 €

36 K transactions

Prix moyen très élevé, volume faible : beaux livres et coffrets jeunesse, segment premium. C'est ce qui ressortira comme levier central plus loin.

CATÉGORIES

Cat 1 Romans, Cat 0 Essais, Cat 2 Jeunesse : trois histoires commerciales différentes



Ce qui me frappe

Peu de ventes, mais 76 € par transaction. La Catégorie 2 Jeunesse est la catégorie qui va ressortir comme levier central dans toute la suite de l'analyse client.

À comparer avec le physique

Question à poser à Julie : en magasin, la catégorie 2 Jeunesse fait-elle aussi 5 % des ventes ?

Catégorie 1 Romans 40,1 %

4,83 M€

Le cœur du catalogue

235 592 ventes · prix moyen 20,49 €

Catégorie 0 Essais 36,7 %

4,42 M€

Le volume (65 % des transactions)

415 459 ventes · prix moyen 10,64 €


Catégorie 2 Jeunesse 23,1 %

2,78 M€

Le premium (prix moyen 76 €)

36 483 ventes · prix moyen 76,21 €

Top 10 Produits (par CA)




TOP 10 : à protéger

Presque tous en Catégorie 2 Jeunesse. Prix 60 à 146 €.
Beaux livres et coffrets à forte valeur.

Stock prioritaire, visibilité renforcée.

Flop 10 Produits (par CA)




FLOP 10 : à questionner

Uniquement des Catégorie 0 Essais à moins de 3 €. 1 à 2 ventes en 24 mois.

Candidats au déréférencement.

Diagramme de Pareto - Analyse ABC des Produits



700

produits prioritaires


21,4 % du catalogue = 80 % du CA

Décision opérationnelle

Sur ces 700 produits : toujours en stock, bien mis en avant, marketing ciblé. Sur le reste : on fait le tri pour alléger le catalogue.

COURBE DE LORENZ

Concentration du CA, et le coude terminal qui saute aux yeux



Lecture du graphique

En abscisse : clients du plus petit au plus grand acheteur. En ordonnée : CA cumulé. Plus la courbe s'éloigne de la diagonale, plus le CA est concentré.

Gini = 0,442


Inégalité marquée, sans dépendance excessive

Le coude terminal

Sur les derniers pourcents en abscisse, la courbe décroche quasi-verticalement. C'est le signal de 4 clients à part : détaillé slide suivante.

Top 1 % : 10,5 % du CA · Top 10 % : 31,6 % du CA · Top 50 % : 79,7 % du CA

Analyse Pareto Clients - Répartition du CA



Ce que montre le triangle rouge

4 clients

captent ~7,4 % du CA

pour moins de 0,05 % des clients.

50 % des clients = 80 % du CA


Le Pareto clients confirme le Gini : la moitié des meilleurs clients porte l'essentiel du CA: dont les 4 BtoB.

La courbe de Lorenz n'est pas qu'un outil descriptif

C'est elle qui m'a permis de repérer visuellement ces 4 profils grâce au coude terminal, de conclure qu'ils captent 7,4 % du CA pour 0,05 % des clients, qu'ils portent l'essentiel du Gini de 0,442, et qu'il faut les isoler : d'abord dans la stratégie commerciale (fidélisation prioritaire) et dans le notebook statistique (exclusion comme outliers pour ne pas fausser les tests).

PROFIL DES 4 BtoB

Qui sont-ils, et pourquoi on les met de côté pour les tests



Profils individuels			
Client	CA	Sessions	Panier moy.
c_1609	326 040 €	10 997	29,65 €
c_4958	290 227 €	3 851	75,36 €
c_6714	153 919 €	2 620	58,75 €
c_3454	114 111 €	5 571	20,48 €

4 clients · 884 K€ · 7,4 % du CA

De 2 600 à 11 000 commandes par compte sur 24 mois : ce ne sont pas des particuliers : librairies partenaires, institutions, revendeurs.

Exclusion pour les tests statistiques

Leurs volumes (3 851 à 10 997 sessions) écrasent les distributions et tirent les moyennes : les garder fausserait tous les tests sur la clientèle BtoC (8 596 clients).

MAINTENANT, LES QUESTIONS DE JULIE

Comprendre le comportement des clients en ligne

Cinq hypothèses qu'on entendait souvent en réunion, et qu'on n'avait jamais vérifiées.

« Les femmes achètent plutôt des romans, et les hommes des essais ? »

« Les clients plus âgés dépensent plus, parce qu'ils ont plus de moyens ? »

« Les clients âgés commandent plus souvent que les jeunes ? »

« Les jeunes ont vraiment un panier plus gros ? »

« L'âge dicte la catégorie préférée ? »

Tests statistiques menés sur 8 596 clients BtoC, les 4 BtoB sont exclus.

Je me pose deux questions simples : quelles variables je compare, et la distribution permet-elle un test "classique" ? Le tableau ci-dessous résume le raisonnement, pas besoin d'en retenir les noms, l'important c'est ce qu'on en tire.



#	Hypothèse	Types	Test retenu	Justification
1	Genre x Catégorie	Quali x Quali	Chi2 d'indépendance	Seul test adapté à 2 qualitatives
2	Âge x CA total	Quanti x Quanti	Spearman	Shapiro rejette la normalité
3	Âge x Fréquence d'achat	Quanti x Quanti	Spearman	Shapiro rejette la normalité
4	Âge x Panier moyen	Quanti x Quanti	Spearman	Shapiro rejette la normalité
5	Âge x Catégorie préférée	Quanti x Quali (3)	Kruskal-Wallis	Variances hétérogènes (Levene)

Un point important : la taille d'effet

Un résultat "significatif" sur 640 000 transactions ne veut pas dire grand-chose si l'effet réel est minuscule. C'est la taille d'effet (V de Cramer, rho, eta2) qui fait la différence entre un résultat qu'on actionne et un résultat qu'on met de côté. On va le voir dès le premier test.

TEST 1 : CHI2

Genre x Catégorie : un effet réel, mais négligeable



Résultats

Chi2	22,67
p-value	1,2 x 10-5
Degrés de liberté	2
V de Cramer	0,006

Conclusion métier

p < 0,05 : formellement, le lien est significatif.



Mais V de Cramer = 0,006 : effet négligeable. Sur 640 000 transactions, n'importe quelle micro-différence devient statistiquement significative.

Inutile de différencier l'offre par genre.

Hommes et femmes achètent dans les mêmes proportions : ~60 % Cat 0 -Essais, ~35 % Cat 1 - Romans, ~5 % et Cat 2 - Jeunesse dans les deux cas.

TESTS 2 & 3 : SPEARMAN

Âge x CA total (montant total des achats) et Âge x Fréquence : effets réels mais faibles



Test 2 · Âge x CA total

$\rho = -0,18$

$p < 0,001$

Conclusion métier

Corrélation faible et négative : les clients plus âgés dépensent légèrement moins au total. Effet réel, mais pas assez pour faire un axe d'action.

Test 3 · Âge x Fréquence d'achat


$\rho = +0,21$

$p < 0,001$

Conclusion métier

Corrélation faible et positive : les 30-49 ans commandent un peu plus souvent, les <30 deux fois moins.

Distribution de la fréquence d'achat par tranche d'âge



30-49 ans

Le cœur de l'activité en ligne

$$\rho = +0,21 \quad \cdot \quad p < 0,001$$


Lecture

Confirmation slide précédente : médiane la plus haute sur les 30-49 ans (~35 transactions / 24 mois). Les 20-29 ans commandent deux fois moins. Après 50 ans, la fréquence redescend légèrement : les seniors restent actifs sans être les plus intensifs.

Levier d'action

Programme fidélité ciblé 30-49 ans : c'est là que la fréquence est la plus haute, et donc le ROI d'une relance la plus élevé.

Age vs Panier Moyen



rho = -0,70

Corrélation forte et négative

$p < 0,001$

Conclusion métier :

Lecture

Plus le client est jeune, plus son panier moyen est gros.

Les <35 ans achètent davantage de Catégorie 2 Jeunesse (76 €). Les plus âgés achètent plus souvent, mais des tickets plus petits.


Levier d'action n°1

Cross-selling Cat 2 Jeunesse + Cat 1 Romans auprès des <35 ans.


TEST 5 : KRUSKAL-WALLIS

Âge x Catégorie préférée (des livres achetés): l'âge structure les goûts

Distribution de l'age par categorie
(Kruskal-Wallis, $p=0.0000$)



Distribution de l'age par categorie (violin)



Résultats

H = 2 003,67

$p < 0,001$

eta2 = 0,22

(taille d'effet forte)

Lecture métier

22 % de la variance de l'âge s'explique par la catégorie préférée.

Cat 2 - Jeunesse : ~25 ans

Cat 0 - Essais : ~43 ans

Cat 1 - Romans : ~55 ans

Segmentation par âge pertinente.

Reprise des mots d'Annabelle : « créer certaines offres, adapter certains prix ou cibler un certain type de clientèle ». Six arbitrages concrets.

1

CIBLE

Cibler les <35 ans avec la catégorie 2 Jeunesse

Résultat le plus fort ($\rho = -0,70$). Offres fidélité et cross-selling Catégorie 2 Jeunesse + Catégorie 1 Romans : le meilleur levier pour faire monter le panier moyen.

2

OFFRE

Sécuriser les 4 clients BtoB par contrat

884 K€ (7,4 % du CA) sur 4 comptes. Conditions pro, contact dédié, sécurisation de la récurrence.

3

OFFRE

Protéger les 700 produits qui font 80 % du CA

Zéro rupture, visibilité renforcée, marketing dédié. Sortir du catalogue les produits qui ne se vendent plus.

4

PRIX

Tester une montée en gamme sur la catégorie 2 Jeunesse

Prix moyen déjà à 76 €, mais on n'a jamais mesuré l'élasticité. A/B test sur quelques coffrets premium (+10 à 15 %) pour capter plus de marge sur les <35 ans

5

CIBLE

Segmenter par âge, pas par genre

Genre : effet négligeable ($V = 0,006$). Âge : effet fort ($\eta^2 = 0,22$). La personnalisation passe par l'âge.

6

OFFRE

Activer des leviers de croissance

CA stable à +/- 4 % sur 24 mois : on est sur un plateau. Acquisition, partenariats, nouveaux canaux : à arbitrer pour sortir du statu quo.

Merci pour votre attention

Questions & discussion

Charles Lippens

Data Analyst - Lapage

Notebooks et annexes disponibles à la demande en démonstrations.